Введение в обработку естественного языка

Задачи, подготовка данных и представление текста
Классические модели и библиотеки

Алан-Барсаг Газзаев

24 октября 2026 · Лекция 1

Содержание первой лекции

- Какие задачи решают системы обработки текста и как формулировать ожидаемый результат.
- Как собирать и размечать данные, выделять обучающую и проверочные выборки.
- Как преобразовывать текст в признаки и обучать классификатор.
- Как оценивать качество и выбирать библиотеки для практической работы.

Обработка естественного языка

- Компьютер получает текст или речь и выполняет задачу, связанную с человеческим языком.
- Одинаковое слово может иметь разные значения; смысл зависит от контекста и цели общения.
- Модель работает с числовым представлением текста, которое нужно построить или обучить.
- Качество решения определяется постановкой задачи, данными и способом проверки результата.

Основные задачи обработки текста

- Задача определяется тем, какой результат нужен пользователю.

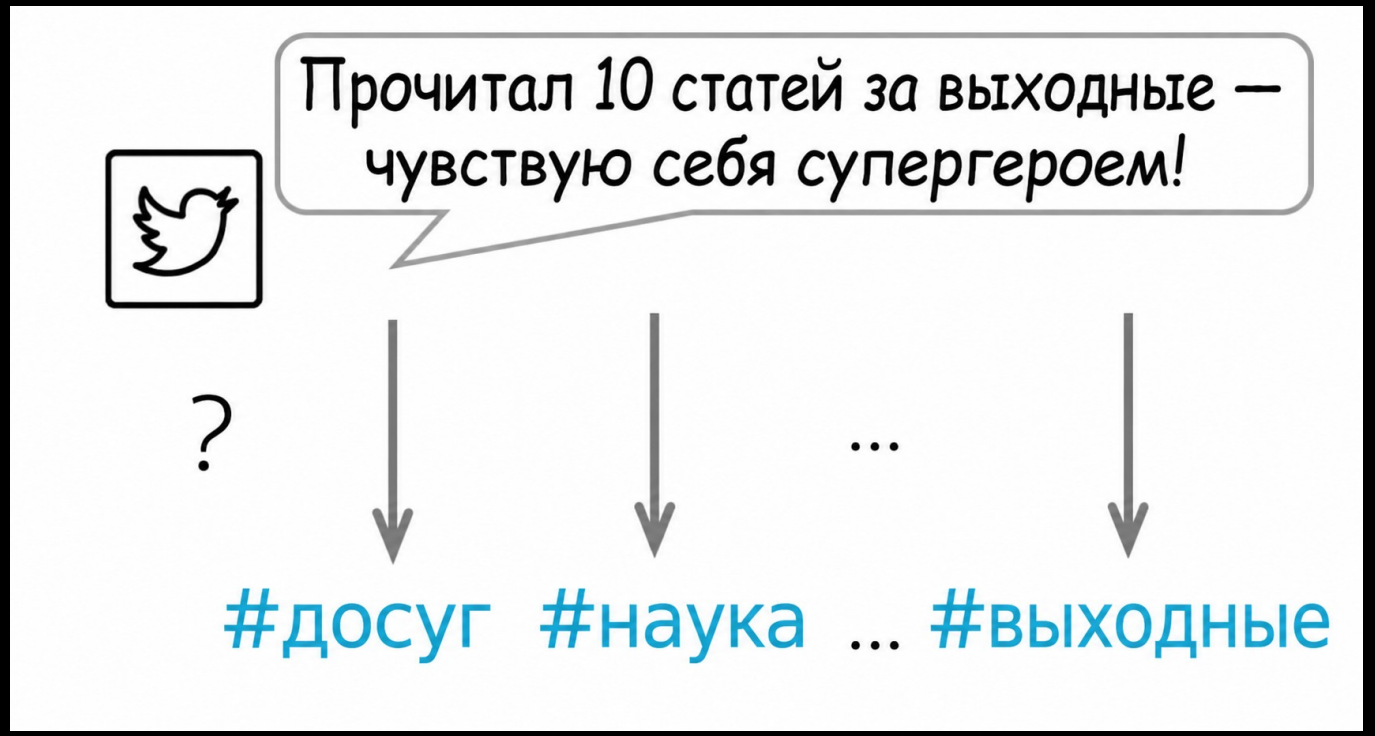
Прикладной сценарий	Тип задачи
Распределение обращений по отделам	Классификация текста
Выделение адреса из сообщения	Извлечение информации
Подбор инструкции по запросу	Поиск информации
Сокращение переписки	Краткое изложение

- Один документ можно использовать для классификации, поиска или извлечения фактов.
- Для каждого сценария нужны собственные данные и критерии качества.

Классификация текста

- По тексту модель выбирает категорию: тему новости, тип обращения или оценку отзыва.
- В обучающих примерах каждому тексту соответствует известная целевая метка.
- Набор классов и правила разметки должны быть определены до обучения.
- На новых текстах проверяют не только общую долю верных ответов, но и ошибки отдельных классов.

Одна или несколько меток

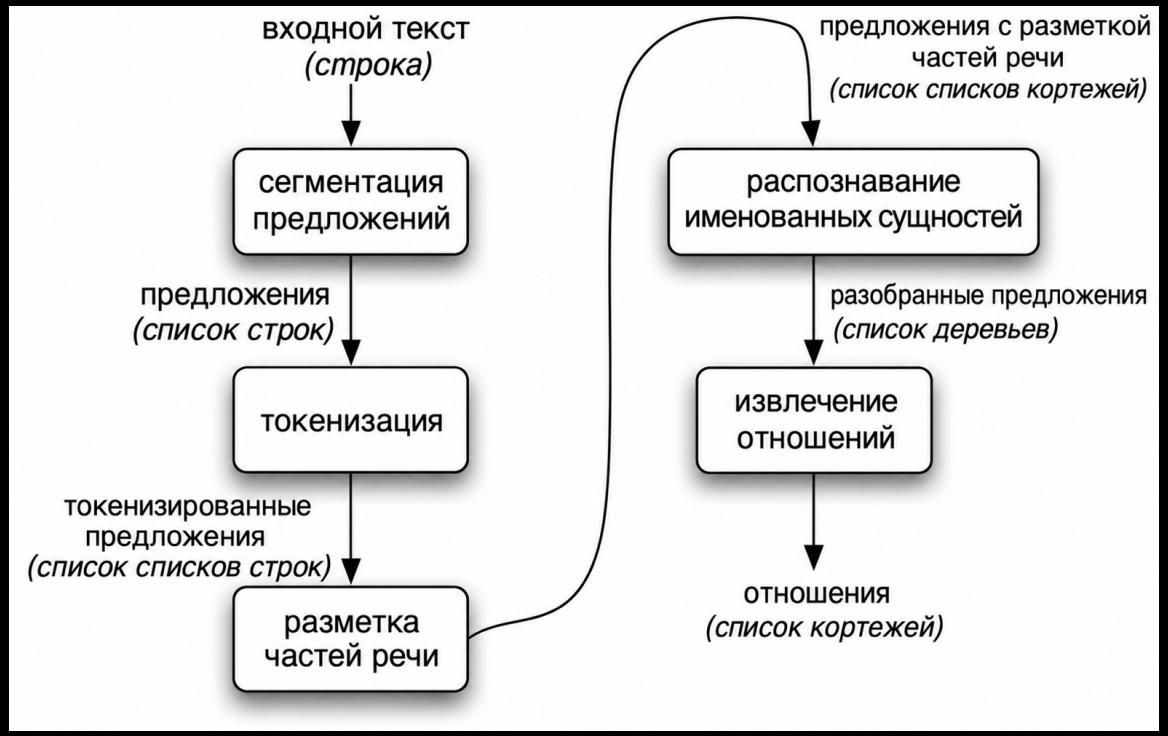


- При классификации с одной меткой каждому тексту назначают один класс.
- В многометочной классификации несколько категорий могут быть верными одновременно.
- Формат разметки определяет выход модели и способ оценки её качества.

Анализ тональности

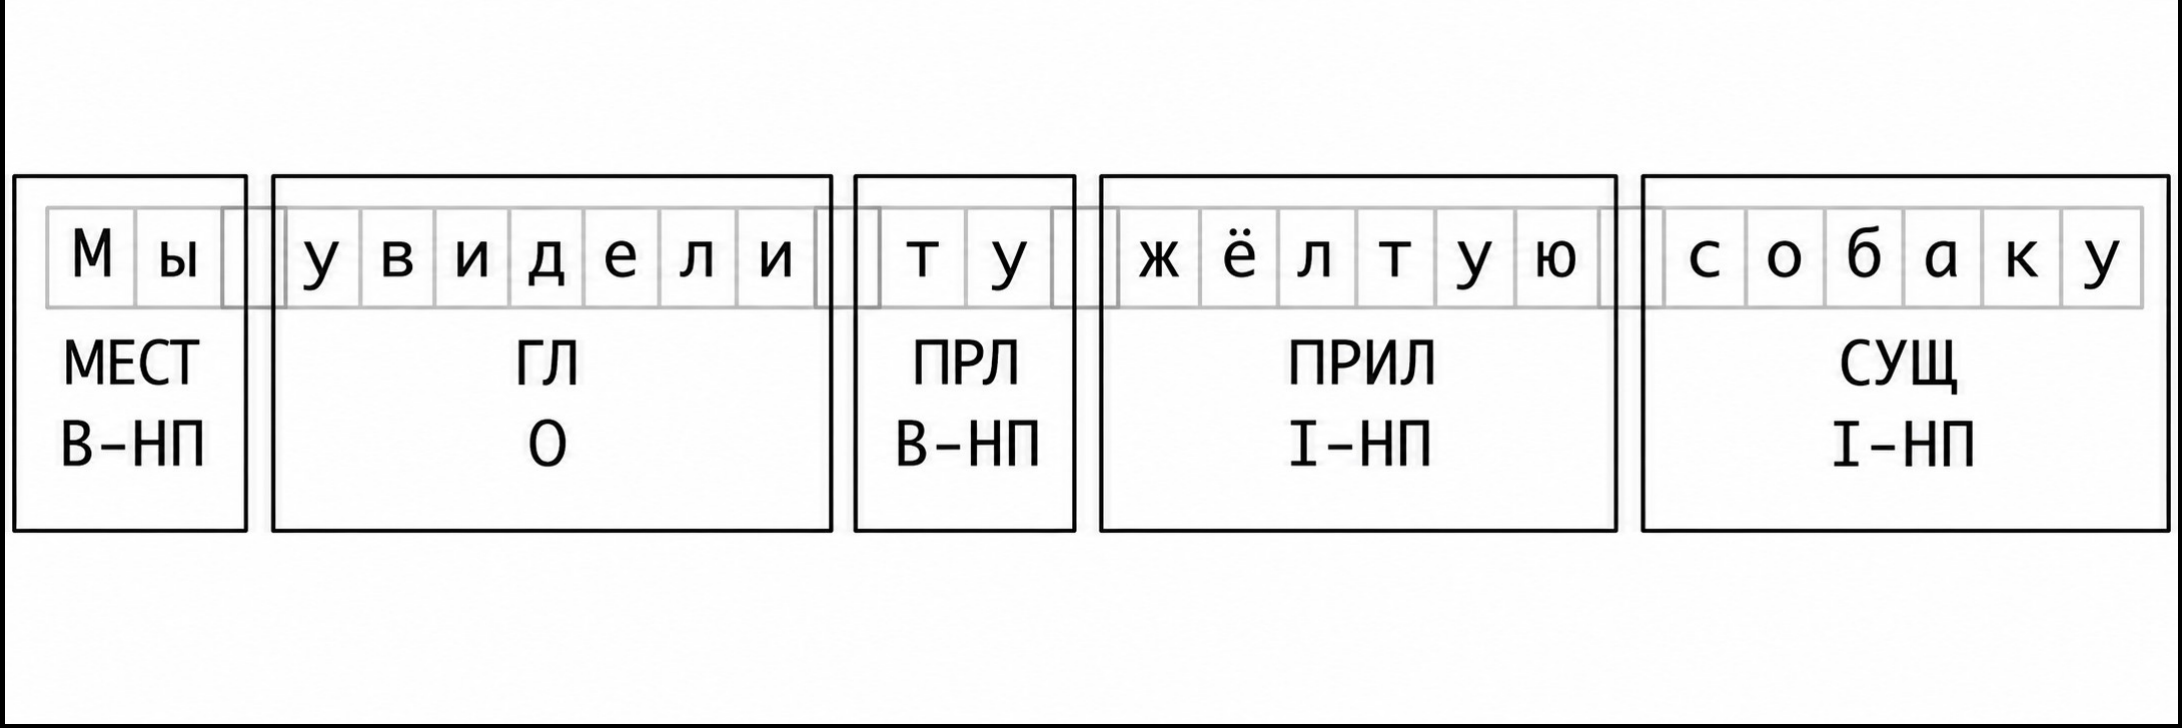
- Модель определяет оценку, выраженную в тексте: положительную, отрицательную или нейтральную.
- Тему сообщения и отношение автора следует различать: упоминание товара ещё не означает положительного отзыва.
- Отрицания, ирония и оценка отдельных характеристик усложняют задачу.
- Пример «экран хороший, батарея слабая» требует учитывать объект каждой оценки.

Извлечение информации



- Из текста выделяют имена, организации, даты, адреса и отношения между объектами.
- Ответ должен сохранять связь с исходным фрагментом документа.
- Ошибки границ сущности и ошибки её типа оценивают отдельно от классификации целого текста.

Разметка последовательности



- Каждому элементу текста присваивают метку, описывающую его роль.
- В схеме IOB отмечают начало фрагмента, его продолжение и элементы вне фрагмента.
- Соседние метки должны образовывать допустимые и осмысленные фрагменты.

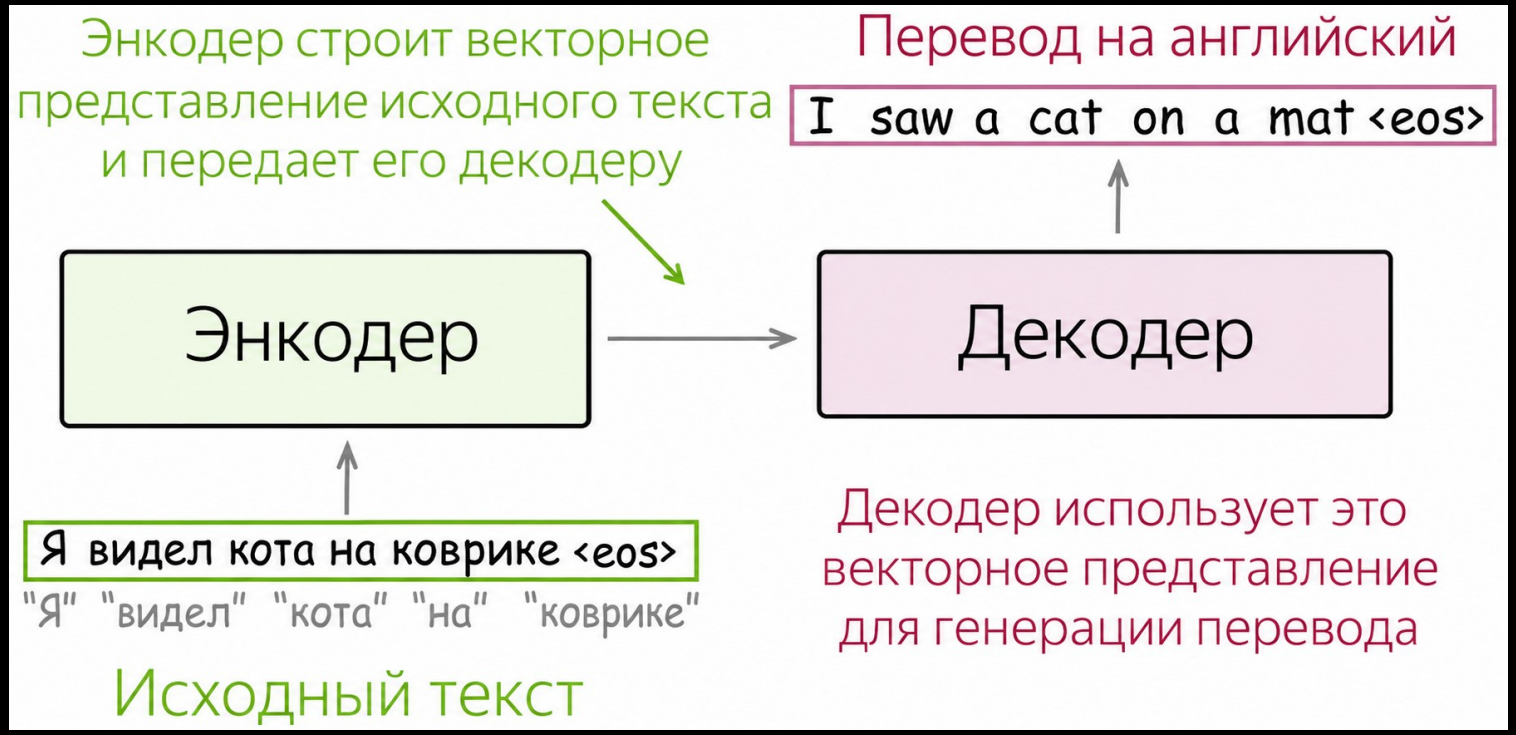
Поиск информации

- По запросу пользователя система выбирает подходящие документы или фрагменты.
- Поиск может учитывать точные слова, смысловую близость или оба вида признаков.
- Найденные результаты упорядочивают по оценке соответствия запросу.
- Качество проверяют по тому, насколько полезны документы на первых позициях выдачи.

Генерация и краткое изложение

- Генерация создаёт текст по запросу или заданному контексту.
- Краткое изложение сохраняет основные сведения исходного документа в меньшем объёме.
- Связный и грамматически правильный ответ не обязательно соответствует фактам.
- Оценка должна учитывать точность содержания, полноту и соблюдение требований к ответу.

Машинный перевод



- Система передаёт содержание текста с одного языка на другой.
- Порядок слов и длина фразы могут изменяться при сохранении смысла.
- Кодировщик представляет исходный текст, а декодировщик формирует перевод.

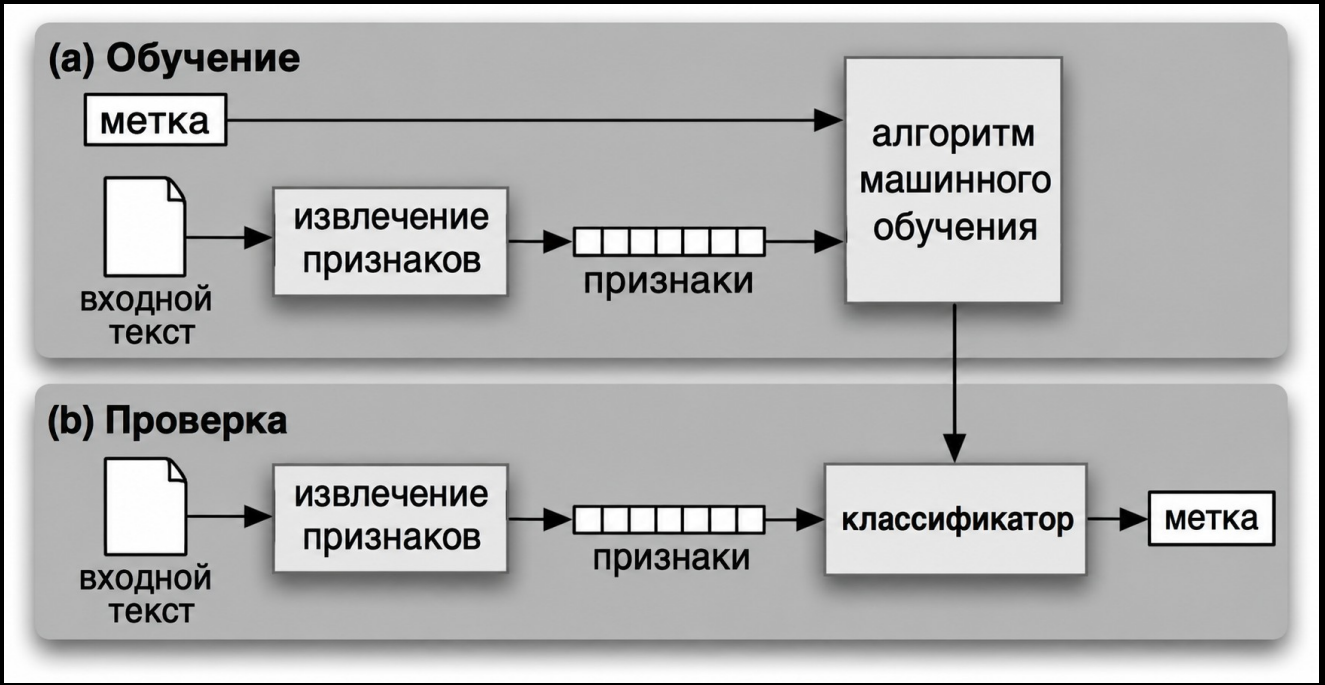
Правила и статистические методы

- Правила описывают решение явно: словари, шаблоны и условия задаёт разработчик.
- Статистическая модель находит закономерности по размеченным или неразмеченным примерам.
- Правила удобны для узких и устойчивых случаев, но требуют поддержки при изменении языка и данных.
- Обучаемые методы лучше используют большие коллекции, однако зависят от качества и состава выборки.

Нейросети и большие языковые модели

- Нейросети учатся строить полезные числовые представления текста вместе с решением задачи.
- Предобучение на больших коллекциях позволяет переносить накопленные закономерности на новые задачи.
- Большие языковые модели могут выполнять инструкции и использовать примеры в запросе.
- Даже крупная модель нуждается в проверке качества, актуальности знаний и устойчивости к ошибкам.

Обучение с учителем



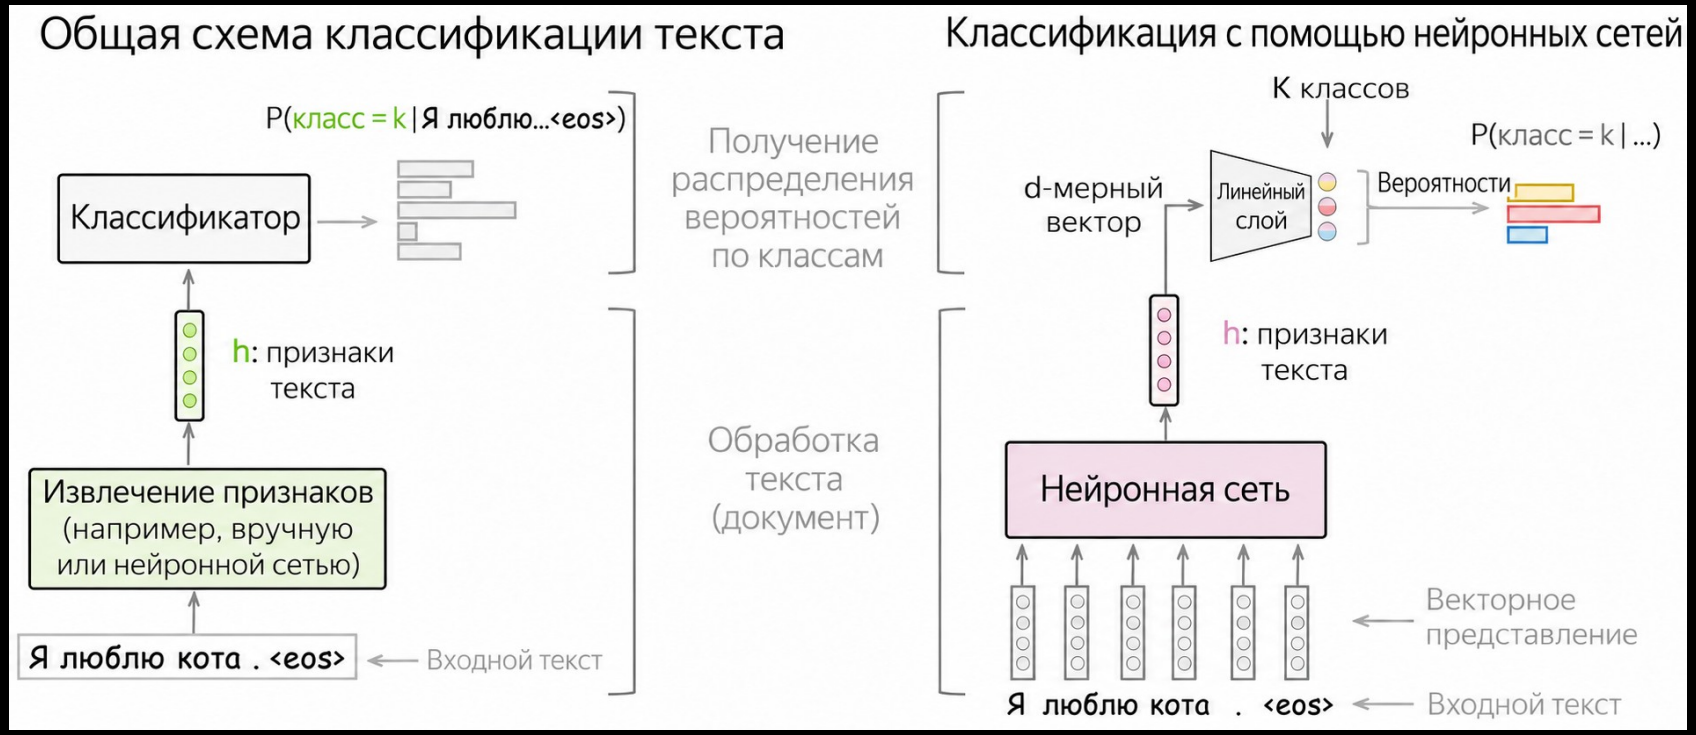
- Каждый обучающий пример содержит входной текст и правильный ответ.
- Модель подбирает параметры, уменьшая ошибку на обучающей выборке.
- Способность работать на новых данных проверяют на отдельных примерах, не использованных при обучении.

Признаки и классификатор



- Преобразование текста в признаки определяет доступную модели информацию.
- Классификатор связывает числовые признаки с целевыми классами.
- Изменение признаков и изменение классификатора следует оценивать раздельно.

Обучение представлений

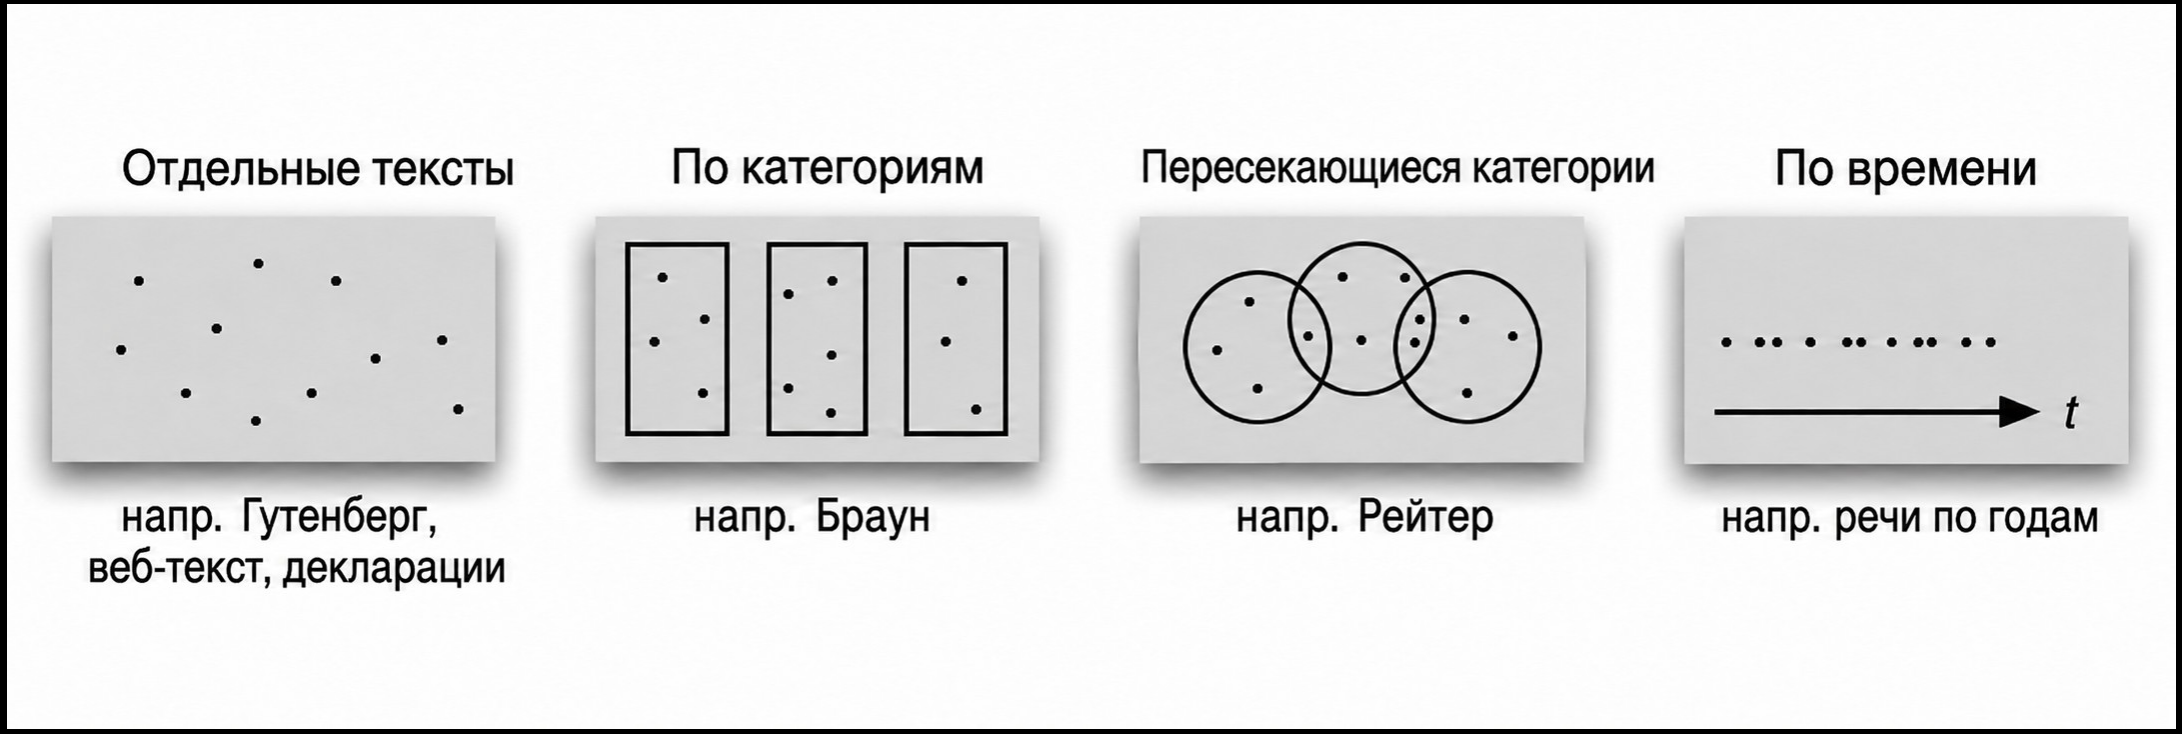


- Нейросеть может сама выделять признаки, полезные для решения задачи.
- Ошибки классификатора передают обучающий сигнал модулю представления текста.
- Качество признаков зависит от данных и цели обучения.

Наборы текстовых данных

- Набор данных включает тексты, метки и сведения, необходимые для понимания происхождения примеров.
- Публичные коллекции удобны для обучения и сравнения методов, но могут отличаться от реальной задачи.
- Следует проверять язык, предметную область, распределение классов и правила разметки.
- Лицензии, персональные данные и ограничения использования учитывают до начала работы.

Организация корпуса текстов



- Корпус — это организованная коллекция текстов с согласованной структурой.
- Документы могут иметь категории, источники, даты и другие дополнительные сведения.
- Исходные тексты и результаты обработки полезно хранить раздельно.

Сбор данных

- Сначала определяют, какие тексты поступят в систему после запуска.
- Данные собирают из подходящих источников с учётом прав доступа и разрешений на использование.
- Удаляют технический мусор и повторяющиеся записи, сохраняя полезные языковые особенности.
- Фиксируют происхождение, время получения и выполненные преобразования каждого набора.

Инструкция по разметке

- Инструкция задаёт смысл классов и критерии выбора метки.
- Пограничные случаи объясняют на примерах, включая неоднозначные и неполные сообщения.
- Согласованность разметчиков проверяют на общей части данных.
- При систематических расхождениях уточняют правила, а не просто усредняют противоречивые ответы.

Примеры наборов для классификации

- Открытые коллекции различаются типами текстов и правилами разметки.

Набор данных	Задача	Особенность
SST-2 / SST-5	Анализ тональности	Два или пять классов
IMDb Reviews	Анализ тональности	Отзывы о фильмах
AG’s News	Классификация по темам	Четыре темы новостей
TREC	Классификация вопросов	Тип ожидаемого ответа

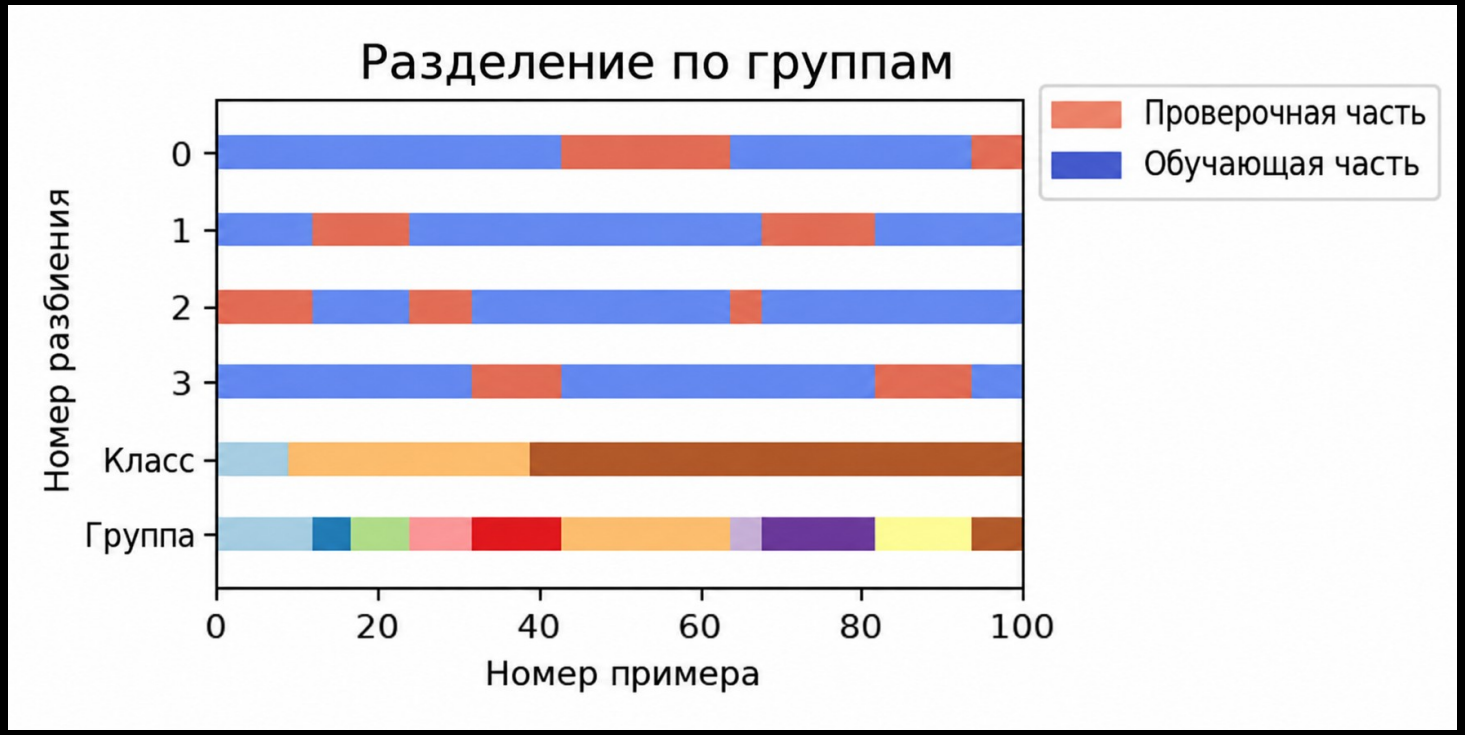
- Название набора не заменяет чтение описания и проверку состава данных.
- Для русскоязычной задачи нужно учитывать отличие языка и предметной области.

Обучающая, проверочная и тестовая выборки



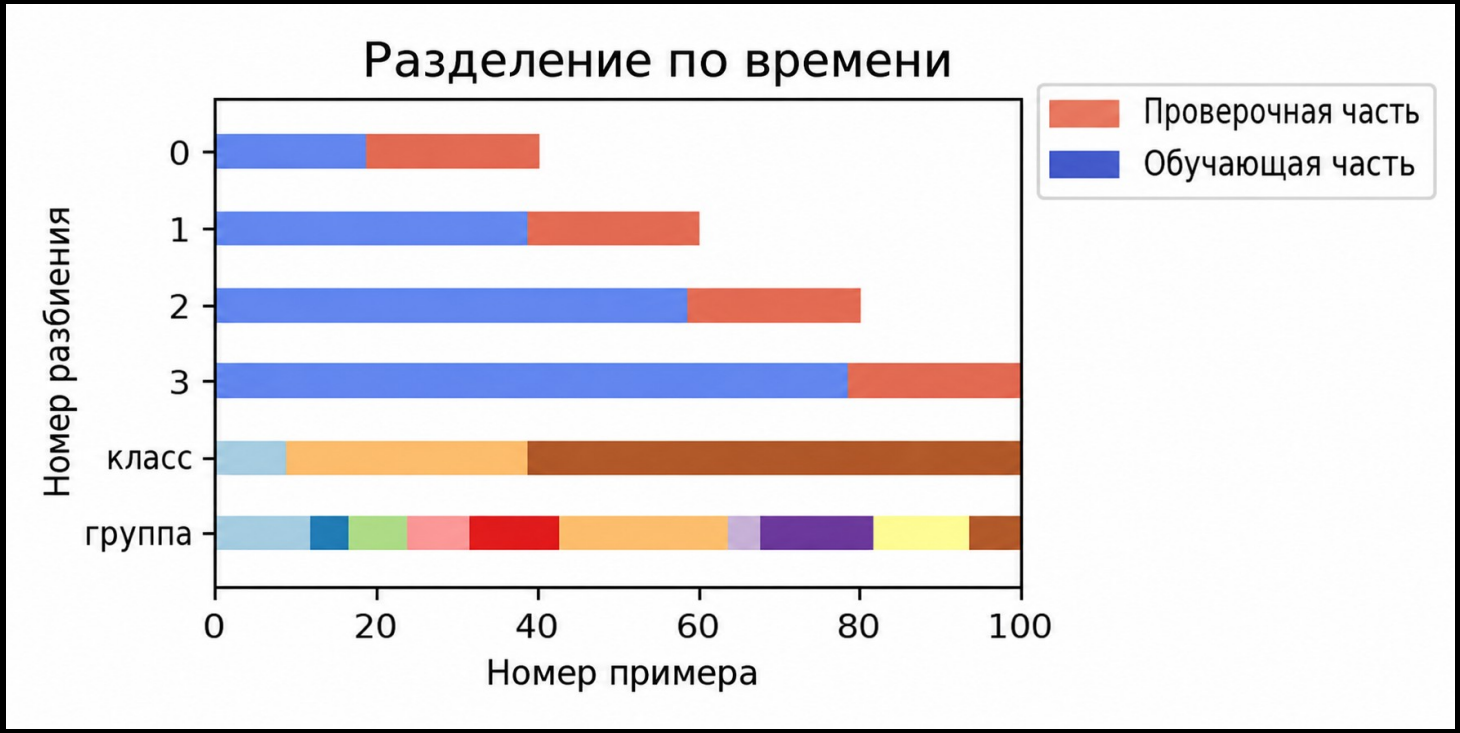
- На обучающей выборке подбирают параметры модели.
- Проверочную выборку используют для выбора настроек и сравнения вариантов.
- Тестовую выборку сохраняют для итоговой независимой оценки.

Разделение по группам



- Тексты одного автора, диалога или документа могут быть сильно связаны.
- Связанные примеры помещают в одну часть выборки, чтобы не завышать качество.
- Способ группировки должен соответствовать будущему применению системы.

Разделение по времени



- Для работы с будущими данными модель обучают на более ранних примерах.
- Проверочная и тестовая части должны находиться позже обучающей по времени.
- Такая проверка помогает заметить изменение тем, словаря и поведения пользователей.

Предварительная обработка текста

- Цель обработки — получить удобные для модели данные, сохранив нужную для задачи информацию.
- Универсального обязательного набора преобразований нет.
- Очистка, разбиение и нормализация должны одинаково выполняться при обучении и применении.
- Полезность каждого изменения подтверждают сравнением качества на проверочных данных.

Этапы подготовки текста

- Каждый этап должен иметь понятный вход и проверяемый результат.

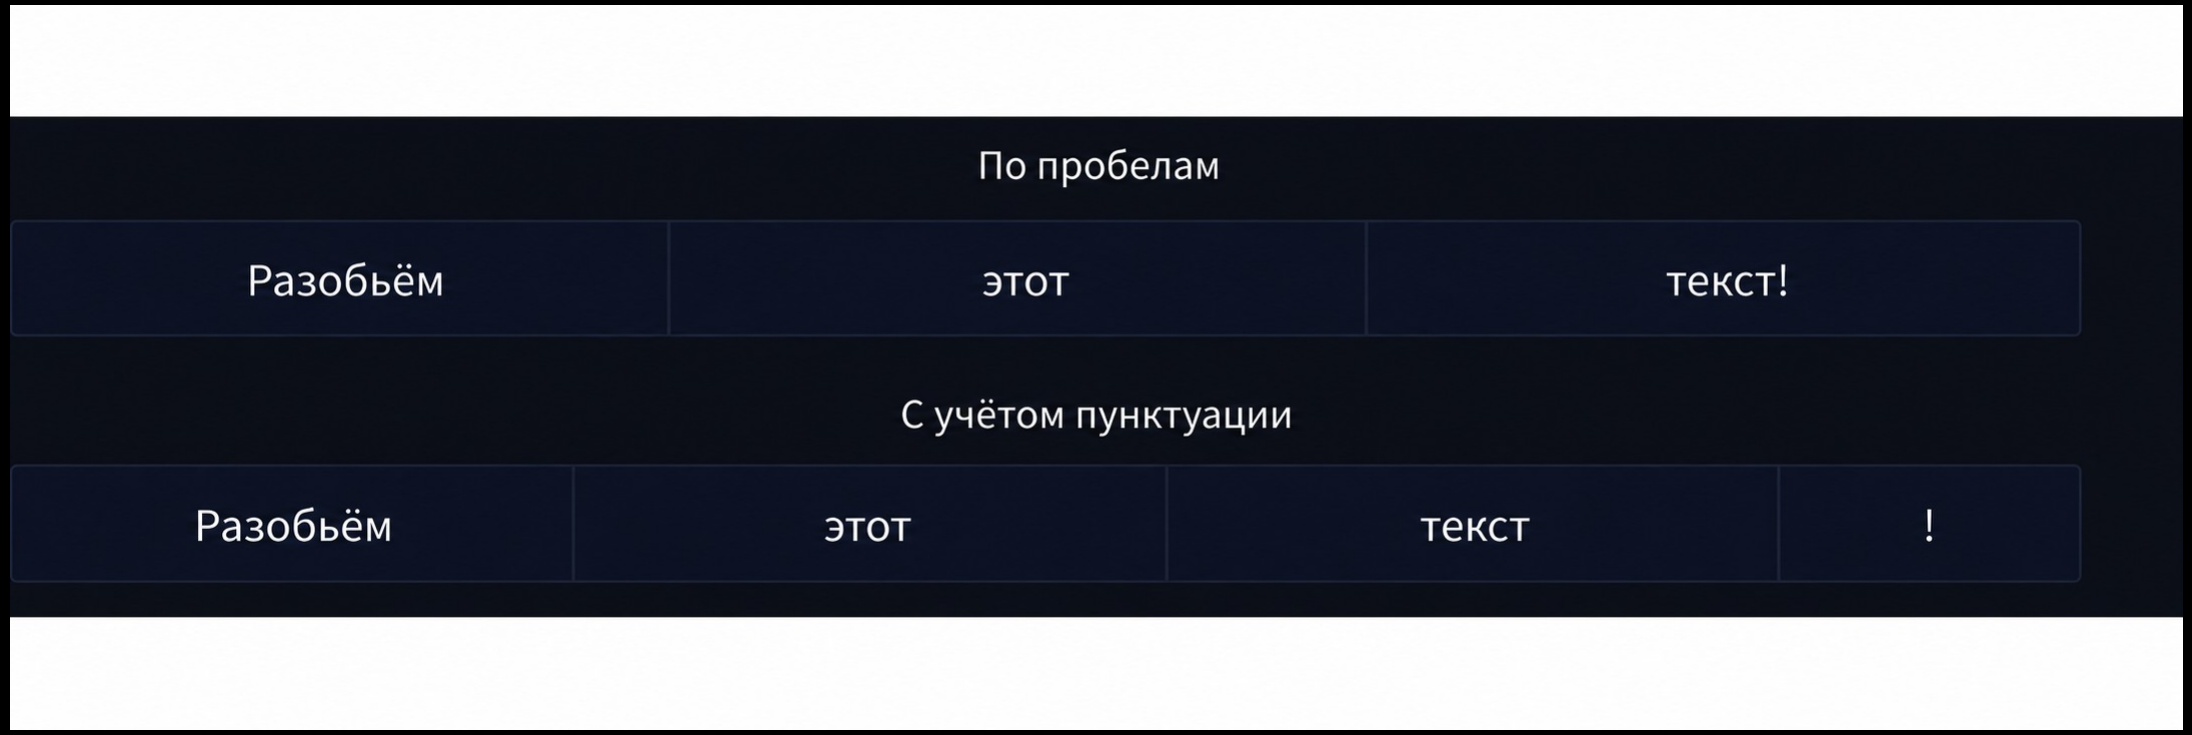
Уровень	Пример результата	Назначение
Документ	Текст и исходная разметка	Сохранение источника
Извлечённый текст	Содержимое без навигации сайта	Выбор нужного материала
Токены	Отдельные элементы текста	Определение единиц анализа
Признаки	Числа в заданном пространстве	Вход классификатора

- Исходный документ сохраняют, чтобы можно было восстановить смысл и проверить ошибки.
- Числовые признаки получают только после определения единиц анализа.

Элементы текста и словарь

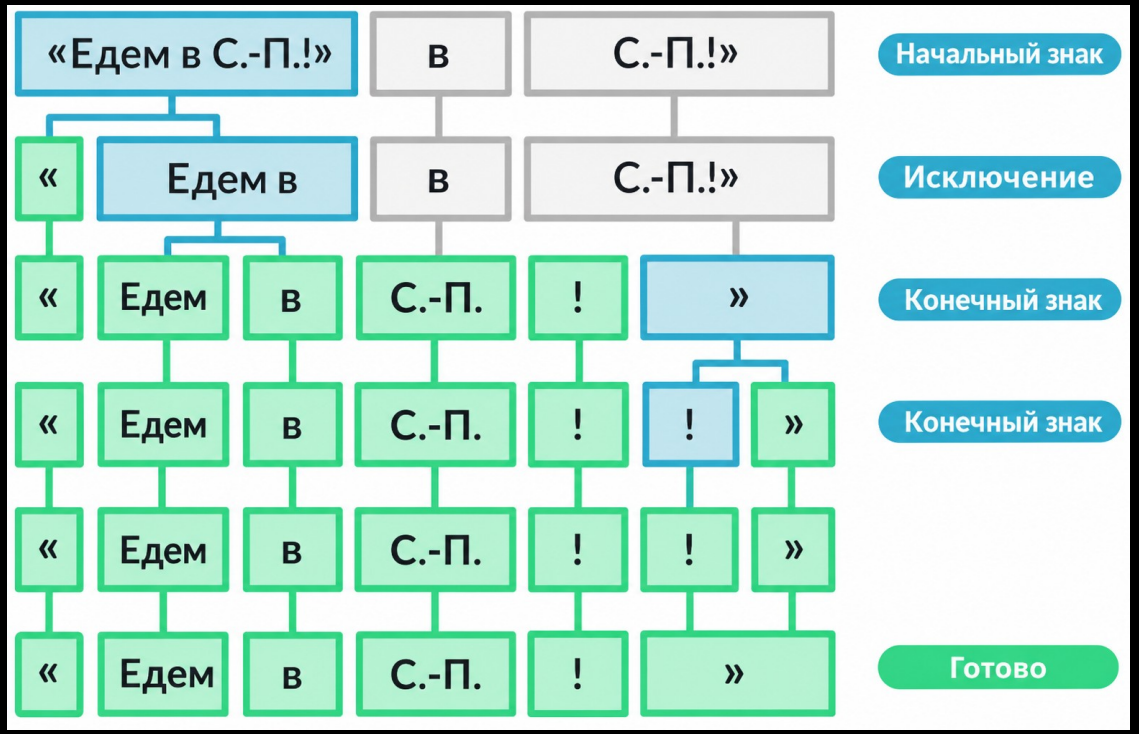
- Токен — отдельный элемент последовательности, например слово, часть слова или знак.
- Разные появления одной записи считаются разными токенами, но относятся к одной словарной единице.
- Словарь задаёт множество допустимых единиц и их числовые идентификаторы.
- Размер словаря влияет на представление редких слов, затраты памяти и длину последовательностей.

Разбиение текста на элементы



- Разбиение задаёт единицы, с которыми дальше работает модель.
- Пробелы не всегда совпадают с нужными границами слов и смысловых фрагментов.
- Правила разбиения должны соответствовать языку и выбранной модели.

Правила разбиения и исключения



- Сокращения, дефисы, числа и адреса требуют особых правил.
- Одинаковые символы могут играть разные роли в разных контекстах.
- Пограничные случаи проверяют на характерных примерах реальных данных.

Сложные случаи разбиения

- При выборе границ важно учитывать задачу, а не только внешний вид записи.

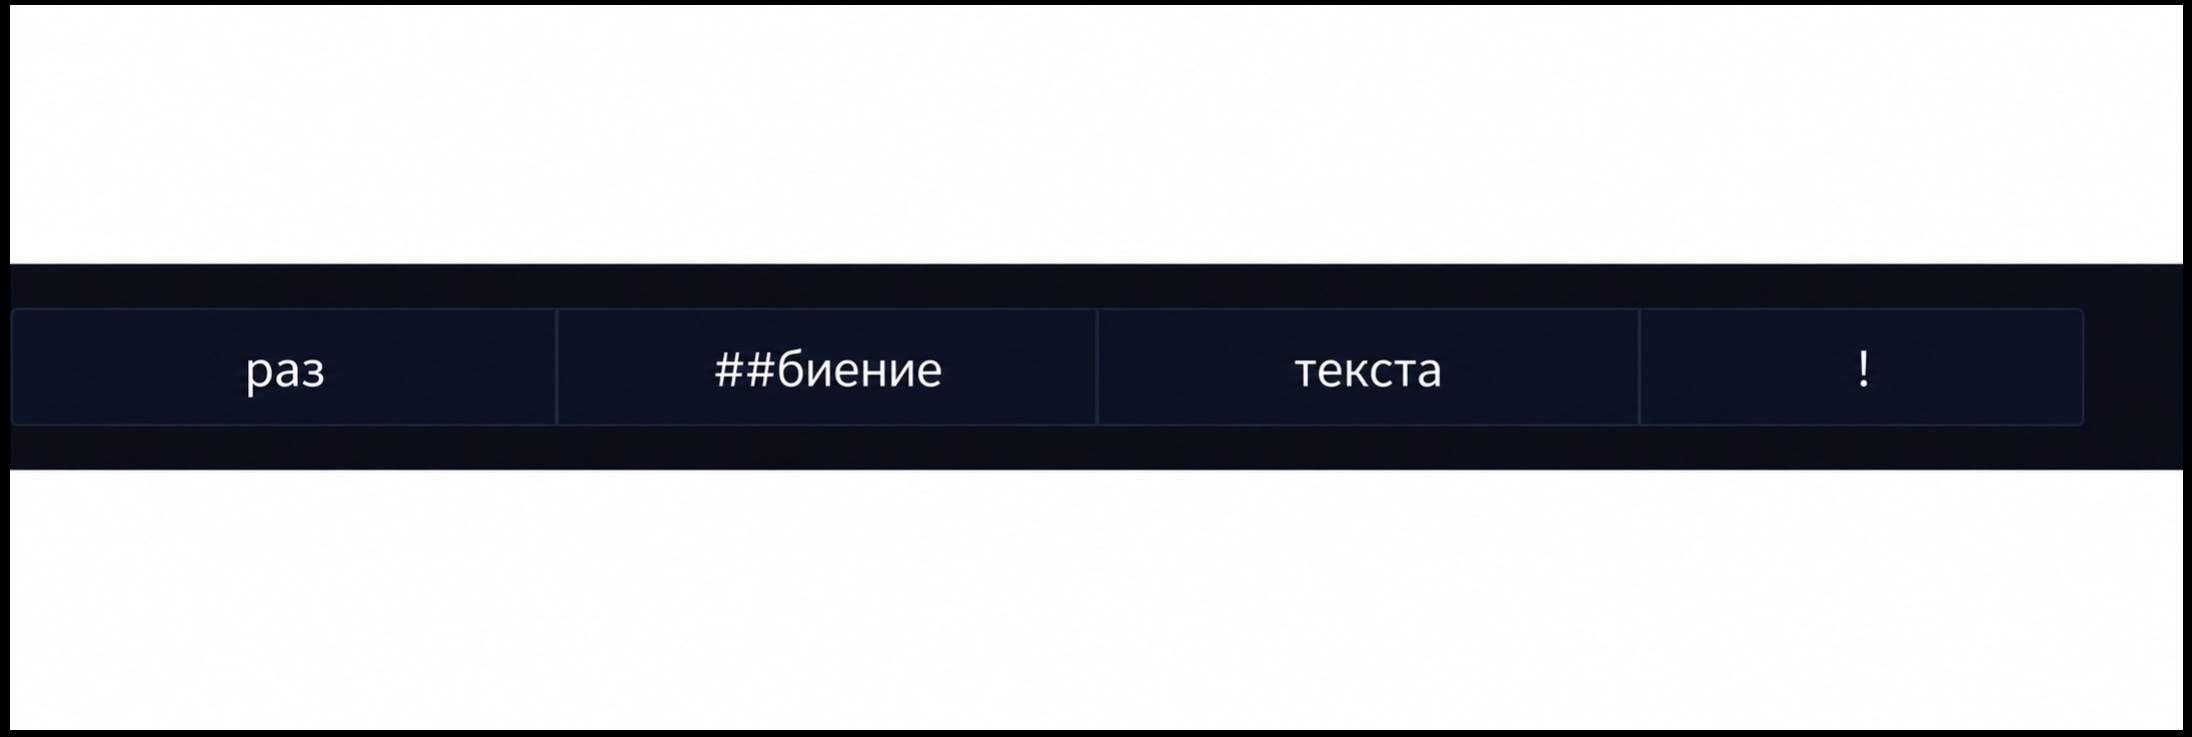
Запись	Существенное свойство	Что требуется проверить
Санкт-Петербург	Название с дефисом	Границы названия
24.10.2026	Единая запись даты	Связь частей даты
3,5 кг	Число и единица измерения	Десятичный разделитель
не понравился	Отрицание и оценка	Сохранение соседства

- Название, дата и единица измерения могут состоять из нескольких частей.
- Ошибки разбиения распространяются на последующие этапы обработки.

Особенности русского текста

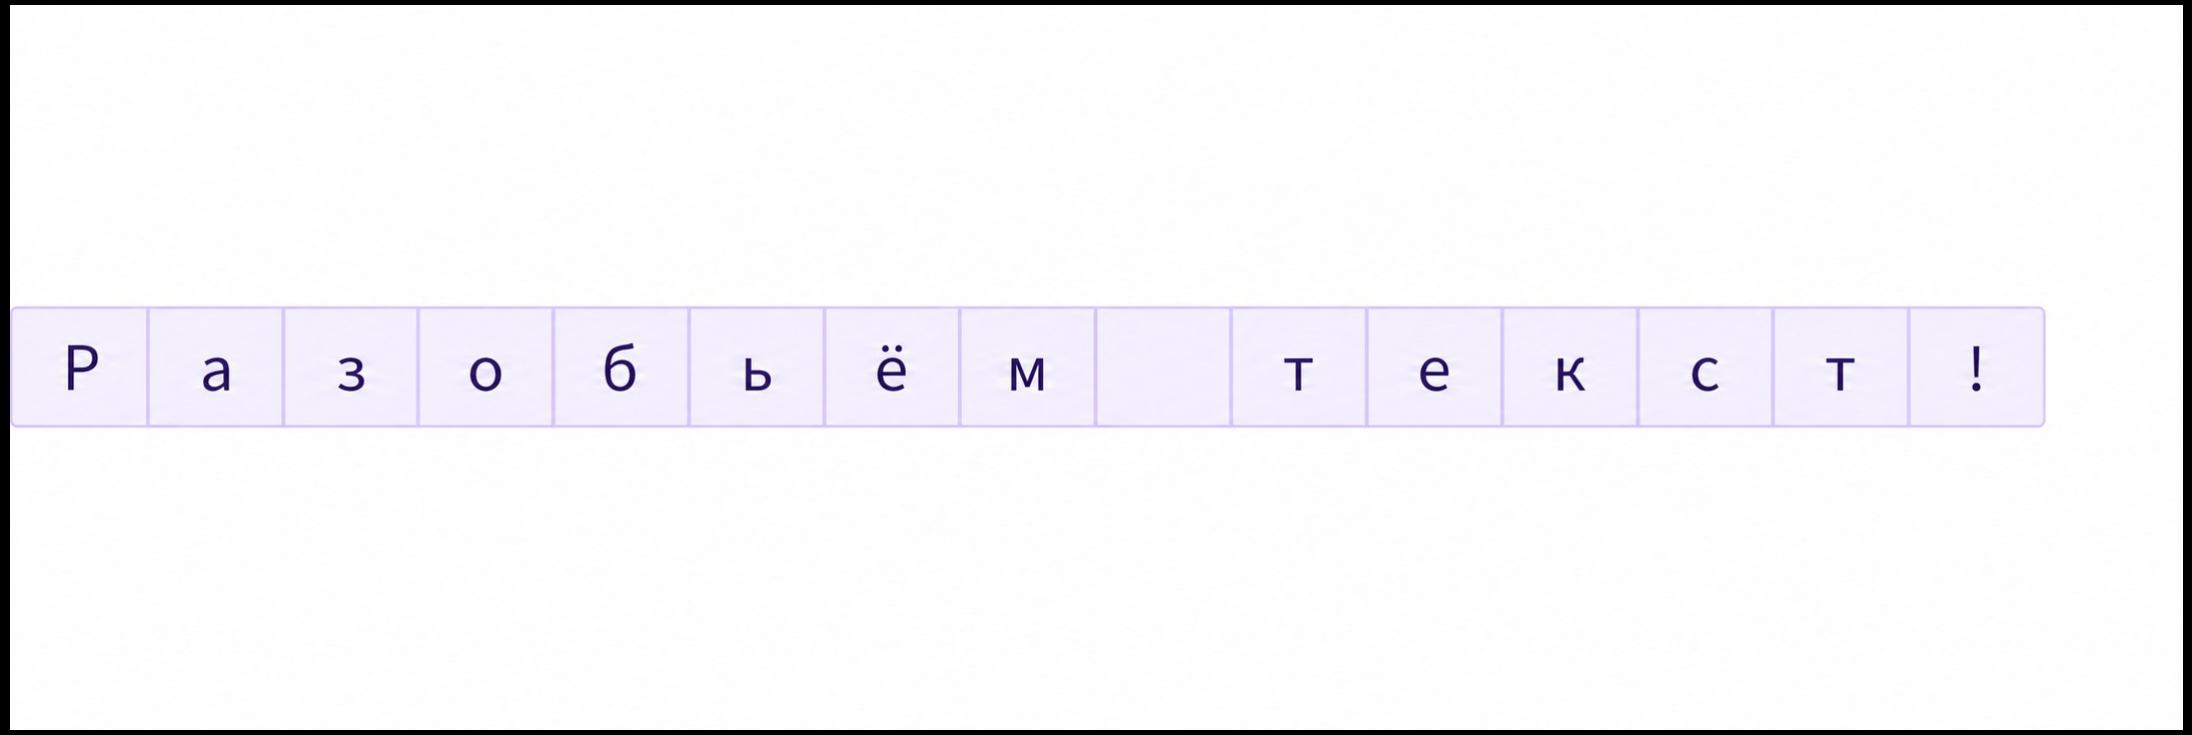
- Окончания и формы слов передают грамматическую информацию.
- Одинаковая запись может соответствовать разным словам и частям речи.
- Буквы «е» и «ё», дефисы, сокращения и свободный порядок слов требуют осмысленной обработки.
- Языковые модели и правила проверяют на русскоязычных примерах, близких к целевой задаче.

Слова, символы и части слов



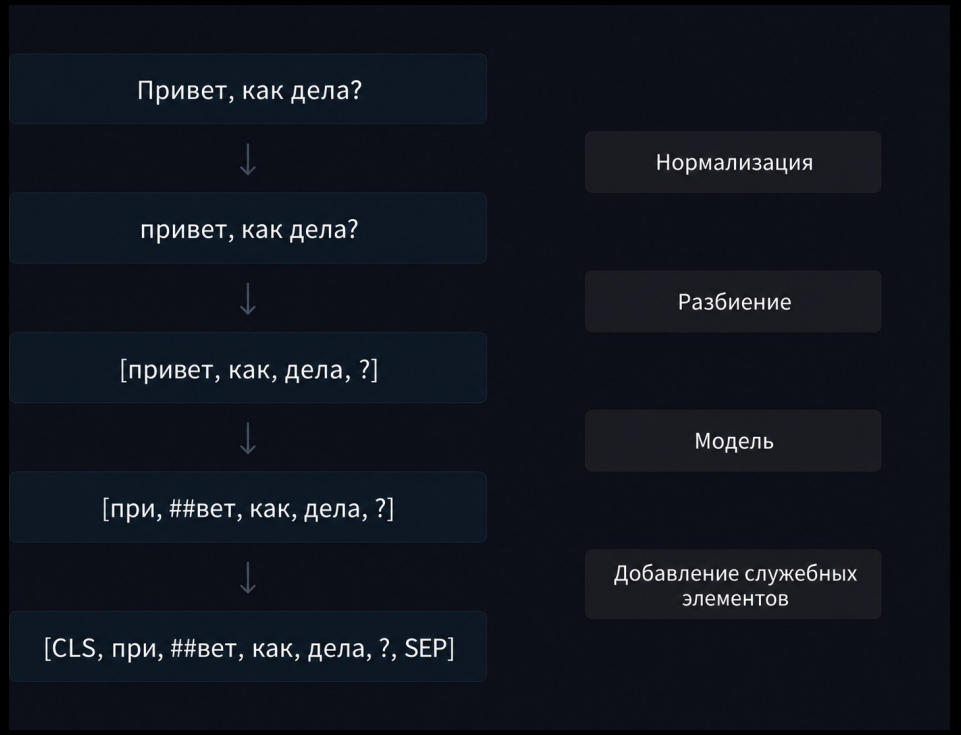
- Словное разбиение удобно для интерпретации, но требует обработки неизвестных слов.
- Символьное разбиение ограничивает размер словаря, увеличивая длину последовательности.
- Разбиение на части слов позволяет собирать редкие слова из знакомых элементов.

Представление по символам



- Каждый символ становится отдельным элементом последовательности.
- Такое представление сохраняет написание, опечатки и внутреннее строение слова.
- Для понимания длинных зависимостей модели приходится учитывать больше позиций.

Разбиение на части слов



- Часто встречающиеся фрагменты получают собственные идентификаторы.
- Редкая или новая запись может состоять из нескольких известных частей.
- При применении готовой модели используют именно её словарь и правила разбиения.

Нормализация текста

- Нормализация приводит допустимые варианты записи к согласованному виду.
- Можно устранять лишние пробелы, унифицировать некоторые символы и приводить буквы к одному регистру.
- Преобразование не должно уничтожать признаки, важные для задачи: например, заглавные буквы в именах.
- Правила фиксируют и применяют одинаково ко всем частям данных.

Начальная форма и усечение слова

- Приведение к начальной форме использует языковые признаки и словарь.

Характеристика	Начальная форма	Усечение слова
Принцип	Определение словарной формы с учётом языковых признаков	Сокращение слова по набору правил
Пример	«машины» — «машина»	«машины» — «машин»
Результат	Лемма, обычно полноценное слово	Усечённая запись, не обязательно слово

- Усечение отбрасывает части слова по правилам и не гарантирует получения существующего слова.
- Выбор метода зависит от языка, скорости и требуемой точности.

Роль контекста при разборе слова

- Одинаковая запись может иметь разные начальные формы.

Фрагмент	Словоформа	Интерпретация
Деталь изготовлена из стали	стали	Существительное «сталь»
Они стали работать быстрее	стали	Глагол «стать»
Новое стекло треснуло	стекло	Существительное «стекло»
Молоко стекло на пол	стекло	Глагол «стечь»

- Соседние слова помогают определить грамматическую роль и значение.
- Поэтому разбор отдельных слов без контекста может давать неверный результат.

Морфологический анализ

- Морфологический анализ определяет часть речи и грамматические признаки слова.
- Для русского языка важны падеж, число, род, время и другие категории.
- Возможны несколько допустимых разборов; контекст помогает выбрать нужный.
- Такие признаки полезны для анализа языка, но не обязаны улучшать любой классификатор.

Частые слова и отбор признаков

- Частые служебные слова иногда исключают, чтобы уменьшить объём признаков.
- Высокая частота сама по себе не означает отсутствия полезной информации.
- Для анализа тональности и смысла особенно важно сохранять отрицания.
- Списки исключений проверяют на конкретной задаче и сравнивают с вариантом без удаления.

Отрицания и удаление слов

- Удаление короткого служебного слова может полностью изменить смысл.

Исходный текст	После удаления «не»	Смысловой эффект
Товар понравился	Товар понравился	Положительная оценка
Товар не понравился	Товар понравился	Отрицание исчезло
Не могу рекомендовать	Могу рекомендовать	Смысл изменился
Совсем не плохой товар	Совсем плохой товар	Оценка искажена

- Нужно проверять не только список исключений, но и получившиеся тексты.
- Примеры с отрицанием полезны для ручного анализа ошибок системы.

Потери при обработке текста

- Приведение к нижнему регистру может убрать признаки имени собственного или эмоционального акцента.
- Удаление пунктуации и смайликов может стереть отношение автора.
- Сведение словоформ к одной записи иногда уничтожает грамматические различия.
- Исходный текст сохраняют, а полезность преобразований подтверждают проверкой качества.

Выбор обработки под задачу

- Решение об очистке принимают с учётом того, какую информацию использует модель.

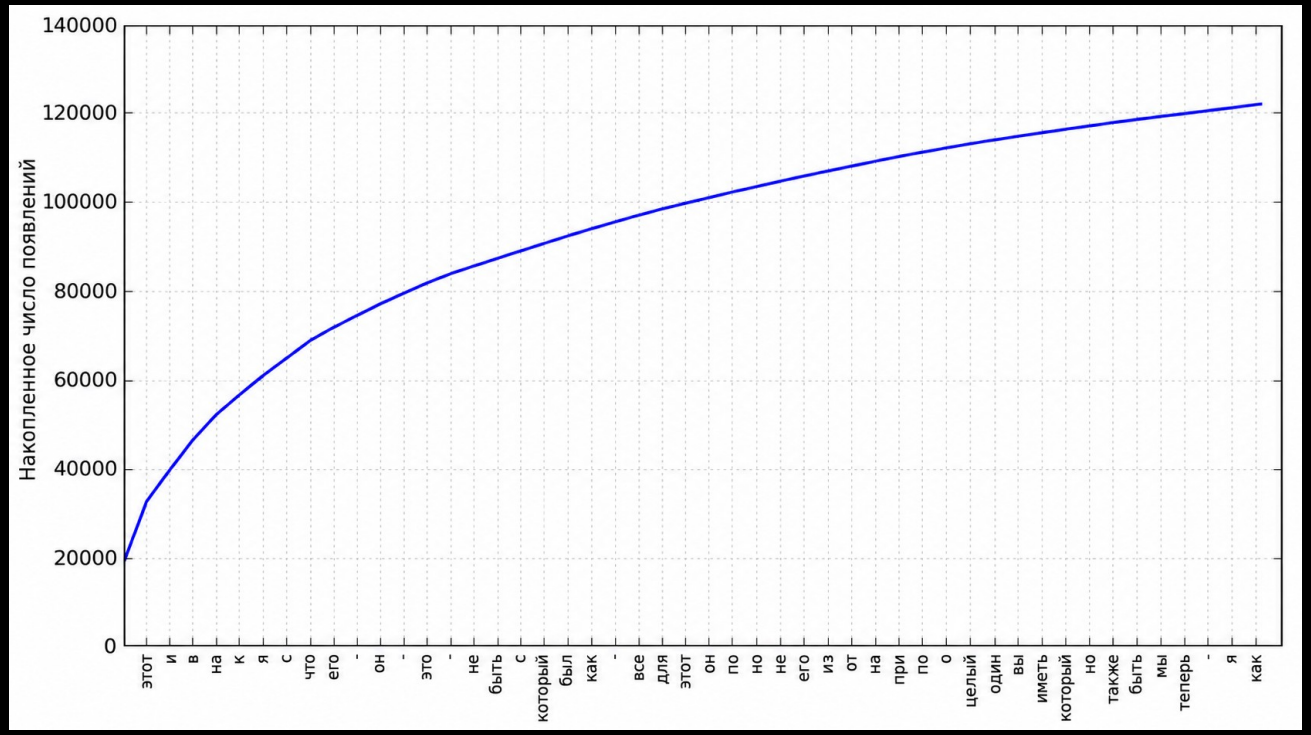
Исходный текст	Методический комментарий
«НЕ рекомендую!!!»	Сохранить отрицание, проверить роль регистра и пунктуации
«Заказ №48392 задержали»	Рассмотреть маскирование идентификатора, сохранить событие
«Классный товар :)»	Учесть смайлик как возможный эмоциональный сигнал
« пришло быстро »	Устранить внешние и повторяющиеся пробелы

- Для идентификаторов, отрицаний и эмоциональных знаков могут потребоваться разные правила.
- Практический ориентир — устойчивое качество на новых данных.

Статистика корпуса

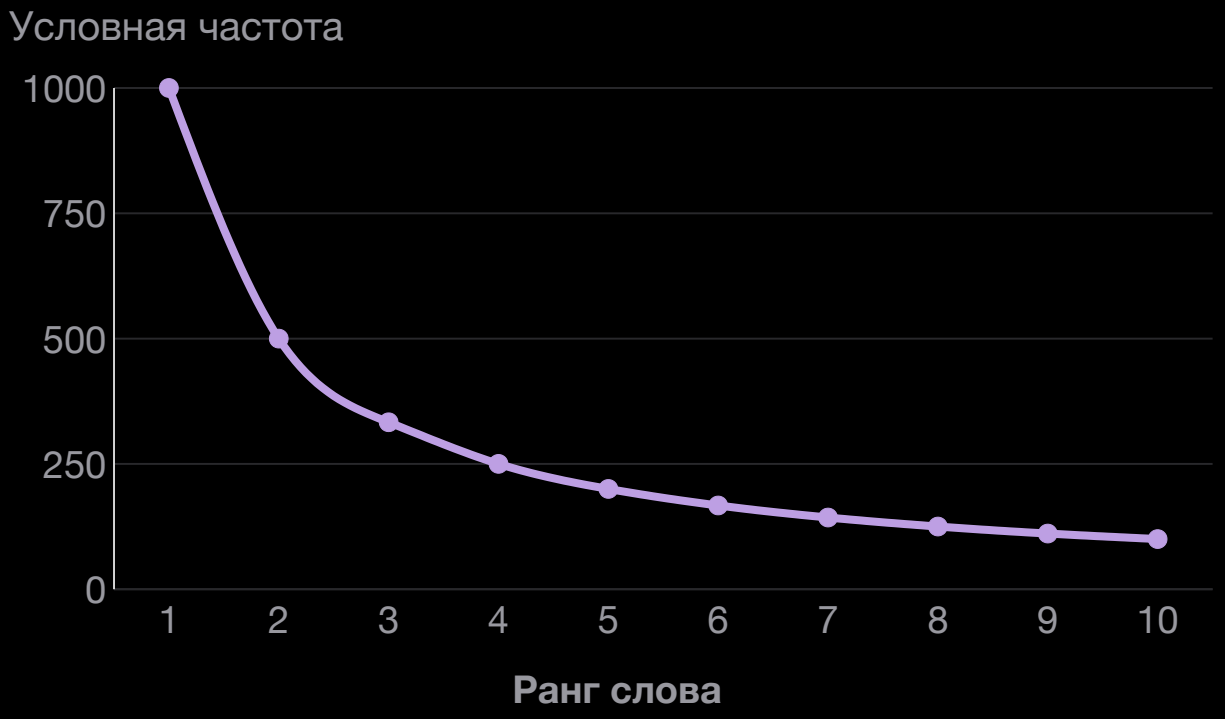
- Измеряют число документов, длину текстов и размер словаря.
- Сравнивают частоты слов, доли классов и количество повторов.
- Отдельно проверяют пустые записи, необычно длинные тексты и ошибки кодировки.
- Статистика помогает заметить проблемы данных до обучения модели.

Частота слов



- Частота показывает, сколько раз единица встречается в корпусе.
- Небольшое число слов обычно встречается очень часто, а множество других — редко.
- Частотный анализ помогает оценить словарь и выбрать пороги отбора признаков.

Закон Ципфа



- При упорядочивании слов по частоте частота приблизительно убывает обратно пропорционально рангу.
- Несколько наиболее частых слов занимают большую долю текста.
- Редкие слова образуют длинную часть распределения и усложняют оценку статистики.
- Это эмпирическая закономерность, а не точный закон для любого корпуса и всех рангов.

График показывает условную зависимость «частота = 1000 / ранг». Это иллюстрация, а не измерение учебного корпуса.

Последовательности слов и символов

- Группа из n соседних элементов называется n-граммой.
- Группы слов сохраняют локальный порядок: «не понравился» отличается от отдельных слов.
- Группы символов помогают учитывать окончания, части слов и некоторые опечатки.
- Увеличение длины групп расширяет словарь признаков и усиливает разреженность данных.

Примеры последовательностей

- Одни и те же данные можно описать одиночными словами, парами слов или группами символов.

Представление	Исходная запись	Полученные элементы
Одиночные слова	товар не пришёл	товар · не · пришёл
Пары слов	товар не пришёл	товар не · не пришёл
Группы из трёх символов	товар	тов · ова · вар
Группы из четырёх символов	товар	това · овар

- Выбор элементов определяет, какие совпадения сможет обнаружить модель.
- Размер словаря и качество признаков проверяют на обучающих и проверочных данных.

Признаки и языковая модель

Марковское предположение

> Вероятность слова зависит только от **фиксированного** числа предыдущих слов.

Для модели n-грамм,

$$P(y_t \mid \underbrace{y_1, y_2, \ldots, y_{t-1}}) = P(y_t \mid \underbrace{y_{t-n+1}, \ldots, y_{t-1}})$$

все предыдущие слова — n-1 предыдущее слово

- Группы соседних слов можно использовать как признаки документа.
- Языковая модель оценивает вероятность продолжения последовательности.
- Ограничение контекста предыдущими n – 1 элементами упрощает модель, но теряет дальние зависимости.

Модель «мешок слов»

- Документ представляют частотами слов из фиксированного словаря.

Текст	товар	хороший	плохой
«товар хороший»	1	1	0
«товар плохой»	1	0	1
«хороший хороший товар»	1	2	0

- Порядок слов исчезает, но информация о составе текста сохраняется.
- Простой метод служит отправной точкой для сравнения более сложных представлений.

Матрица «термин — документ»

	Антоний и Клеопатра	Юлий Цезарь	Буря	Гамлет	Отелло	Макбет	...
Антоний	1	1	0	0	0	1	
Брут	1	1	0	1	0	0	
Цезарь	1	1	0	1	1	1	
Кальпурния	0	1	0	0	0	0	
Клеопатра	1	0	0	0	0	0	
милость	1	0	1	1	1	1	
хуже	1	0	1	1	1	0	
...							

► **Рисунок 1.1** Матрица вхождений терминов в документы. Элемент матрицы (t, d) равен 1, если пьеса в столбце d содержит слово из строки t, и 0 в противном случае.

- Строки и столбцы связывают документы со словарными единицами.
- Значением может быть наличие слова, его частота или вычисленный вес.
- Общая структура позволяет применять стандартные методы машинного обучения.

Разреженные представления

- Каждый короткий документ содержит лишь малую часть общего словаря.

Документ	товар	доставка	цена	экран	батарея
A	1	0	0	0	0
B	1	1	0	0	0
C	0	0	1	1	0
D	0	0	0	0	2

- Поэтому большинство координат его вектора равны нулю.
- Специальный формат хранения сохраняет только ненулевые значения и их позиции.

Взвешивание слов по важности

- TF-IDF сочетает частоту слова в документе и редкость слова среди документов.
- Слово получает меньший вес, если встречается почти во всей коллекции.
- Формулы частоты, сглаживания и нормализации могут различаться между реализациями.
- Все параметры преобразования оценивают по обучающим данным.

Пример вычисления весов слов

- Рассмотрим три документа: «товар хороший», «товар плохой» и «доставка».
- Слово «товар» встречается в двух документах; остальные слова — в одном.
- При сглаживании IDF = ln((1 + N) / (1 + df)) + 1 получаем 1,288 и 1,693 соответственно.
- Веса документа затем могут нормироваться по длине вектора; это отдельный шаг преобразования.

Число документов и редкость слова

- Документная частота считает документы с термином, а не все его появления.

Термин	Документов с термином	Сглаженный IDF
товар	2	1,288
хороший	1	1,693
плохой	1	1,693
доставка	1	1,693

- Чем больше документов содержит термин, тем меньше его редкость в данной коллекции.
- Для трёх документов таблица показывает сглаженные значения IDF.

Настройка и применение преобразования

- На обучающей выборке формируют словарь и оценивают веса редкости слов.
- К проверочным, тестовым и новым текстам применяют уже настроенное преобразование.
- Повторная настройка на тестовых данных нарушает независимость итоговой оценки.
- Неизвестные слова обрабатывают по правилам выбранного метода.

Ограничения словарных признаков

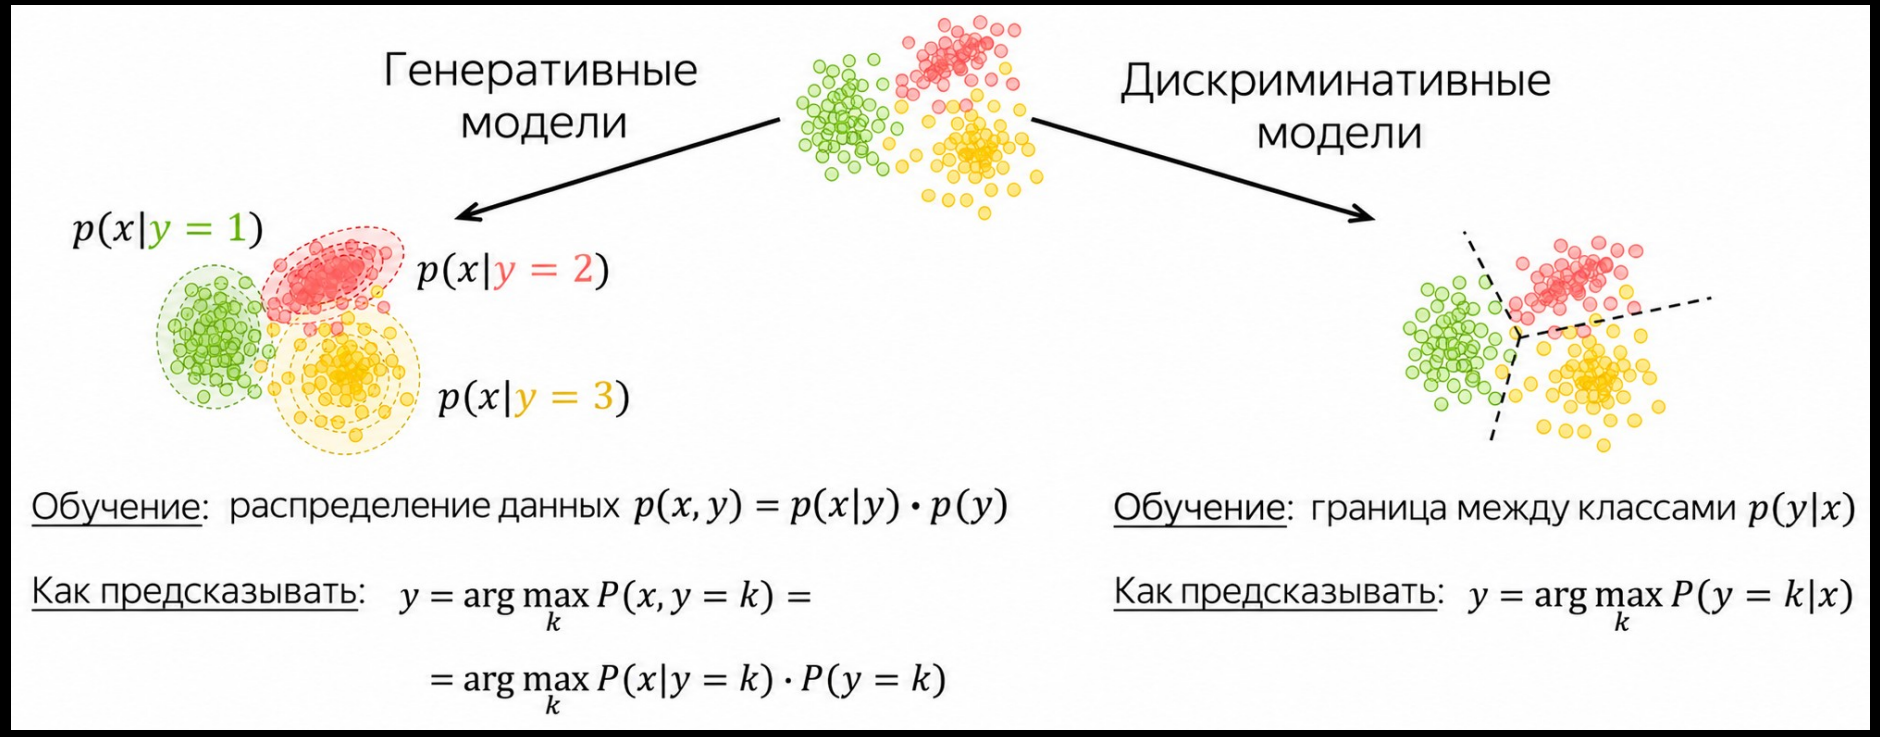
- Разные слова могут выражать близкий смысл, не имея общих координат в словаре.
- Одно слово может встречаться в разных значениях.
- Без дополнительных признаков теряются порядок и отношения между словами.
- Большой словарь увеличивает число параметров, а редкие признаки трудно надёжно оценить.

Построение признаков из сочетаний



- Сочетания слов сохраняют часть локальных зависимостей.
- Например, «не понравился» позволяет отличить отрицание от положительной оценки.
- Полезность новых признаков проверяют по качеству, а не только по размеру словаря.

Порождающие и разделяющие модели



- Порождающая модель описывает совместную вероятность текста и класса.
- Разделяющая модель оценивает класс по тексту или строит границу между классами.
- Эти подходы используют разные предположения об устройстве данных.

Наивный байесовский классификатор



- Модель использует вероятности классов и частоты признаков внутри классов.
- Упрощающее предположение: при известном классе признаки условно независимы.
- Метод быстро обучается и полезен как простое исходное решение.

Сглаживание частот

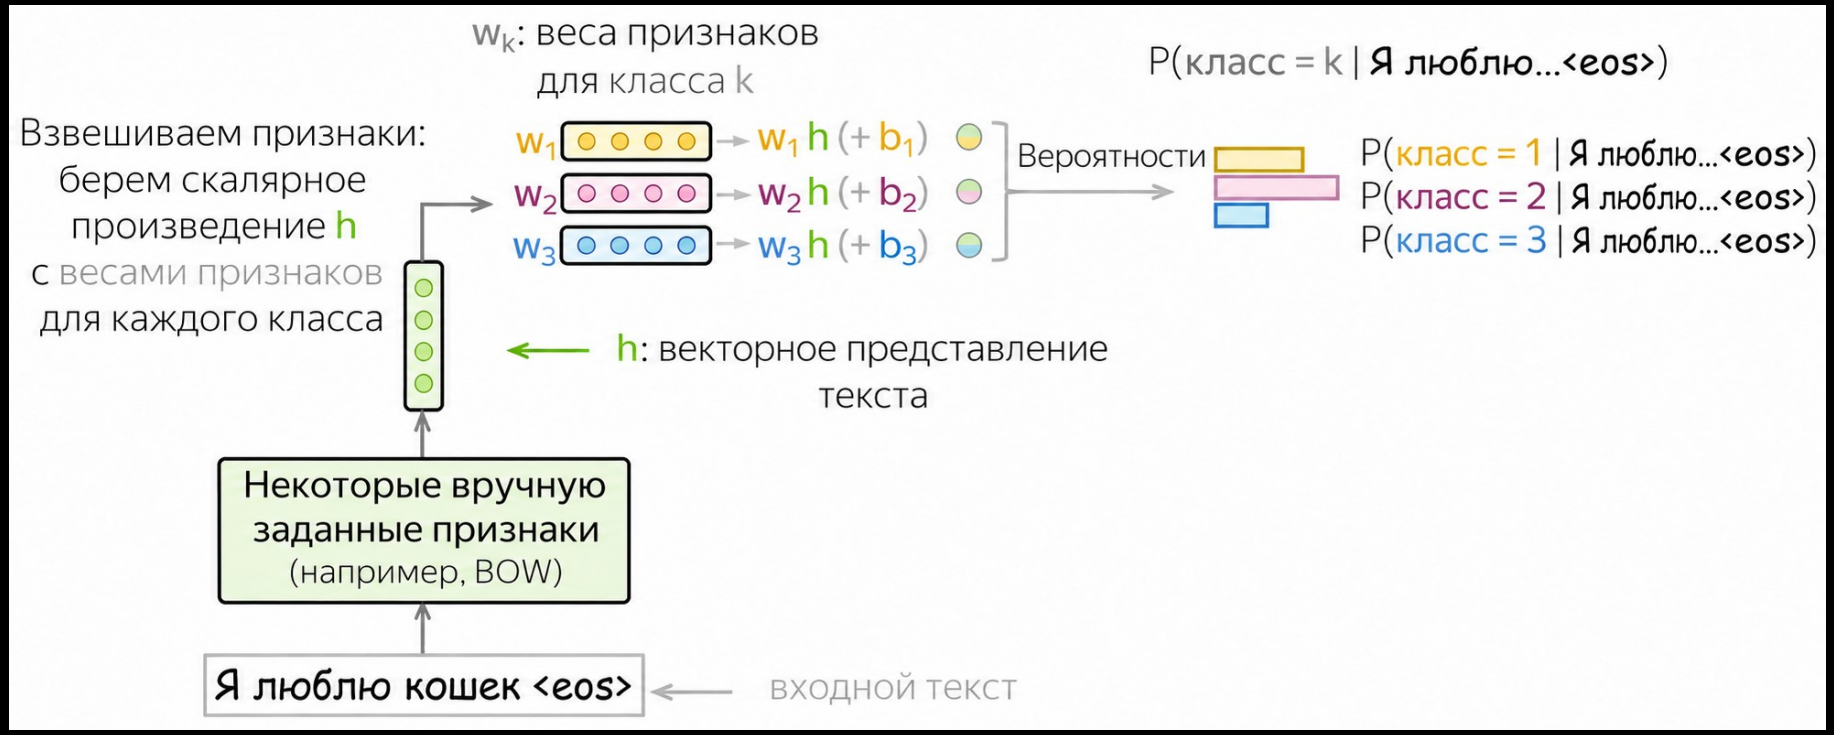
обнуляет вероятность слова $\Longrightarrow$ обнуляет вероятность документа $\Longrightarrow$ Плохо!

$$N(x_i, y = k) = 0 \Rightarrow P(x_i|y = k) = \frac{N(x_i, y = k)}{\sum_{t=1}^{|V|} N(x_t, y = k)} = 0 \Longrightarrow P(x|y = k) = \prod_{i=1}^{n} P(x_i|y = k) = 0$$

В обучающей выборке не встречалось слово x_i в документах класса k

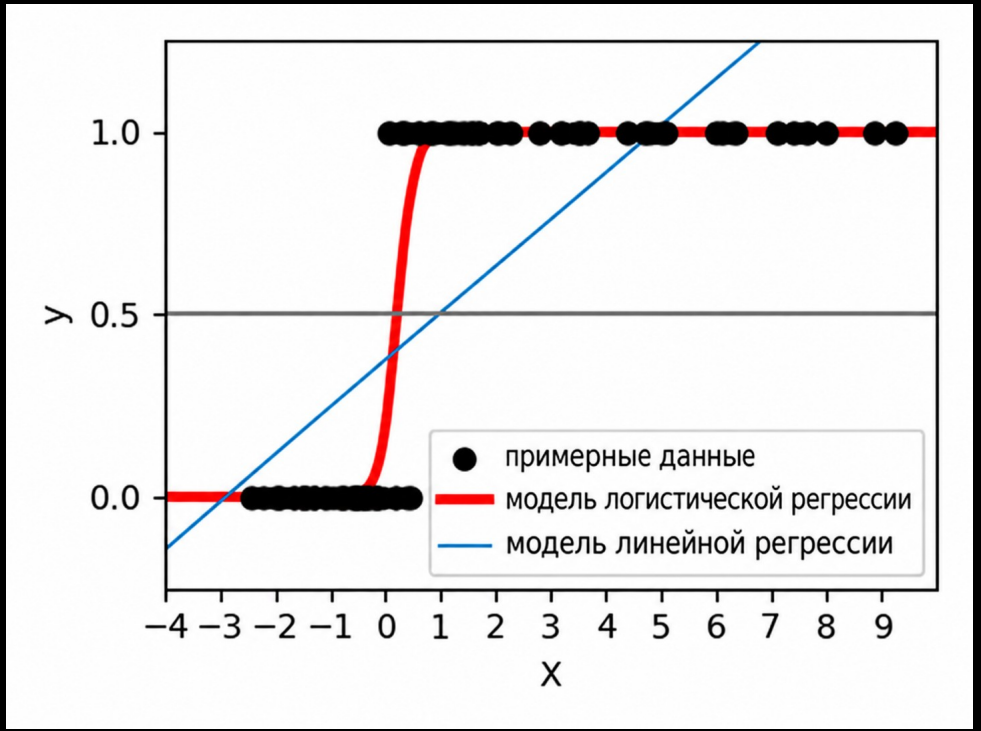
- Не встречавшееся в обучении слово не должно автоматически обнулять вероятность класса.
- Сглаживание добавляет небольшой запас к оценке частот.
- Силу сглаживания выбирают на проверочной выборке.

Логистическая регрессия



- Каждый признак получает вес для оценки принадлежности текста к классу.
- Линейные оценки преобразуются в вероятности классов.
- Регуляризация ограничивает сложность и помогает работать с большим числом признаков.

Сигмоида и порог решения



- Сигмоида преобразует линейную оценку в число от нуля до единицы.
- Порог определяет, когда модель выдаёт положительный класс.
- Порог выбирают с учётом цены ошибок и проверяют на независимых данных.

Сравнение классических методов

- Простые модели помогают быстро оценить качество данных и признаков.

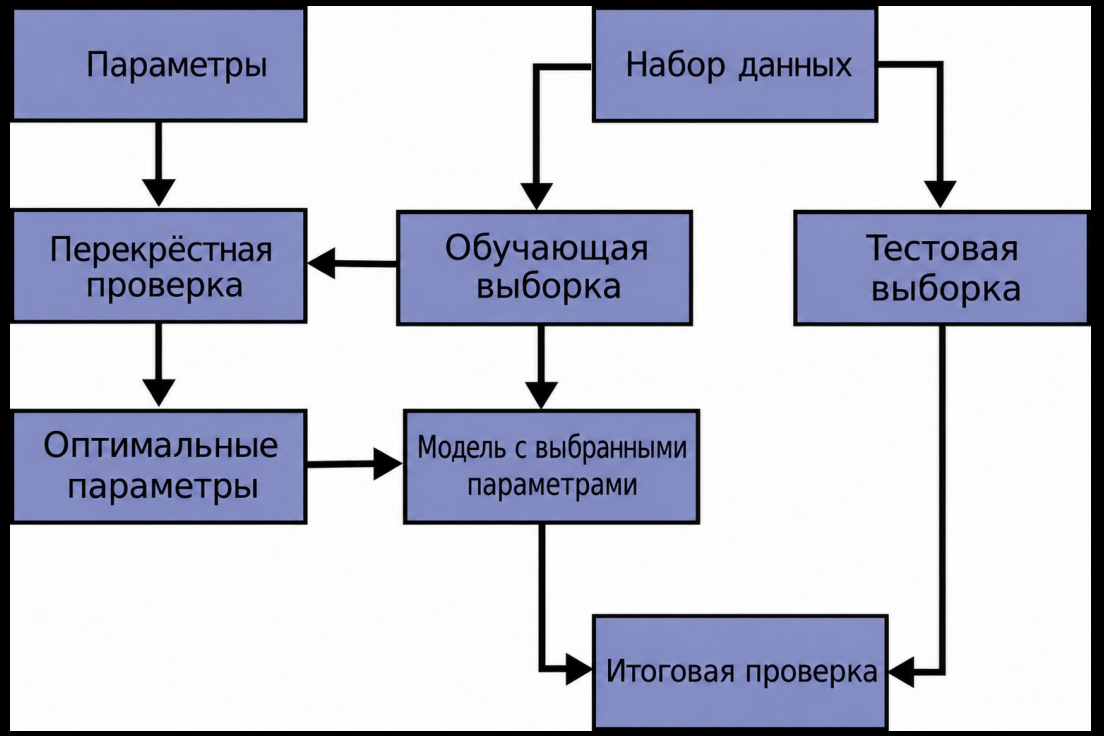
Метод	Принцип	Практическая роль
Наивный байесовский метод	Частоты и условная независимость	Быстрое решение на основе частот
Логистическая регрессия	Линейные оценки и вероятности классов	Исходное решение с TF-IDF
Линейный метод опорных векторов	Разделяющая граница с зазором	Метод для разреженных признаков

- Сравнение проводят на одинаковом разделении данных и по одинаковым метрикам.
- Выбор метода зависит от требований к качеству, скорости и интерпретации.

Последовательность классификации

- Сначала выделяют обучающие, проверочные и тестовые данные.
- Преобразование текста в признаки настраивают только по обучающей части.
- После обучения классификатора выбирают настройки по проверочной выборке.
- Итоговое качество оценивают на тесте, сохраняя весь порядок обработки для новых текстов.

Перекрёстная проверка

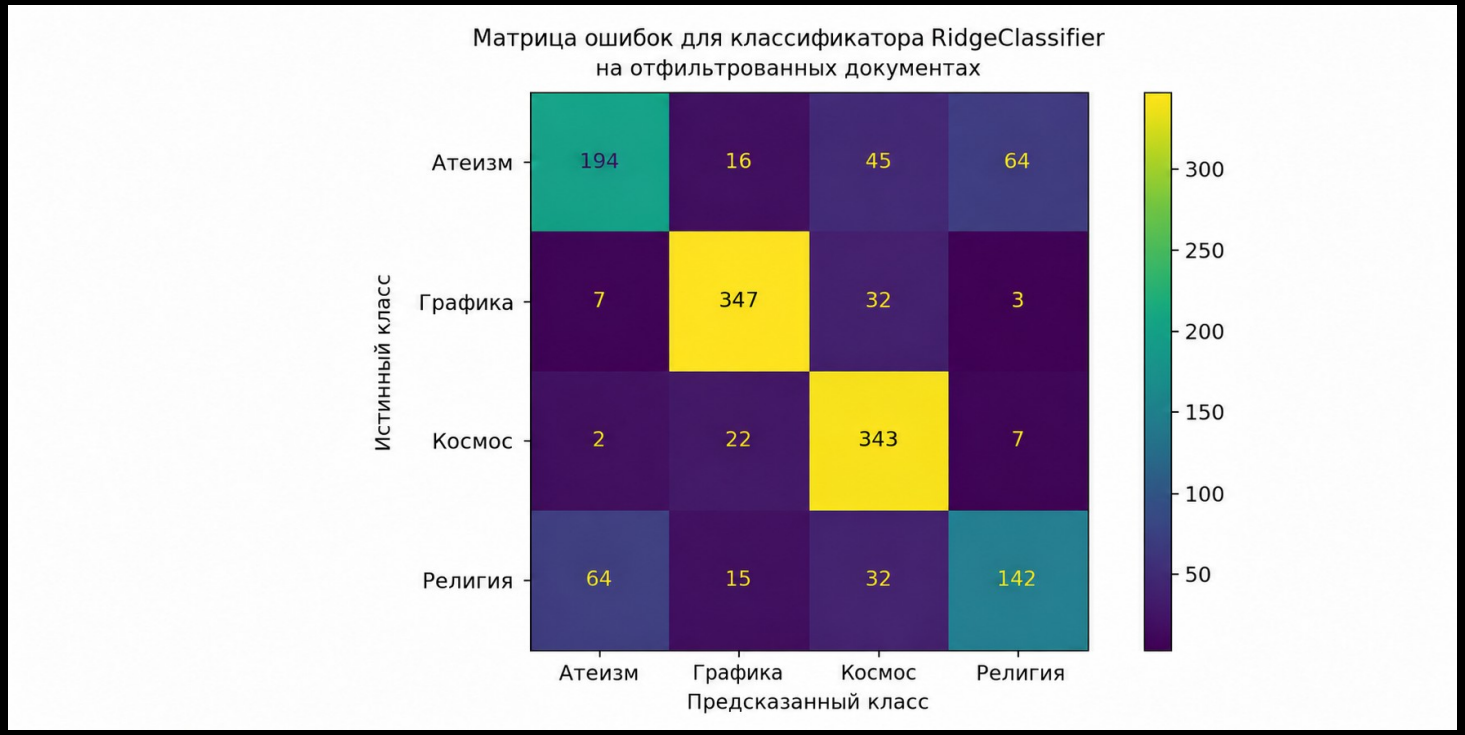


- Данные несколько раз разделяют на обучающую и проверочную части.
- В каждом разбиении заново настраивают все обучаемые этапы обработки.
- Настройки сравнивают по результатам нескольких разбиений с учётом разброса качества.

Утечка данных

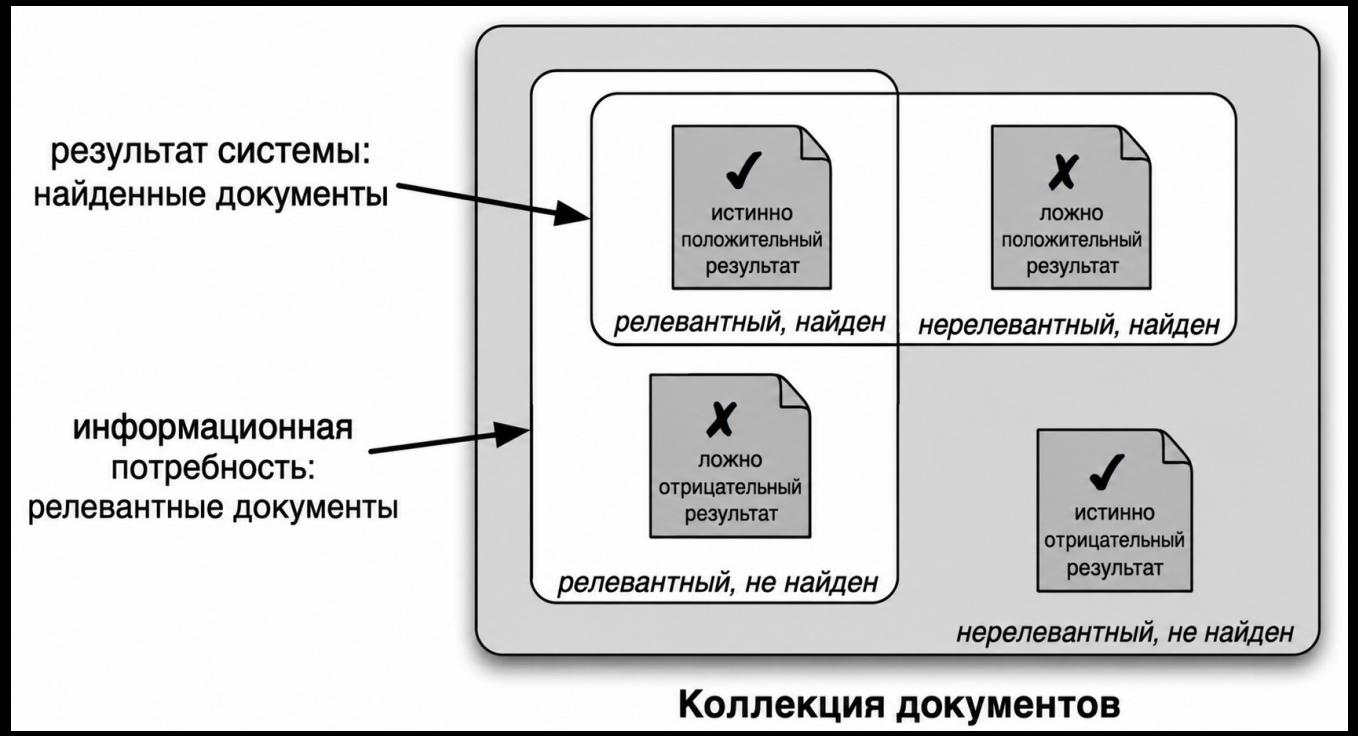
- Утечка возникает, когда при обучении используется информация, недоступная при реальном применении.
- Причиной могут стать дубликаты между частями выборки, будущие события или признаки из целевой метки.
- Даже словарь и веса слов нельзя настраивать по тестовой выборке.
- Высокая оценка при утечке не отражает способность работать на новых данных.

Матрица ошибок



- Строки соответствуют истинным классам, столбцы — предсказанным.
- Диагональ показывает правильные ответы, остальные ячейки — виды ошибок.
- Матрица помогает понять, какие классы модель путает чаще всего.

Точность и полнота



- Точность: какая доля найденных объектов действительно относится к нужному классу.
- Полнота: какую долю всех объектов нужного класса удалось найти.
- Их баланс зависит от порога решения и стоимости разных ошибок.

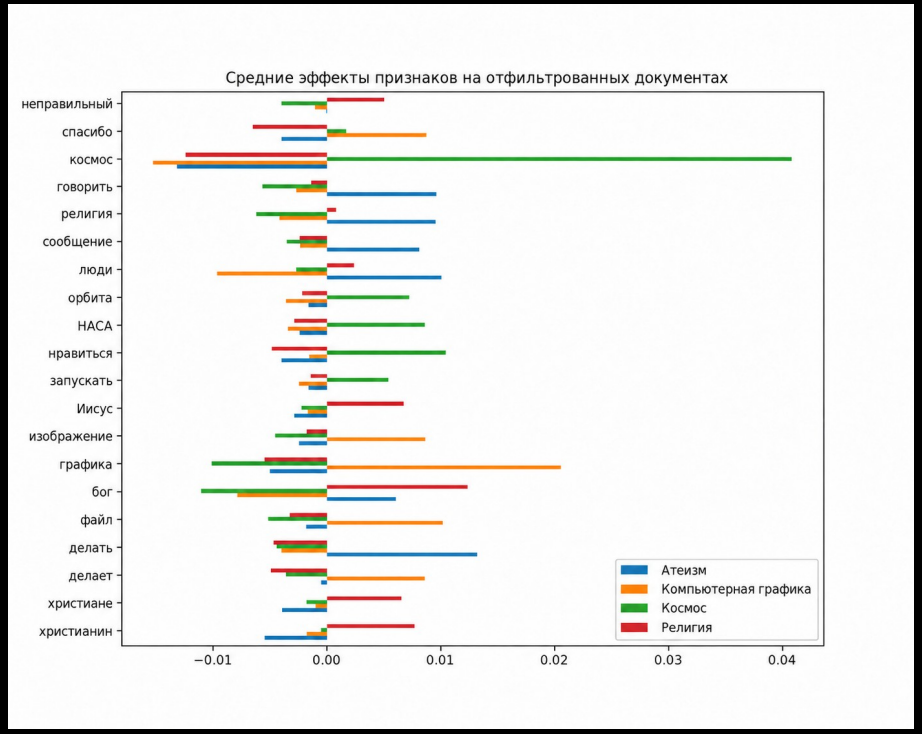
Дисбаланс классов

- Модель, всегда выбирающая частый класс, может иметь высокую общую долю верных ответов.

Истинный класс	Предсказано: нейтральный	Предсказано: жалоба
Нейтральный	90	0
Жалоба	10	0

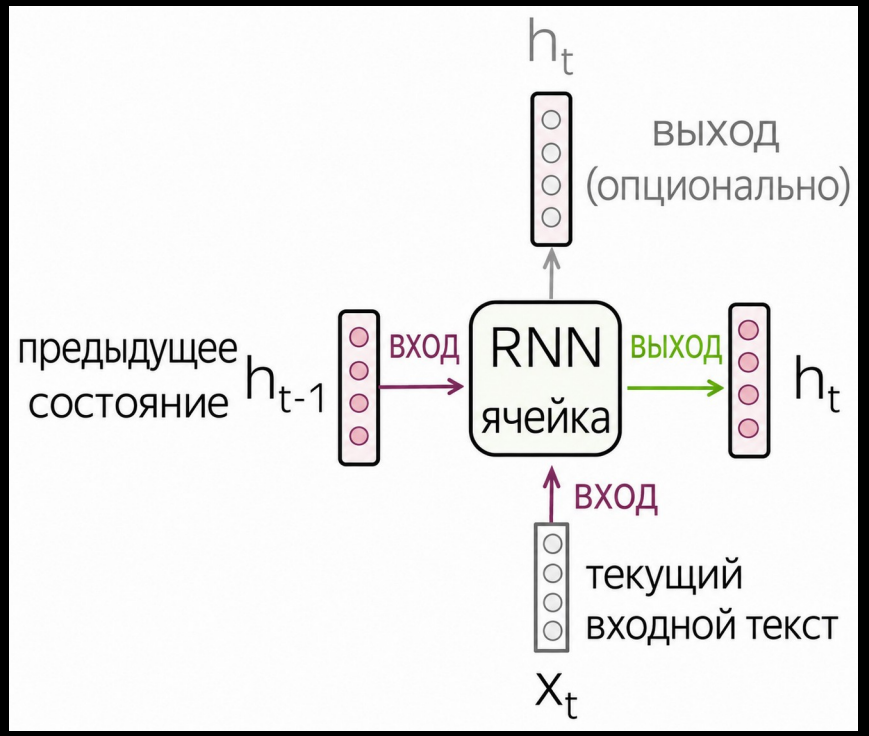
- В примере верны 90% ответов, но ни одна жалоба не обнаружена.
- Среднее F1 по классам ≈ 0,474: каждый класс получает одинаковый вес.

Анализ и интерпретация



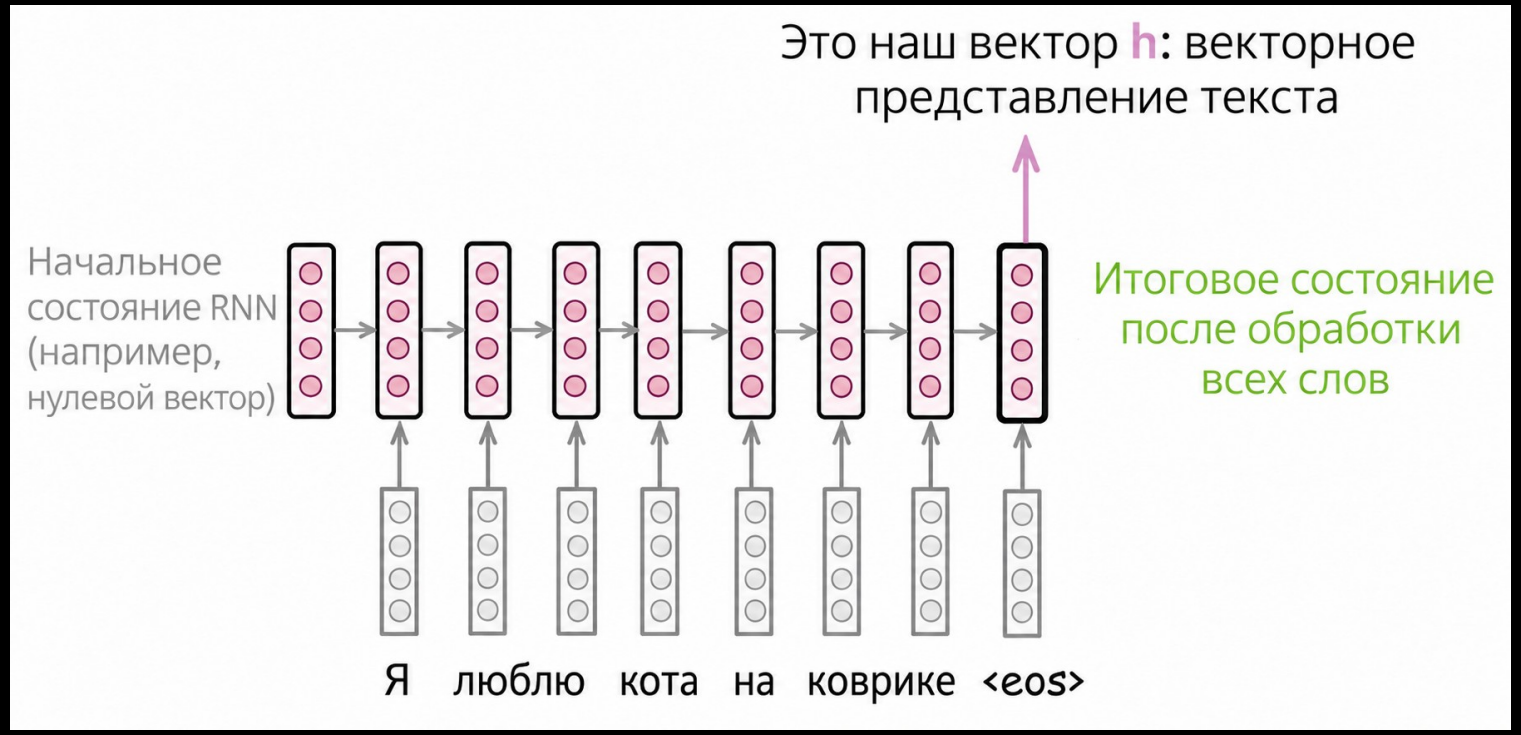
- В линейной модели веса показывают вклад отдельных признаков в оценку класса.
- Необычные признаки помогают обнаружить ошибки данных и нежелательные зависимости.
- Для выводов полезно совместно изучать веса, тексты и конкретные ошибки.

Рекуррентные нейронные сети



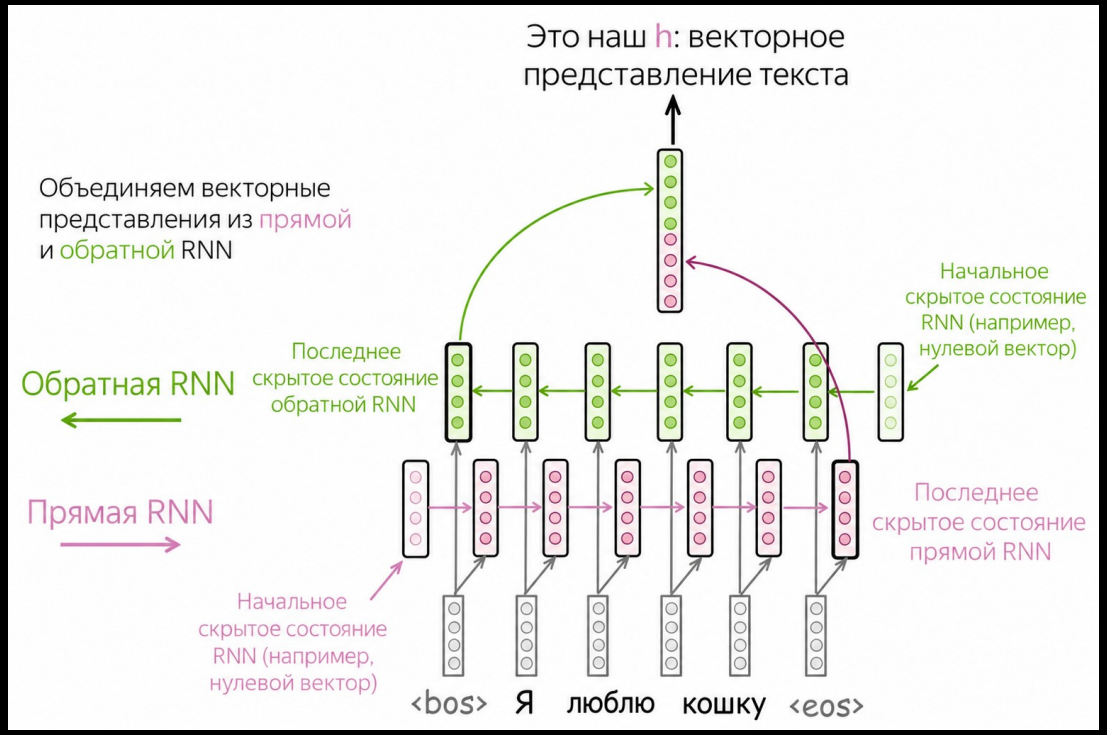
- Сеть последовательно обрабатывает элементы текста.
- Скрытое состояние передаёт информацию от предыдущих позиций к следующим.
- Общая функция обновления применяется на каждом шаге.

Классификация рекуррентной сетью



- Последовательная обработка формирует представление текста с учётом порядка слов.
- Для классификации используют итоговое состояние или объединение состояний.
- Способ объединения влияет на сохранение информации из разных частей текста.

Двунаправленная обработка



- Одна сеть читает последовательность слева направо, другая — справа налево.
- Представление позиции может учитывать контекст с обеих сторон.
- Для предсказания будущего текста правый контекст недоступен, и это ограничение важно соблюдать.

Дальние зависимости в тексте

- Для понимания слова иногда нужна информация из начала длинного предложения.
- В простой рекуррентной сети сигнал проходит через множество последовательных преобразований.
- Из-за этого обучение дальним зависимостям может быть нестабильным.
- Архитектурные изменения помогают, но не отменяют необходимости проверять работу на длинных текстах.

Сети с управляемой памятью

- LSTM вводит состояние памяти и механизмы, управляющие записью, сохранением и выдачей информации.
- GRU использует более компактную схему управления обновлением состояния.
- Обе архитектуры помогают обучать зависимости, которые сложно сохранять простой рекуррентной сети.
- Они остаются последовательными моделями и имеют ограничения по скорости обработки длинных текстов.

От рекуррентных сетей к вниманию

- Механизм внимания позволяет обращаться к разным позициям последовательности.
- Модель может выбирать информацию по её полезности для текущей задачи.
- Трансформер строит взаимодействие позиций через внимание и учитывает их порядок.
- Подробное устройство внимания и трансформеров рассматривается в следующем блоке курса.

Инструменты для обработки текста

- Для языковых правил и учебных примеров подходят NLTK и spaCy.
- Для векторизации, классификации и оценки качества используют scikit-learn.
- Gensim предоставляет методы работы с тематическими и векторными представлениями.
- Hugging Face и Sentence Transformers помогают применять готовые нейросетевые модели.

Библиотека для изучения языка

- NLTK содержит инструменты разбиения текста, усечения слов, языковые ресурсы и учебные корпуса.
- Набор независимых компонентов удобен для изучения отдельных этапов обработки.
- Для некоторых функций требуется отдельно загрузить данные и модели.
- Качество и доступность ресурсов различаются между языками.

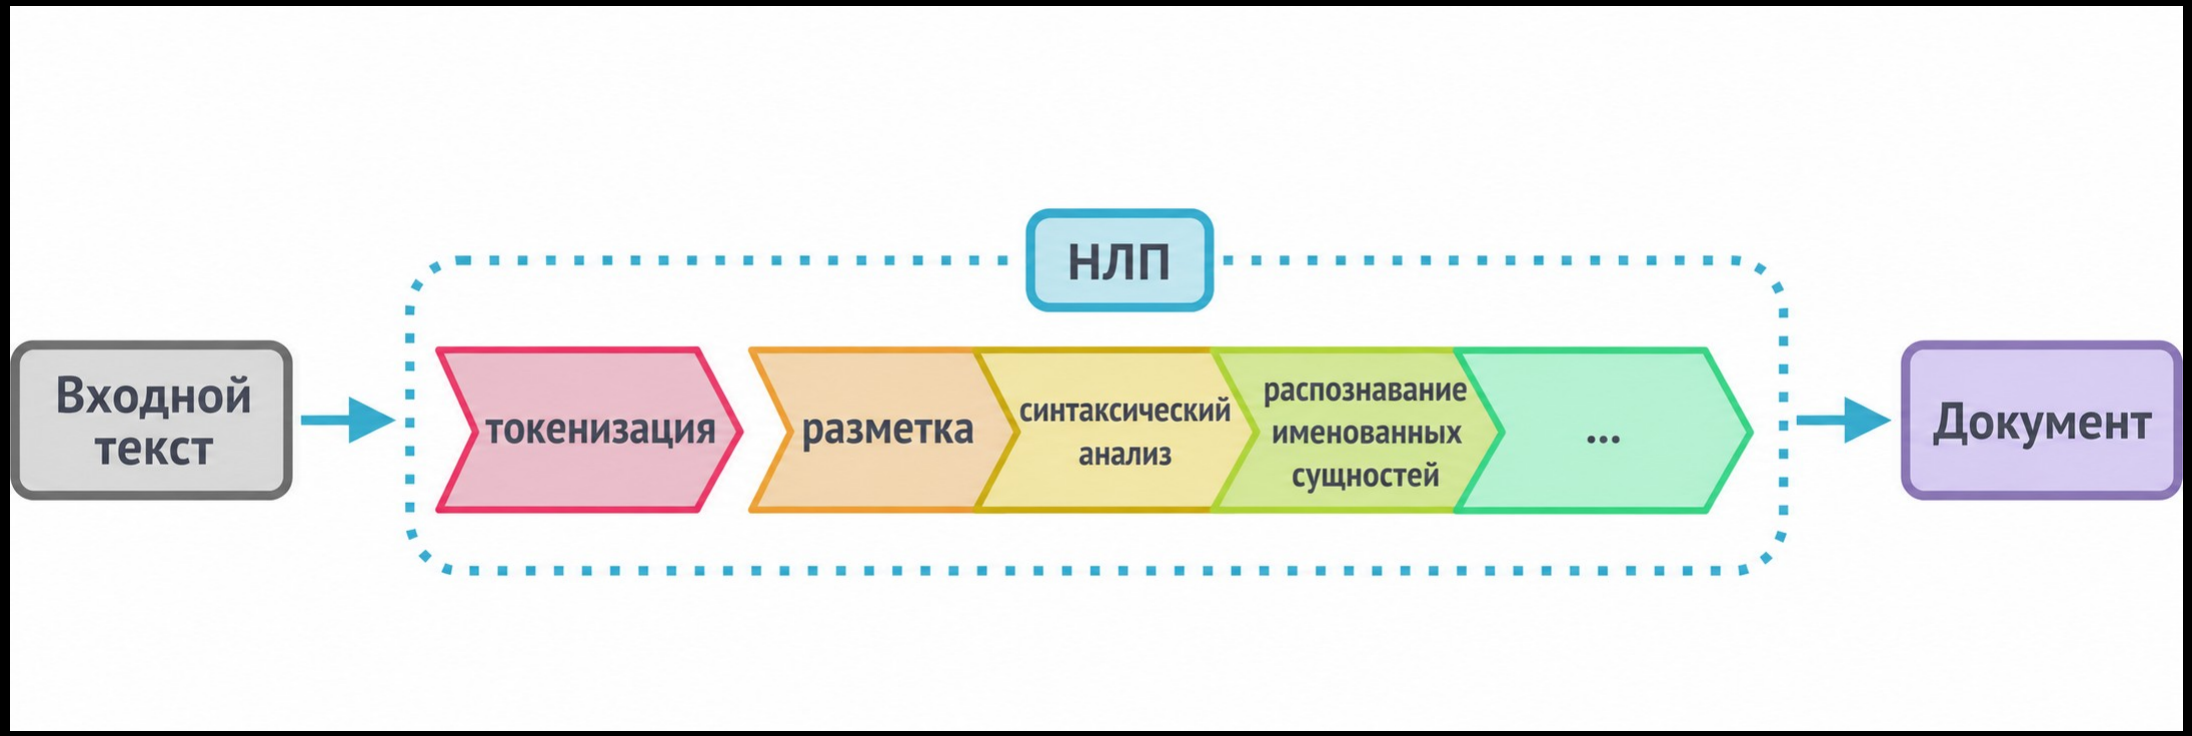
Учебные корпуса и словари

- Корпуса позволяют изучать распределение слов и проверять методы на реальных текстах.
- Лексические ресурсы описывают слова, значения и отношения между ними.
- Ресурс для одного языка нельзя автоматически считать подходящим для другого.
- Перед использованием проверяют состав, лицензию и правила разметки коллекции.

Документ, элемент и фрагмент текста

- В spaCy документ хранит исходный текст и последовательность элементов вместе с разметкой.
- Объект Token представляет отдельный элемент, объект Span — непрерывный фрагмент документа.
- Такое устройство сохраняет связь результатов анализа с исходным текстом.
- При обработке важно различать текстовую запись, начальную форму и предсказанные языковые признаки.

Последовательность языковой обработки



- В spaCy текст проходит разбиение и последовательность подключённых компонентов.
- Компоненты могут определять части речи, зависимости, сущности и начальные формы.
- Состав обработки выбирают под задачу, отключая ненужные этапы.

Языковые правила и обученные модели

- Языковые правила и обученные модели выполняют разные функции.
- Наличие правил разбиения не означает наличия качественной разметки всех языковых признаков.
- Для нужного языка загружают подходящий пакет и проверяют состав его компонентов.
- Скорость и точность зависят от размера модели, области данных и включённых этапов.

Библиотека классического машинного обучения

- В scikit-learn векторизаторы преобразуют тексты в частоты или веса слов.
- Объект Pipeline объединяет преобразования и классификатор в один порядок обработки.
- Это помогает правильно выполнять перекрёстную проверку и избегать утечки данных.
- Библиотека также предоставляет метрики, подбор параметров и инструменты анализа ошибок.

Векторные и тематические модели

- Gensim работает с корпусами, тематическими моделями и векторными представлениями.
- В библиотеке доступны Word2Vec, fastText и модели представления документов.
- Готовые векторы можно загрузить и использовать для поиска близких слов.
- Слова вне словаря и различия между обучающим корпусом и задачей требуют отдельного внимания.

Экосистема готовых моделей

- В экосистеме Hugging Face библиотека Transformers предоставляет готовые нейросетевые архитектуры и средства их применения.
- Datasets помогает загружать и преобразовывать наборы данных.
- Tokenizers реализует быстрые способы разбиения текста.
- Hub хранит модели, данные и описания условий их использования.

Векторы предложений

- Sentence Transformers получает числовые представления предложений и фрагментов текста.
- Близость векторов используют для поиска, группировки и сравнения формулировок.
- Модель выбирают с учётом языка, области данных и типа задачи.
- Размерность вектора сама по себе не определяет качество представления.

Контрольные вопросы

- Чем классификация текста отличается от разметки отдельных элементов последовательности?
- Как удаление короткого слова может изменить смысл и ухудшить качество?
- Почему словарь и веса слов нужно настраивать только на обучающей части?
- Какая метрика поможет заметить, что модель не находит редкий класс?

Итоги и подготовка к семинару

- Умеем формулировать задачу обработки текста и определять ожидаемый ответ.
- Понимаем роль данных, разметки, разбиения выборки и предварительной обработки.
- Можем объяснить словарные признаки, классическую классификацию и основные метрики.
- На семинаре сравним взвешенные частоты слов и готовые векторы предложений на одной задаче.

Материалы и источники

Курс ШАД по обработке текста

NLTK и spaCy: обработка языка

scikit-learn: признаки и классификация

Векторы слов и предложений