# Векторные представления текста

Представления слов, предложений и документов
Перенос обучения, смысловой поиск и ответы по документам

Алан-Барсаг Газзаев

24 октября 2026 · Лекция 2

# Содержание второй лекции

- Разберём, как слова и документы превращаются в числовые векторы.
- Сравним частотные методы, обучаемые векторы слов и модели с учётом контекста.
- Рассмотрим перенос готовых представлений на новые задачи.
- Обсудим смысловой поиск, повторное ранжирование и генерацию ответов по найденным документам.

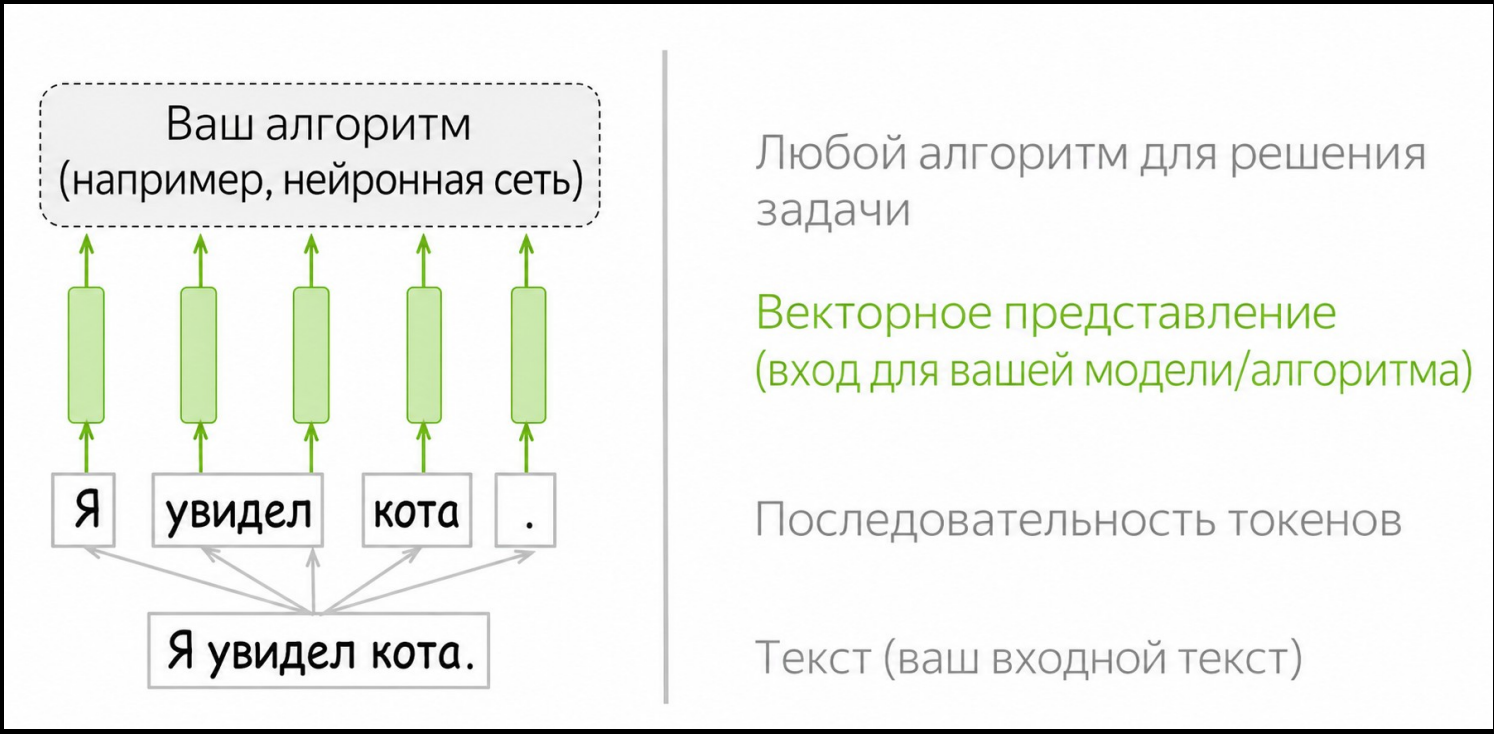
# Уровни представления текста

- Вектор может описывать слово, отдельное употребление, предложение или целый документ.

| Объект | Что описывает вектор | Пример применения |
|---|---|---|
| Элемент / слово | Элемент или его употребление | Разметка последовательности |
| Предложение / фрагмент | Предложение или фрагмент | Смысловой поиск |
| Документ | Документ целиком | Классификация, группировка |

- Выбор единицы зависит от того, какой ответ должна выдавать система.
- Способ получения вектора должен сохранять информацию, нужную для задачи.

# Представления в системе обработки текста




- Исходный текст разбивают на элементы и переводят в числовую форму.
- Модель использует эти представления для решения прикладной задачи.
- Значение отдельных координат может быть неочевидным: важна совместная структура вектора.

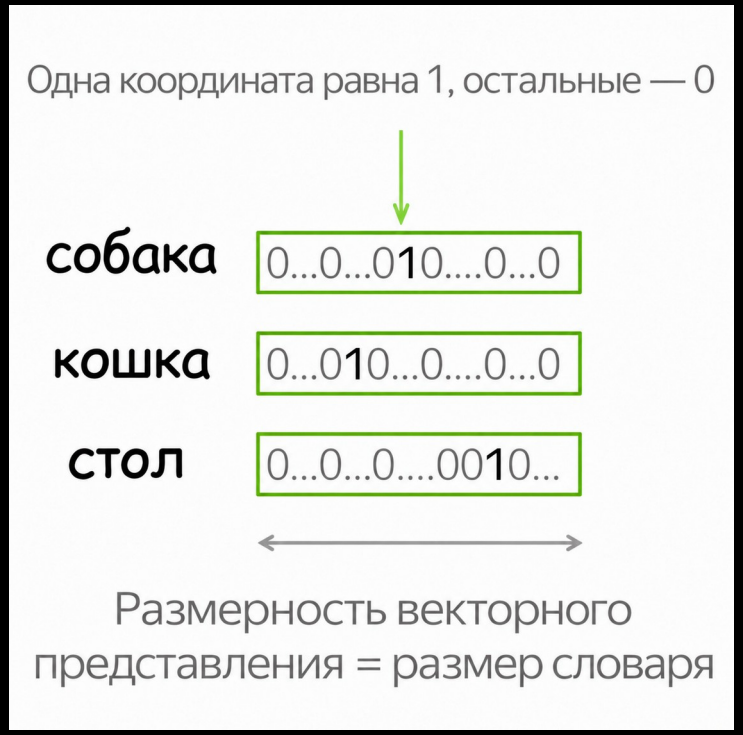
# Разреженные и плотные векторы

- В словарных представлениях координаты часто соответствуют конкретным словам.

| Свойство | Разреженное представление | Плотное представление |
|---|---|---|
| Координаты | Часто соответствуют словам | Обычно обучаются совместно |
| Нулевые значения | Преобладают у коротких текстов | Обычно не преобладают |
| Пример | Частоты, TF-IDF | Векторы слов и предложений |

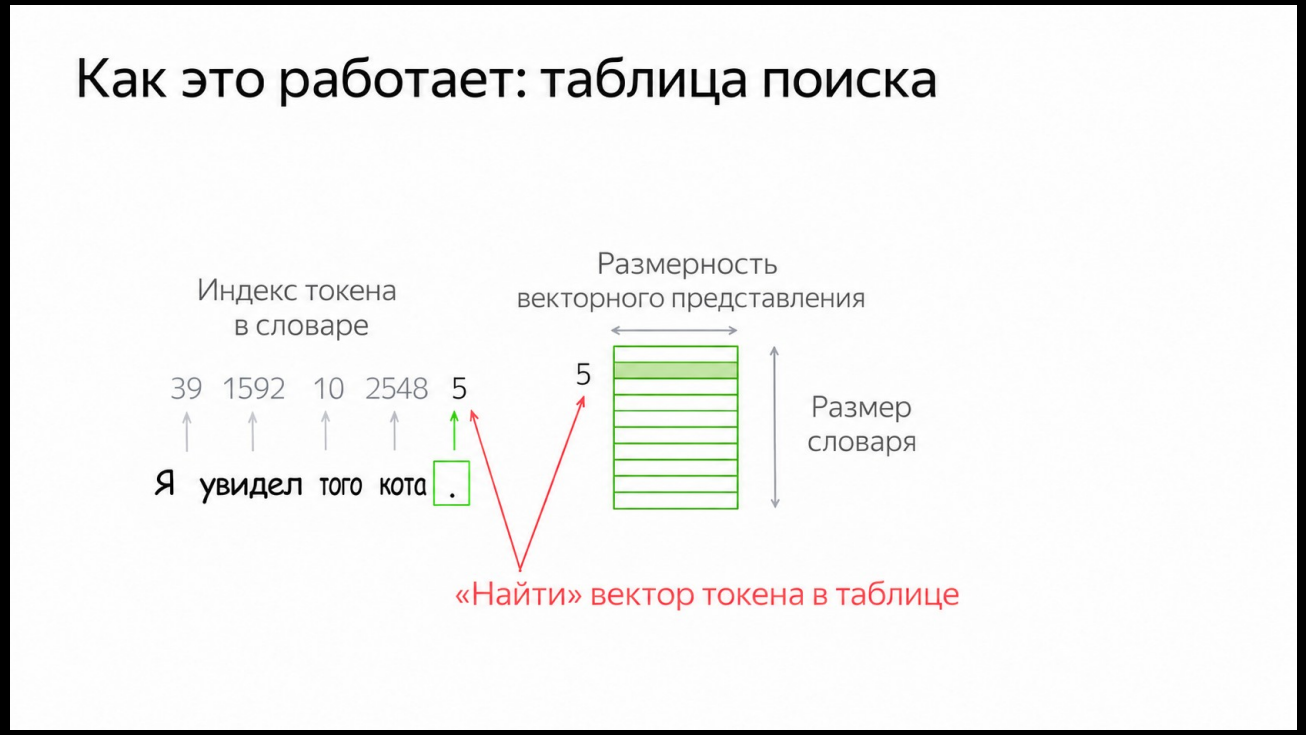
- У обучаемого плотного вектора признаки обычно распределены между несколькими координатами.
- Размерность и доля нулей влияют на хранение данных, но не определяют качество сами по себе.

# Кодирование одной единицей




- Каждому слову соответствует своя позиция в словаре.
- В этой позиции стоит единица, во всех остальных — нули.
- Такое кодирование различает слова, но само по себе не выражает близость их значений.

# Таблица векторов слов




- Идентификатор слова выбирает строку таблицы представлений.
- Число строк связано с размером словаря, число столбцов — с размерностью вектора.
- Словарь и таблица должны использовать одно и то же соответствие слов и индексов.

# Гипотеза о сходстве контекстов

- Слова, встречающиеся в похожем окружении, часто имеют связанные значения.
- По распределению контекстов можно обучать представления без ручной разметки каждого слова.
- Сходство окружений не гарантирует взаимозаменяемость: антонимы тоже бывают близкими.
- Полученное представление отражает закономерности конкретного обучающего корпуса.

# Значение слова и его окружение

(1) Бутылка _____ стоит на столе.

(2) Всем нравится _____ .

(3) От _____ можно опьянеть.

(4) Мы делаем _____ из кукурузы.

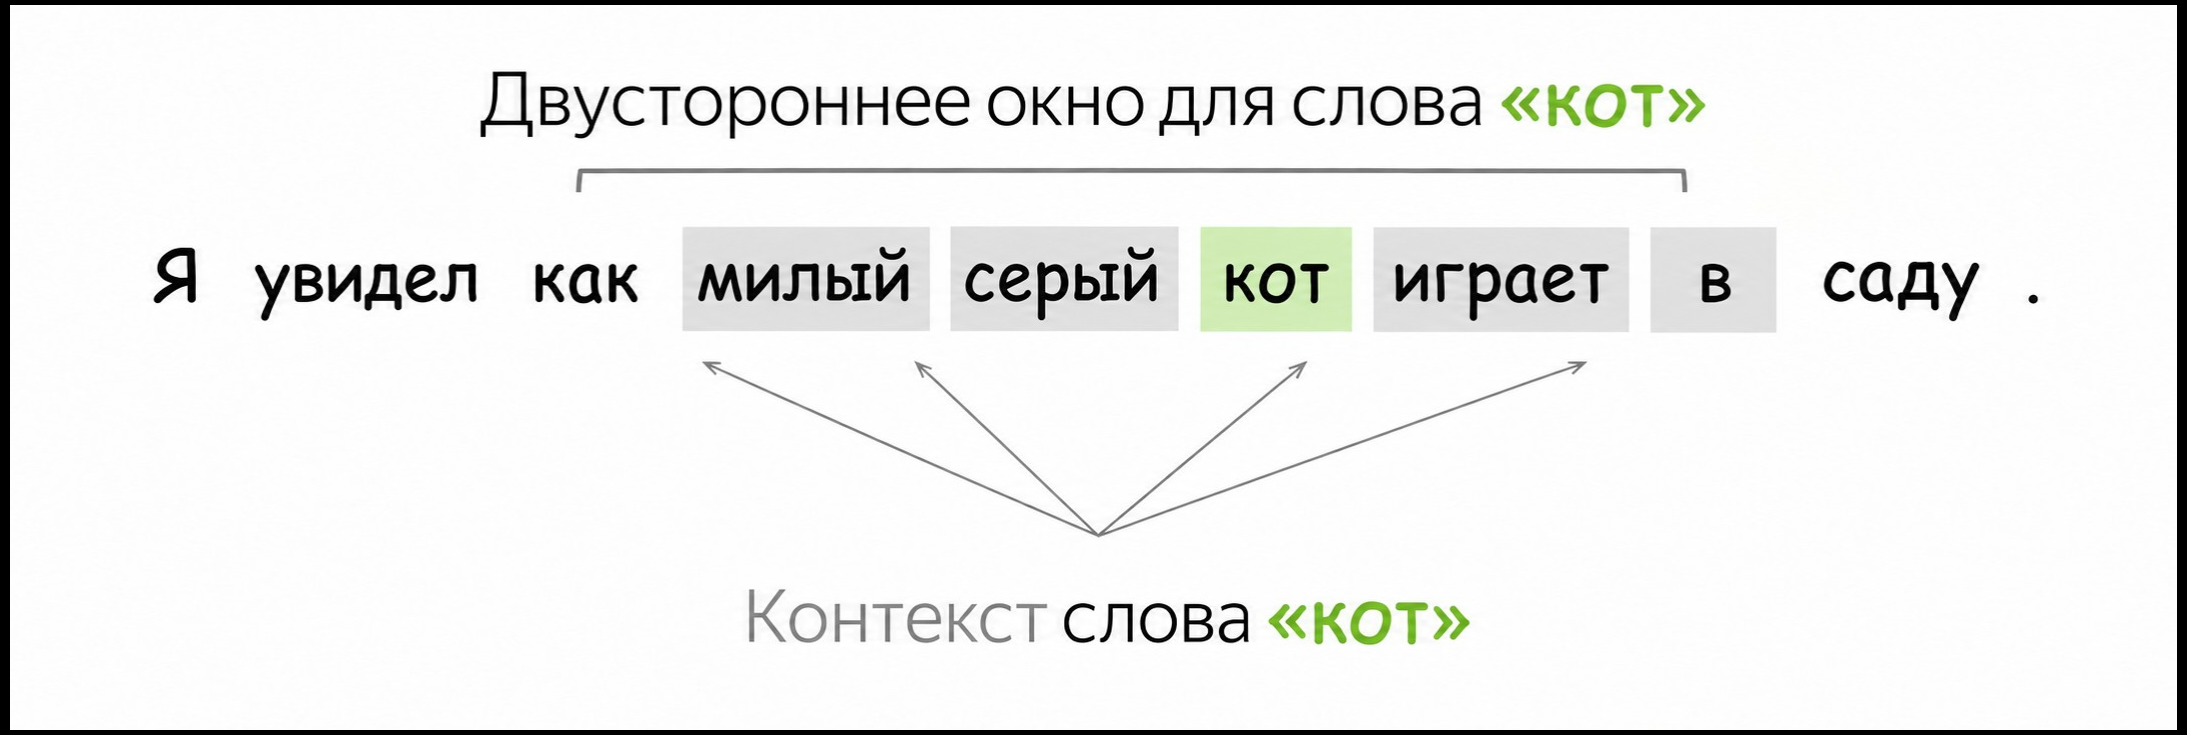
| | (1) | (2) | (3) | (4) | … |
|---|---|---|---|---|---|
| тесгуино | 1 | 1 | 1 | 1 | |
| громкий | 0 | 0 | 0 | 0 | |
| моторное масло | 1 | 0 | 0 | 1 | |
| лепёшки | 0 | 1 | 0 | 1 | |
| вино | 1 | 1 | 1 | 0 | |

Это **дистрибутивная гипотеза**

строки похожи → значения слов похожи

- Даже незнакомое слово можно частично понять по соседним словам и ситуациям употребления.
- Сходные наборы контекстов дают основание считать слова связанными.
- Качество такого вывода зависит от количества и разнообразия наблюдений.

# Контекстное окно




- Контекстное окно ограничивает число соседних позиций вокруг выбранного слова.
- В двустороннем окне учитывают слова слева и справа.
- Размер окна меняет набор наблюдаемых связей между словами.

# Выбор контекста

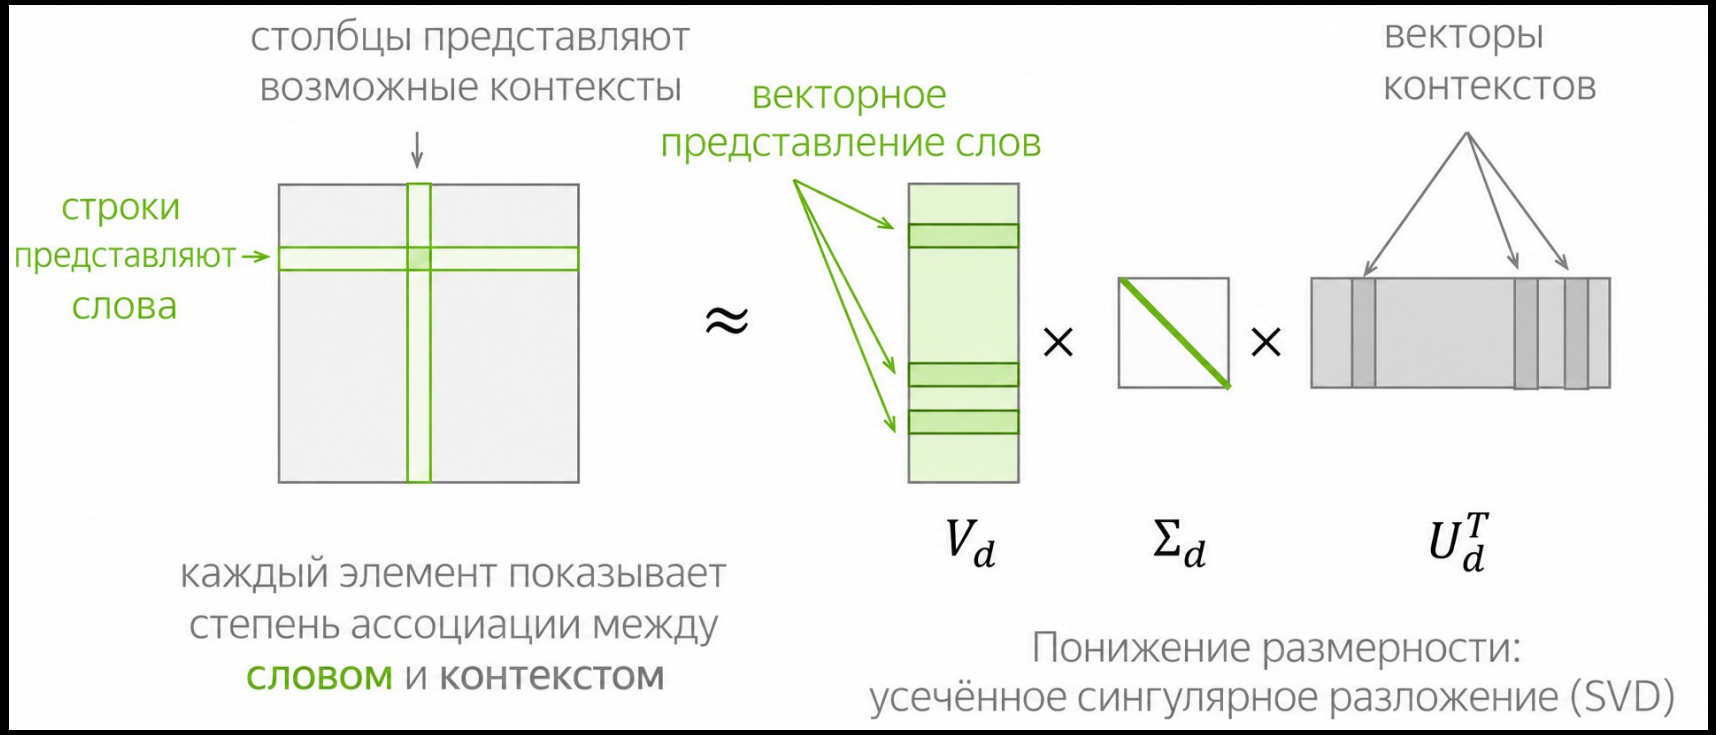
- Небольшое окно чаще выделяет локальные грамматические и устойчивые смысловые связи.
- Широкое окно сильнее отражает тему документа или фрагмента.
- Можно учитывать расстояние до слова, направление и структуру предложения.
- Выбор контекста проверяют на целевой задаче, поскольку универсального размера окна нет.

# Матрица совместной встречаемости




- Для каждой пары слов подсчитывают, как часто они встречаются в выбранном контексте.
- Строка такой матрицы описывает окружения одного слова.
- Окно и правила подсчёта определяют, какие отношения попадут в представление.

# Представления на основе частот




- Матрицу наблюдаемых частот можно преобразовать в более компактные векторы.
- Снижение размерности сохраняет часть общих закономерностей совместной встречаемости.
- Полученные представления зависят от определения контекста и преобразования исходных частот.

# Снижение размерности

- Большая матрица может содержать избыточные и слабо наблюдаемые признаки.
- Снижение размерности ищет более компактное описание её структуры.
- Часть информации при этом теряется, поэтому размер представления нужно проверять.
- Компактность полезна для хранения и вычислений, но не гарантирует улучшения качества.

# Частотные признаки как отправная точка

- TF-IDF описывает документ через веса слов из обучающего словаря.
- Метод прост, интерпретируем и часто сохраняет важные точные совпадения.
- Обучаемые векторы могут связывать разные формулировки, но иногда теряют значимые детали.
- Сравнение проводят на одинаковых данных, метках и правилах оценки.

# Векторы слов и документов

- Строки разных матриц могут соответствовать разным объектам.

| Представление | Один объект | Содержание координат |
|---|---|---|
| Слово и его окружения | Слово | Его окружения в корпусе |
| Документ с весами TF-IDF | Документ | Вес каждого термина |
| Вектор предложения | Предложение | Обучаемые общие признаки |

- Вектор слова описывает его окружения; вектор документа может описывать состав всего текста.
- Перед сравнением важно определить смысл строки, координат и меры близости.

# Пространство векторов

- Каждый объект представлен точкой в многомерном пространстве.
- Обучение определяет, какие объекты и отношения оказываются близкими.
- Отдельная координата обычно не имеет простого словесного толкования.
- Сравнивать векторы корректно только в совместимом пространстве представлений.

# Косинусная близость

- Косинусная близость измеряет сходство направлений двух ненулевых векторов.
- Она равна скалярному произведению, делённому на произведение длин векторов.
- Для нормированных векторов достаточно вычислить скалярное произведение.
- Высокая близость означает сходство по критерию модели, а не обязательную истинность или эквивалентность текстов.

# Ближайшие соседи

Ближайшие слова к «лягушка»:

лягушки
жаба
литория
leptodactylidae
лягушка
ящерица
eleutherodactylus







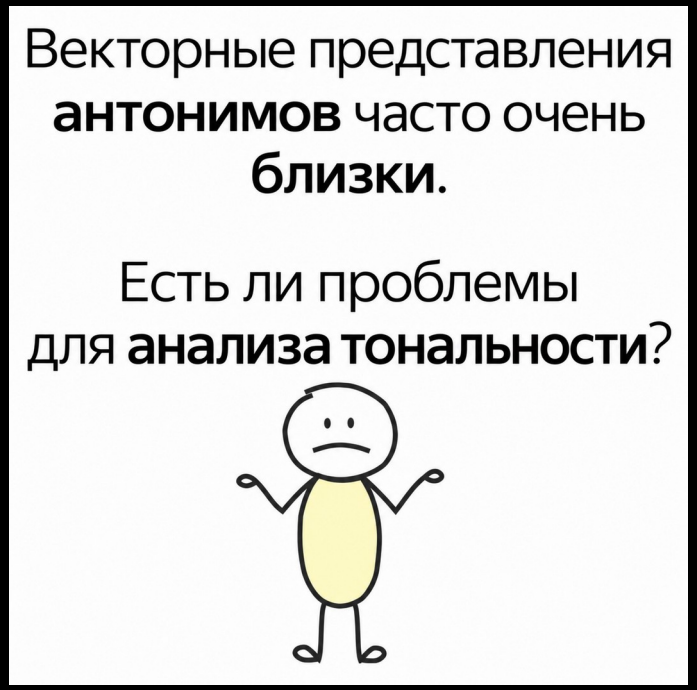






- По вектору слова можно найти слова с наиболее близкими представлениями.
- Соседи показывают, какие связи отражает обучающий корпус.
- Для объяснения результата полезно смотреть не только на список слов, но и на их контексты.

# Сходство и смысловая связь



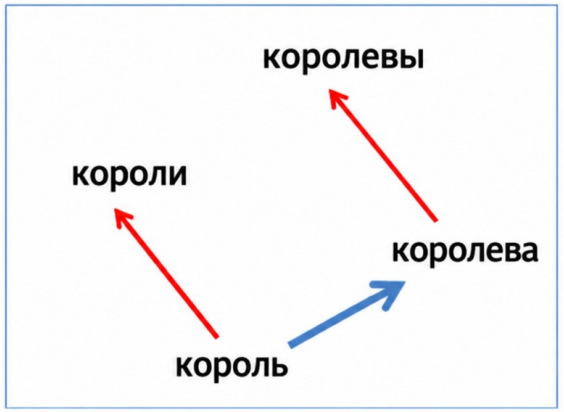

- Два слова могут быть связаны темой, но не иметь одинакового значения.
- Антонимы часто встречаются в похожих контекстах и могут получить близкие векторы.
- Поэтому близость векторов нельзя автоматически считать одинаковой оценкой или взаимозаменяемостью.

# Аналогии между словами

Смысловые отношения: v(**король**) – v(**мужчина**) + v(**женщина**) ≈ v(**королева**)

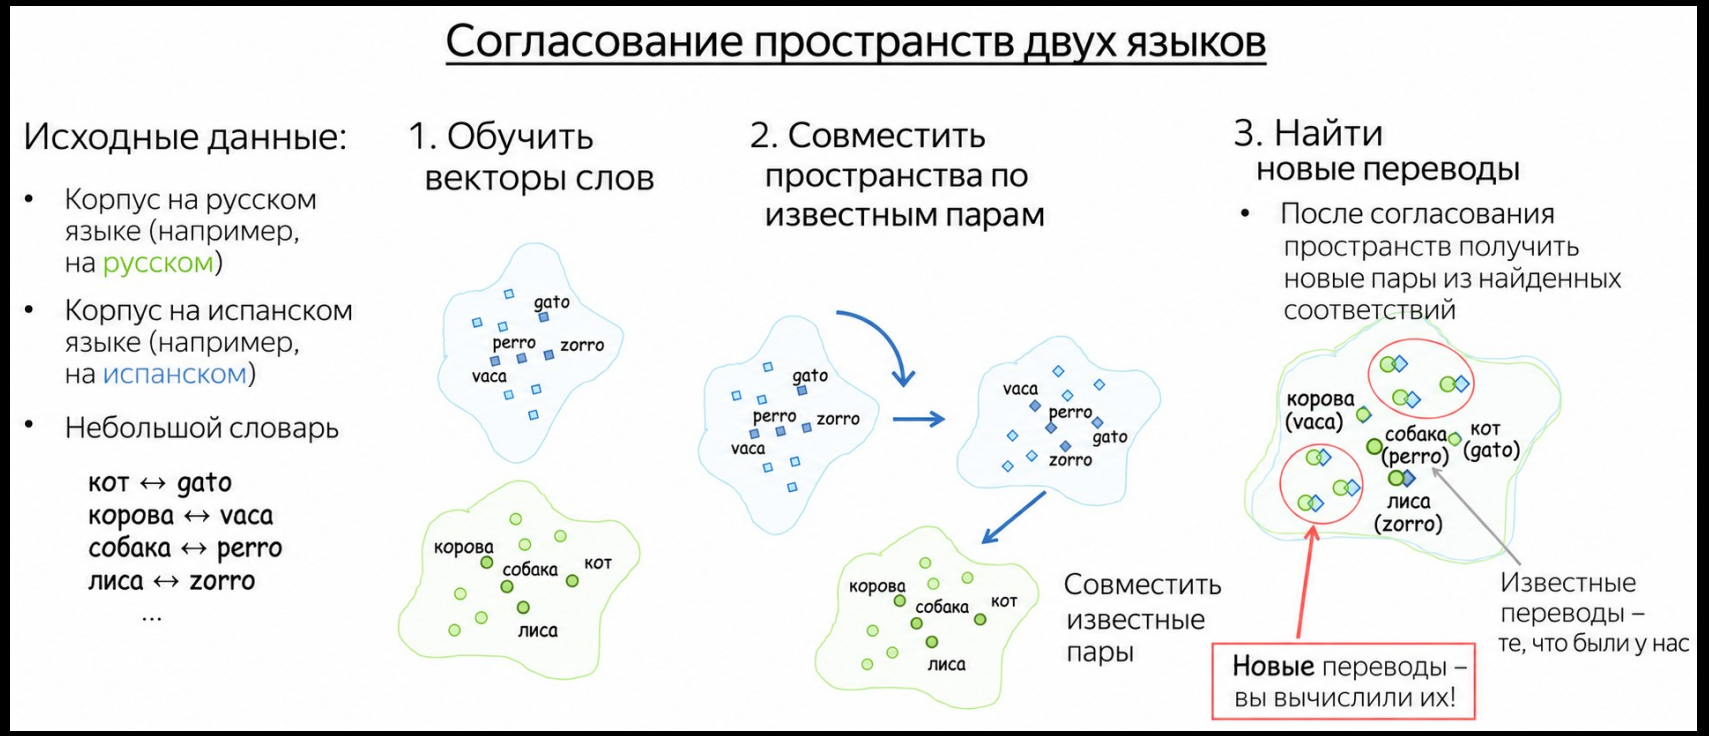
Грамматические отношения: v(**короли**) – v(**король**) + v(**королева**) ≈ v(**королевы**)




- Некоторые отношения проявляются как похожие направления между векторами.
- Классический пример связывает пары «мужчина — женщина» и «король — королева».
- Это полезное наблюдение для анализа, но не универсальное правило и не доказательство понимания языка.

# Представления разных языков




- Независимо обученные пространства могут иметь похожие отношения и разные координаты.
- Известные пары переводов помогают согласовать эти пространства.
- После согласования можно искать новые соответствия между словами разных языков.

# Ограничения векторного пространства

- Частые значения слова могут преобладать над редкими.
- Корпус передаёт модели неполноту данных, стереотипы и смещения.
- Представления из разных моделей нельзя смешивать только потому, что у них одинаковая размерность.
- Полезность пространства проверяют на реальной задаче и характерных ошибках.

# Обучение векторов по соседним словам

- Семейство Word2Vec учится по наблюдаемым соседствам слов.
- Обучающая задача связывает выбранное слово с его окружением.
- Векторы являются параметрами модели и меняются в ходе обучения.
- После обучения их используют как готовые признаки или как начальные параметры другой модели.

# Предсказание окружения слова




- В варианте Skip-gram модель получает центральное слово.
- По нему она учится предсказывать слова из соседних позиций.
- Из одного контекстного окна можно получить несколько обучающих пар.

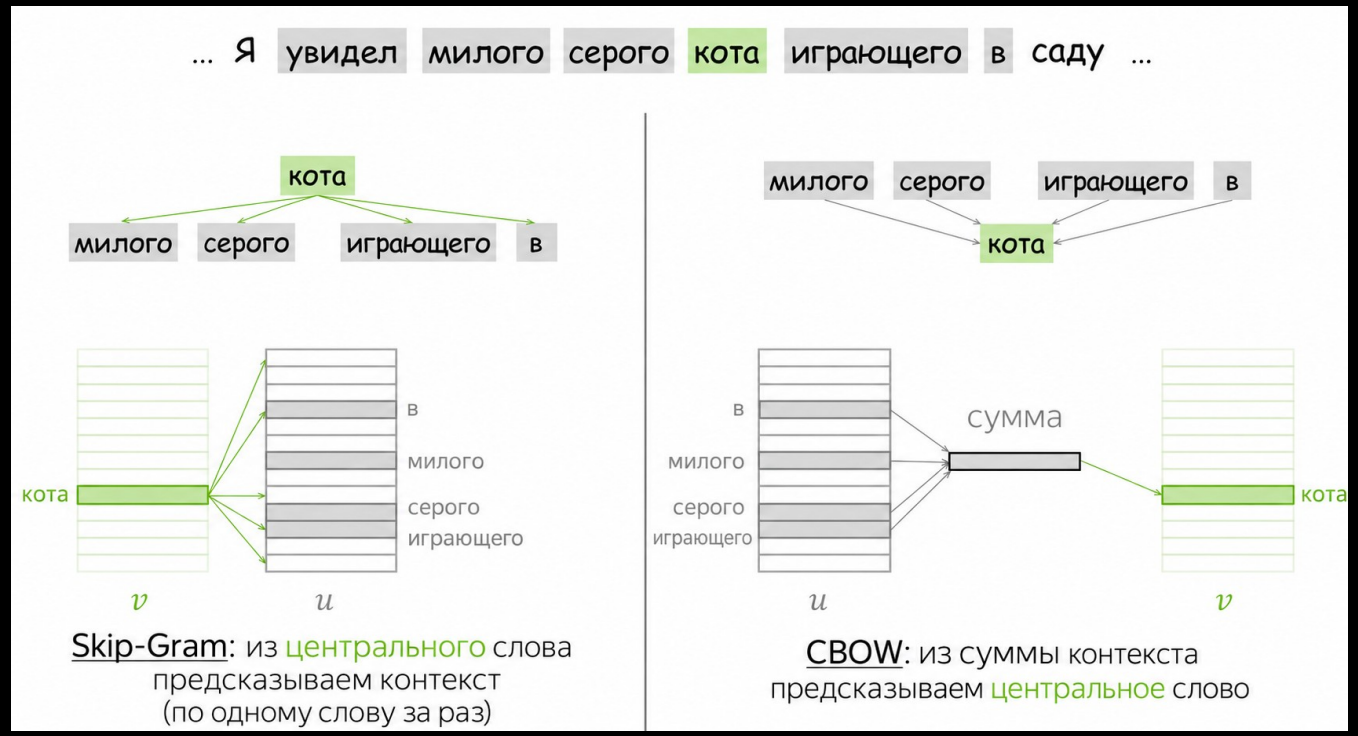
# Обучающие пары

- Пара связывает выбранное слово и одного из его соседей.

| Выбранное слово | Соседнее слово | Наблюдение |
|---|---|---|
| читает | студент | Сосед слева |
| читает | полезную | Сосед справа |

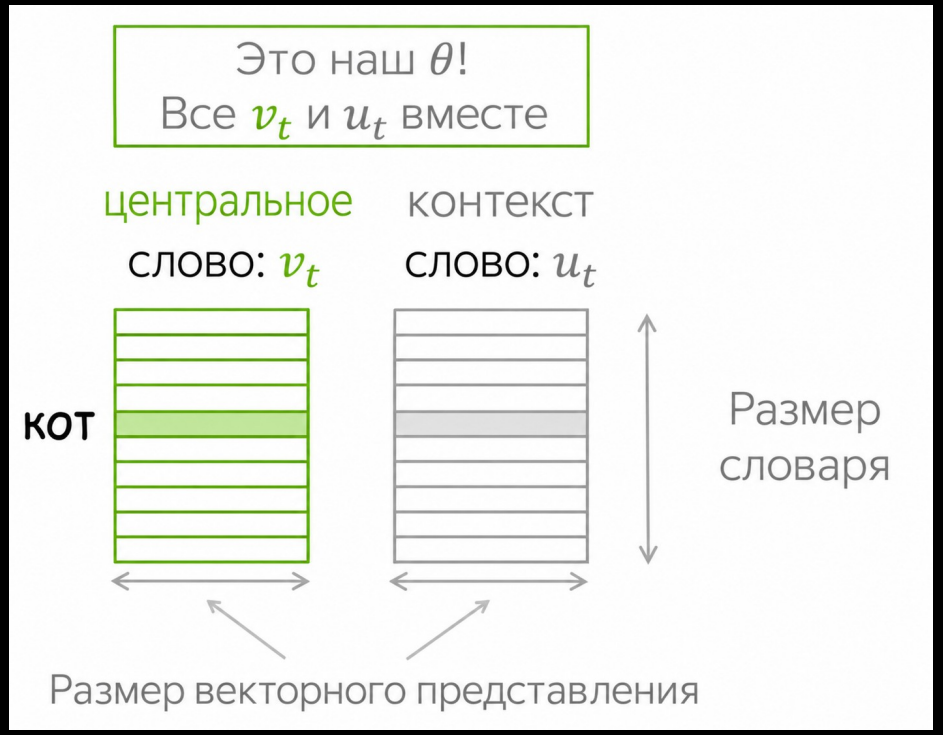
- Количество пар зависит от длины окна и границ текста.
- Правила формирования пар определяют обучающий сигнал модели.

# Два направления предсказания




- Skip-gram предсказывает окружение по выбранному слову.
- CBOW предсказывает выбранное слово по совокупности соседей.
- Оба метода используют контексты, но по-разному строят обучающую задачу.

# Векторы слова и его контекста




- При обучении могут использоваться две таблицы параметров.
- Одна представляет слово в роли входа, другая — в роли предсказываемого соседа.
- При использовании готовой модели важно знать, какие именно векторы она возвращает.

# Отрицательные обучающие пары

- Помимо наблюдаемой пары добавляют несколько случайно выбранных пар.

| Выбранное слово | Возможный сосед | Источник пары |
|---|---|---|
| кот | милый | Соседство в тексте |
| кот | счёт | Случайная отрицательная пара |
| кот | станция | Случайная отрицательная пара |

- Модель учится отличать реальные соседства от искусственно составленных.
- Такой способ уменьшает вычисления по сравнению с полным перебором словаря.

# Корпус для обучения векторов

- Объём корпуса определяет, сколько наблюдений доступно для частых и редких слов.
- Тематика и стиль текстов влияют на смысловые отношения в полученном пространстве.
- Повторы и технический мусор могут создавать нежелательные закономерности.
- Корпус должен соответствовать языку и предполагаемой области применения модели.

# Настройки обучения векторов

- Настройки изменяют объём наблюдений, размер словаря и число параметров.

| Параметр | Что меняется | Что проверять |
|---|---|---|
| Размер окна | Доступный контекст | Локальные связи и темы |
| Размерность вектора | Размер вектора | Качество и затраты памяти |
| Минимальная частота | Состав словаря | Охват редких слов |
| Настройки отбора пар | Обучающий сигнал | Устойчивость результата |

- Большая размерность не всегда полезнее: важны данные, память и устойчивость результата.
- Качество сравнивают на одной и той же проверочной задаче.

# Окно и типы связей

- Малое окно концентрирует обучение на ближайшем окружении слова.
- Более широкое окно чаще отражает общую тему фрагмента.
- Слова разных частей речи могут реагировать на изменение окна по-разному.
- Настройку выбирают по задаче, а не только по внешней убедительности списка соседей.

# Готовые векторы слов

- Предобученные таблицы позволяют начать работу без собственного большого корпуса.
- Перед загрузкой проверяют язык, словарь, размерность и лицензию.
- Терминология новой области может быть представлена плохо или отсутствовать.
- Проверяют способ обработки регистра, форм слов и записей вне словаря.

# Глобальная статистика соседств




- Метод GloVe использует статистику совместной встречаемости слов во всём корпусе.
- Векторы подбирают так, чтобы они согласовывались с этой статистикой.
- Как и другие статические представления, результат зависит от состава обучающих текстов.

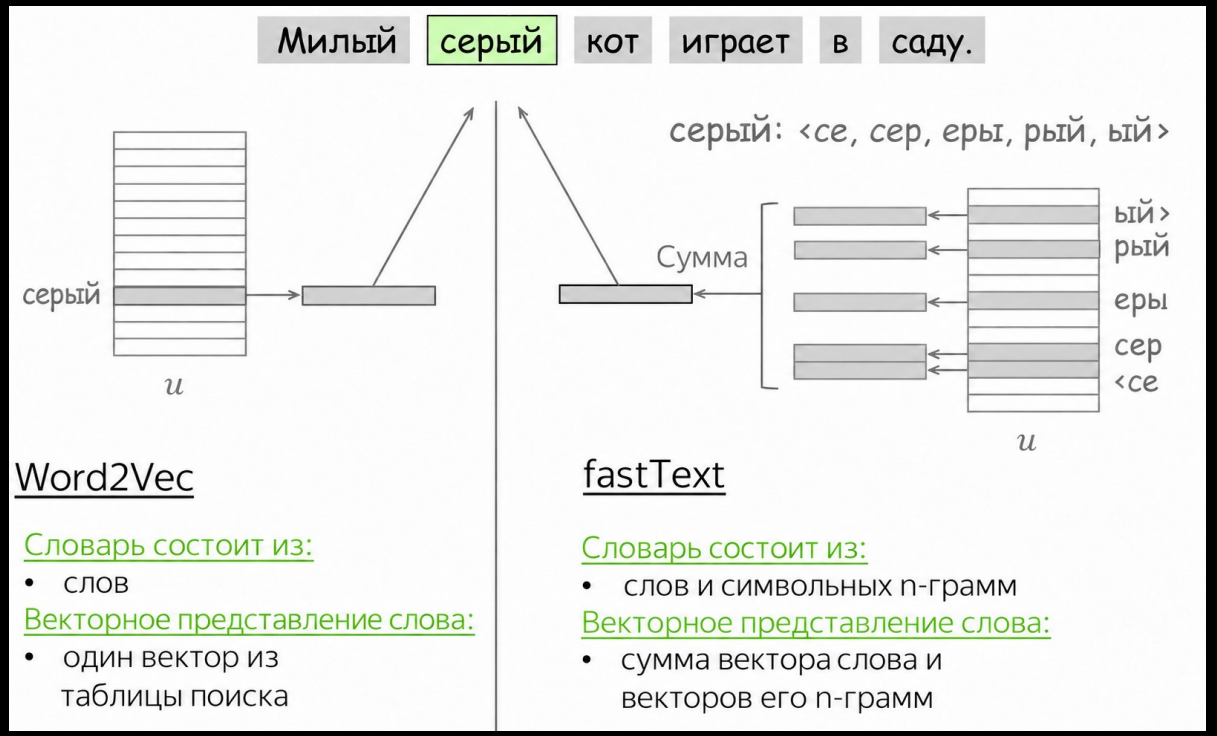
# Сравнение двух способов обучения

- Word2Vec строит обучение вокруг предсказания наблюдаемых соседств.

| Свойство | Word2Vec | GloVe |
|---|---|---|
| Исходные наблюдения | Пары слова и соседа | Статистика соседств |
| Основная идея | Предсказывать окружение | Согласовать векторы со статистикой |
| Результат | Статические векторы слов | Статические векторы слов |

- GloVe использует глобальную статистику совместной встречаемости.
- Оба метода дают статические векторы слов, но по-разному организуют обучающий сигнал.

# Учёт частей слова




- В fastText представление слова использует векторы групп соседних символов.
- Слова с общими фрагментами получают связанный обучающий сигнал.
- Это помогает учитывать формы слов и некоторые новые записи.

# Слова вне словаря

- В обычной таблице новая запись может не иметь собственного вектора.
- В fastText вектор часто можно составить из известных символьных фрагментов.
- Возможность получить вектор не гарантирует знания значения нового слова.
- При сильных опечатках, редких терминах и необычных символах результат нужно проверять отдельно.

# Примеры работы с частями слова

- Общие фрагменты помогают связать похожие словоформы.

| Случай | Что может помочь | Ограничение |
|---|---|---|
| «книга» / «книги» | Общие фрагменты словоформ | Нужные различия могут сохраниться |
| Опечатка в длинном слове | Часть фрагментов остаётся | Сильное искажение меняет вектор |
| Новая терминология | Представление по частям | Значение может быть неизвестно |

- Часть информации сохраняется даже при некоторых опечатках.
- Сходство написания само по себе не гарантирует сходства значений.

# Сравнение статических моделей

- Методы различаются обучающими наблюдениями и обработкой неизвестных записей.

| Метод | Основной сигнал | Работа с новой записью |
|---|---|---|
| Word2Vec | Предсказание контекстов | Таблица и правило для новых слов |
| GloVe | Глобальная статистика соседств | Таблица и правило для новых слов |
| fastText | Контексты и части слов | Возможно объединение частей слова |

- Для новой области важны покрытие словаря и качество редких терминов.
- Выбор следует подтверждать качеством прикладного решения.

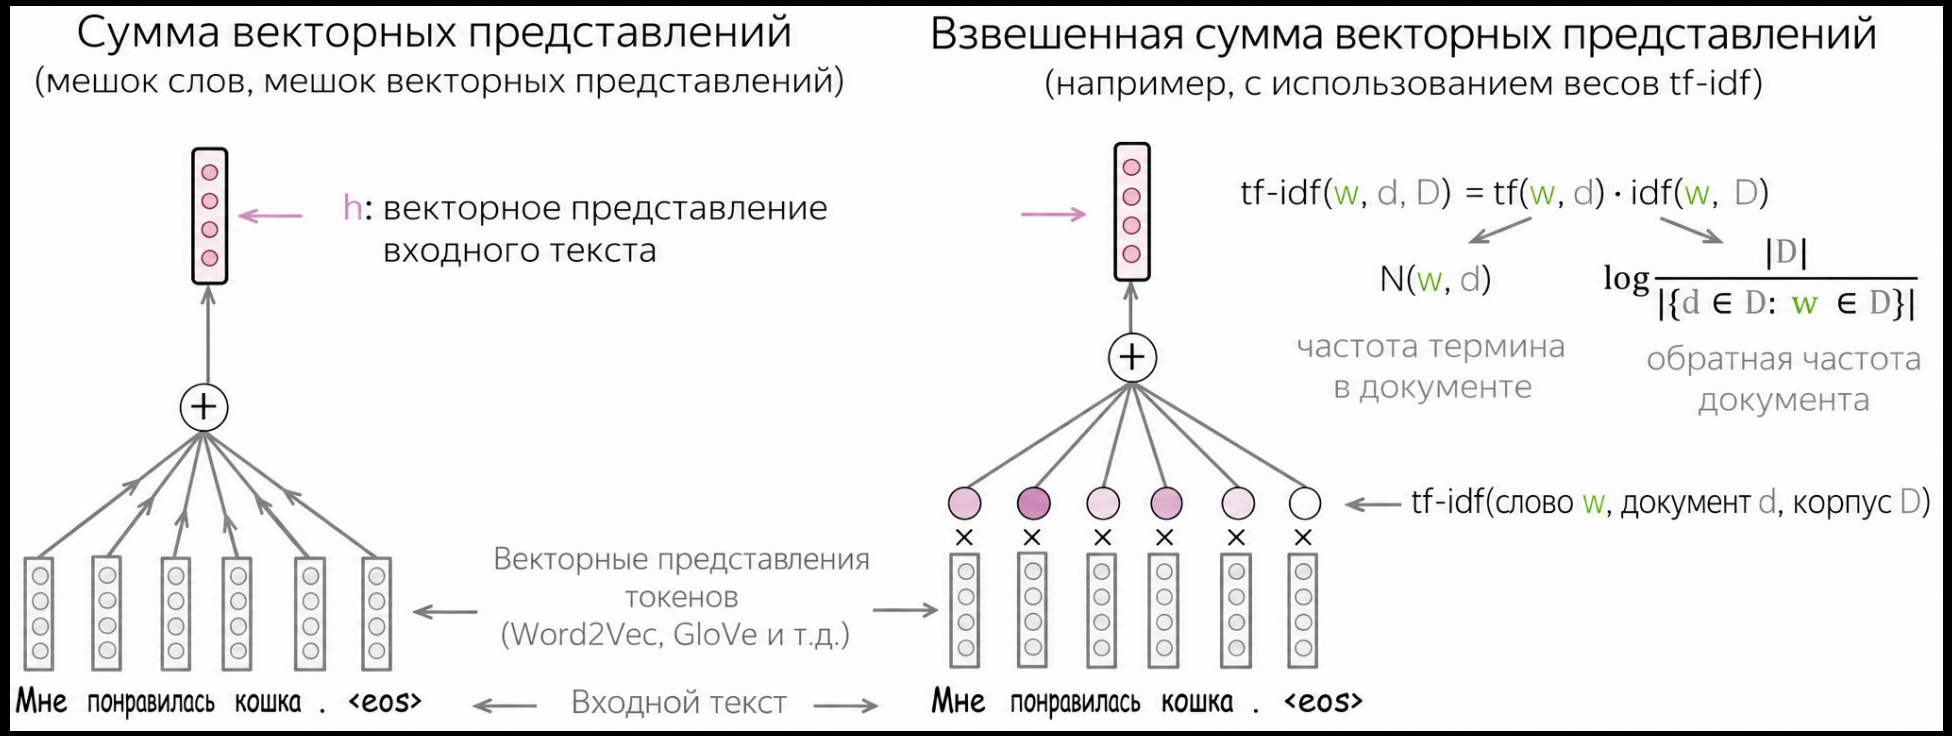
# Многозначность статического вектора

- Обычная статическая таблица возвращает один вектор для каждой словарной записи.
- Разные значения слова оказываются объединены в одном представлении.
- Для слова «ключ» это могут быть предмет для замка, источник воды или средство решения задачи.
- Чтобы различать конкретные употребления, модель должна учитывать окружающий текст.

# Представления предложений и документов

- Задачи классификации, поиска и группировки часто требуют одного вектора на целый текст.
- Можно объединять векторы слов или обучать отдельную модель представления документа.
- Метод объединения определяет, какие сведения о порядке и смысле сохранятся.
- Длину документа и ограничения модели учитывают до выбора способа представления.

# Усреднение векторов слов




- Простой способ получить вектор текста — усреднить векторы входящих в него слов.
- Такое объединение быстро вычисляется и не требует отдельного обучения.
- Порядок слов и распределение ролей обычно теряются.

# Взвешенное объединение

- Разные слова могут вносить разный вклад в представление документа.
- Вес можно связать с частотой, редкостью или обучаемой оценкой полезности.
- Перед сравнением нужно согласовать нормализацию весов и полученных векторов.
- Взвешивание не устраняет все ограничения: порядок и сложные смысловые связи всё ещё могут теряться.

# Потери при усреднении

- Одинаковый набор слов может описывать разные события.

| Текст A | Текст B | Что различается |
|---|---|---|
| «Собака укусила человека» | «Человек укусил собаку» | Роли участников |
| «Товар хороший, сервис плохой» | «Товар плохой, сервис хороший» | Объект оценки |

- Перестановка участников или объектов оценки способна изменить смысл при похожем среднем векторе.
- Такие пары полезны для проверки выбранного представления.

# Частотное представление документа

- TF-IDF сохраняет связь координат с конкретными словами или сочетаниями.
- Такое представление удобно для точного поиска терминов и интерпретации признаков.
- Синонимы и новые формулировки могут не иметь общих координат.
- Частотный метод полезно сохранять как исходное решение при сравнении с нейросетевыми векторами.

# Скрытые связи между терминами

Контекст:

- документ $d$ (из коллекции $D$)

Элемент матрицы:

- $\text{tf-idf}(w, d, D) = \text{tf}(w, d) \cdot \text{idf}(w, D)$

$\text{N}(w, d)$ — частота термина

$\log \frac{|D|}{|\{d \in D: w \in d\}|}$ — обратная частота документа

- Латентный семантический анализ снижает размерность матрицы «термин — документ».
- Совместные закономерности слов помогают представить документы компактнее.
- Число сохраняемых компонент выбирают по качеству и доступным ресурсам.

# Обучаемый вектор документа

- В doc2vec каждому обучающему документу соответствует собственное представление.
- Оно участвует в предсказании слов и обновляется вместе с другими параметрами.
- Вектор должен собирать информацию, полезную для объяснения слов документа.
- Получение вектора нового документа требует отдельной процедуры, а не простого выбора готовой строки.

# Документ и локальное окружение

- В варианте PV-DM предсказание использует вектор документа и соседние слова.

| Компонент | Роль в предсказании |
| --- | --- |
| Идентификатор документа | Выбирает обучаемый вектор документа |
| Соседние слова | Дают локальное окружение позиции |
| Предсказываемое слово | Задаёт обучающий ответ |

- Документ даёт общую информацию, а локальный контекст уточняет текущую позицию.
- Все компоненты должны согласованно обучаться на одной задаче.

# Предсказание слов по документу

- В варианте PV-DBOW по представлению документа предсказывают слова из него.
- Локальное окружение не подаётся так же, как в варианте с распределённой памятью.
- Обучающая задача заставляет вектор отражать состав и особенности документа.
- Детали реализации и дополнительные режимы обучения проверяют в документации библиотеки.

# Новый документ в обученной модели

- Для нового текста сначала применяют те же правила подготовки, что и при обучении.
- Основные параметры обученной модели фиксируют.
- Новый вектор документа подбирают по его словам в отдельной процедуре оптимизации.
- Время и устойчивость этой процедуры нужно учитывать при массовой обработке документов.

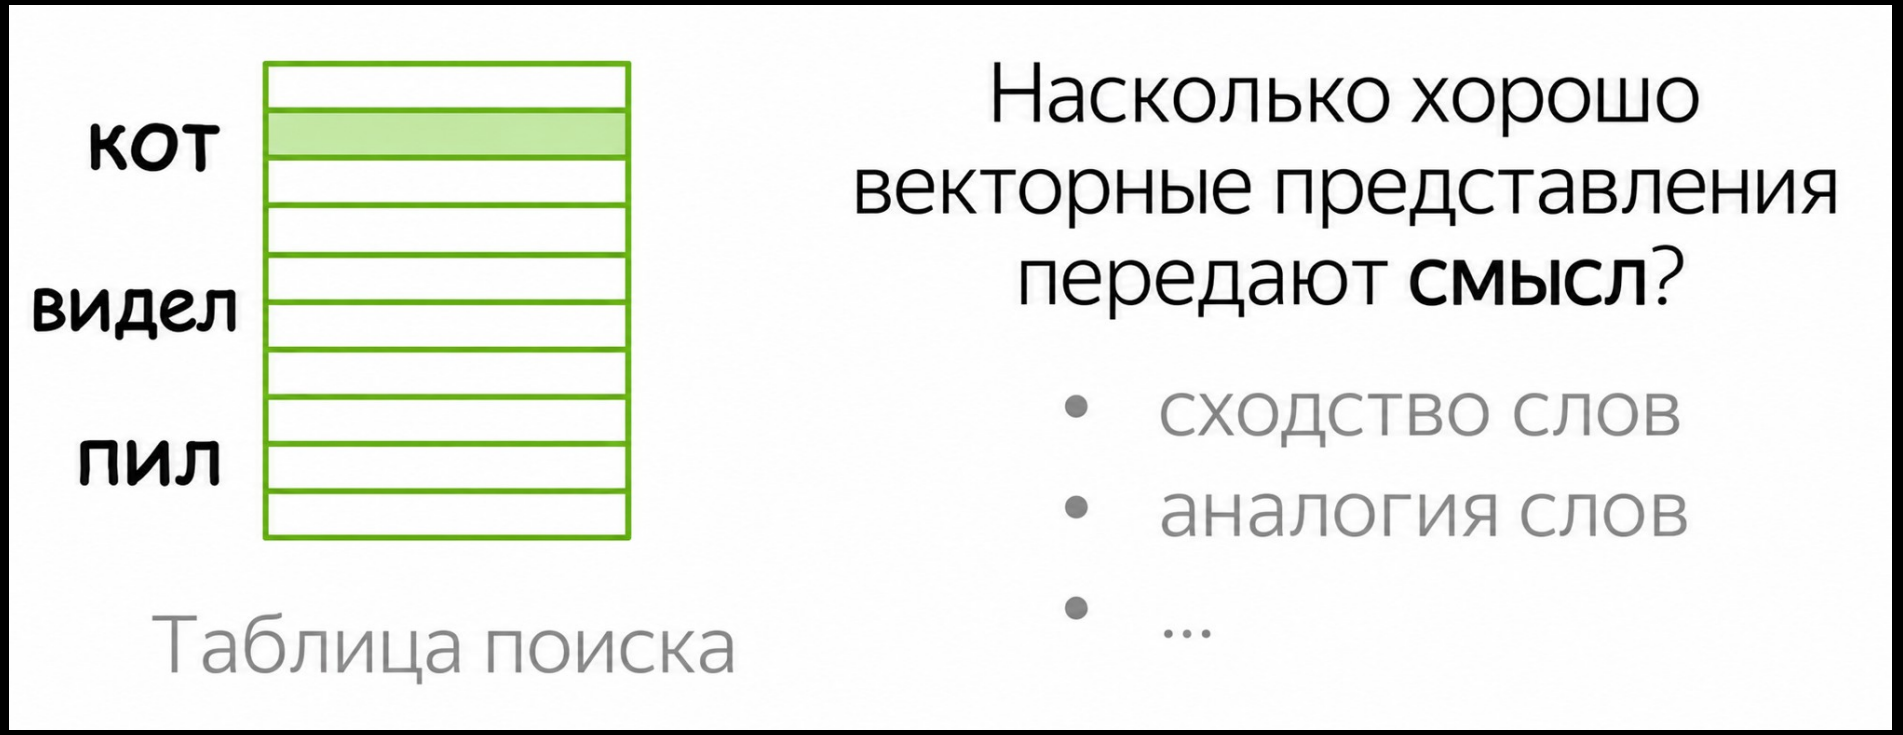
# Сравнение представлений документов

- Разные методы по-разному используют словарь, контекст и обученные параметры.

| Подход | Представление | Новый текст |
|---|---|---|
| TF-IDF | Веса словарных признаков | Применение обученного словаря |
| Объединение векторов слов | Объединение векторов слов | Выбор векторов и объединение |
| doc2vec | Обученный вектор документа | Отдельный подбор нового вектора |
| Кодировщик предложений | Вектор целого текста | Вычисление выхода модели |

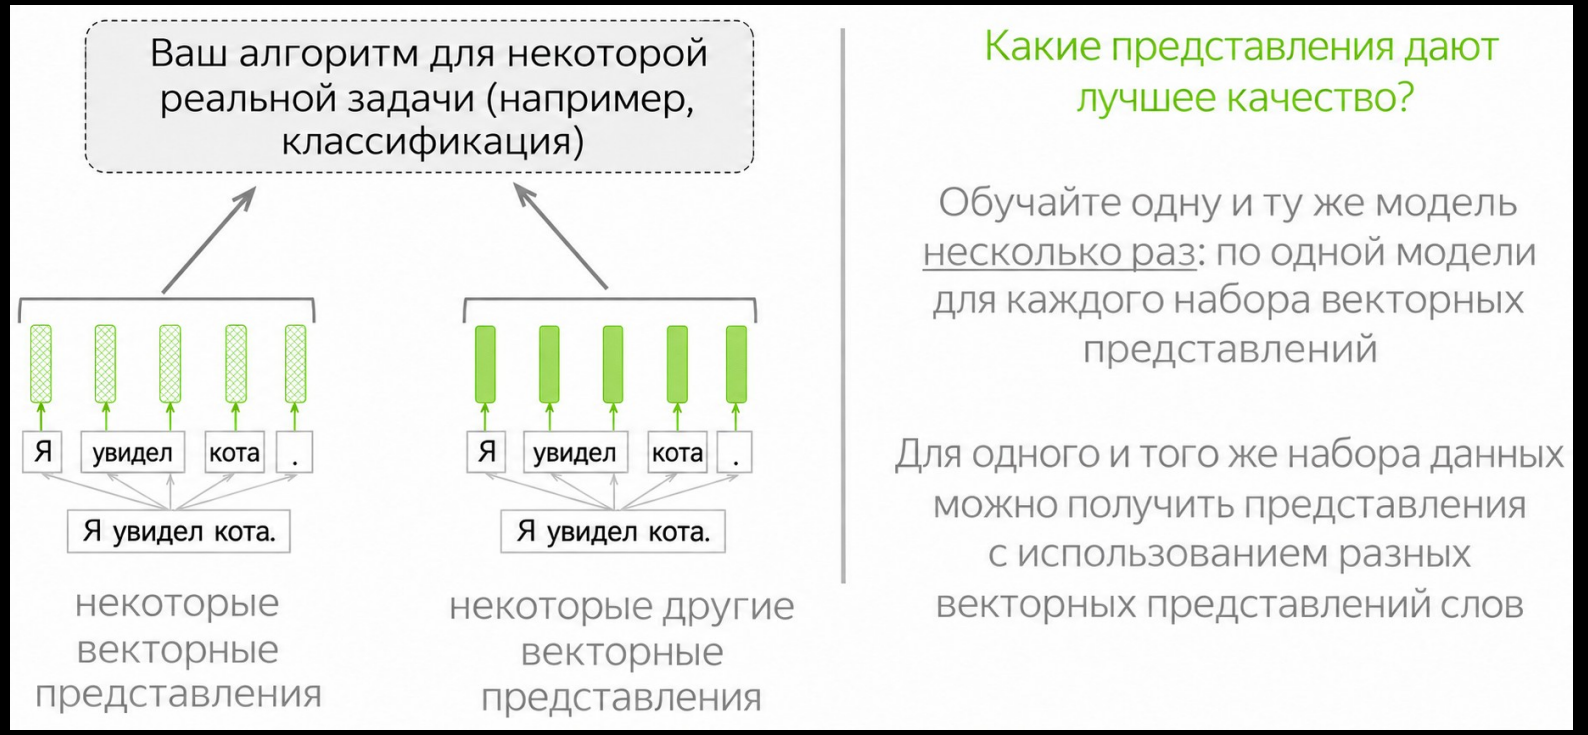
- Особое внимание уделяют способу обработки нового текста.
- Сравнение должно включать качество, скорость и потребление памяти.

# Проверка свойств самих векторов




- Можно оценивать сходство слов, аналогии и структуру ближайших соседей.
- Такая проверка помогает понять, какие отношения представлены в пространстве.
- Хорошие результаты на этих примерах не гарантируют успеха в прикладной задаче.

# Проверка в прикладной задаче

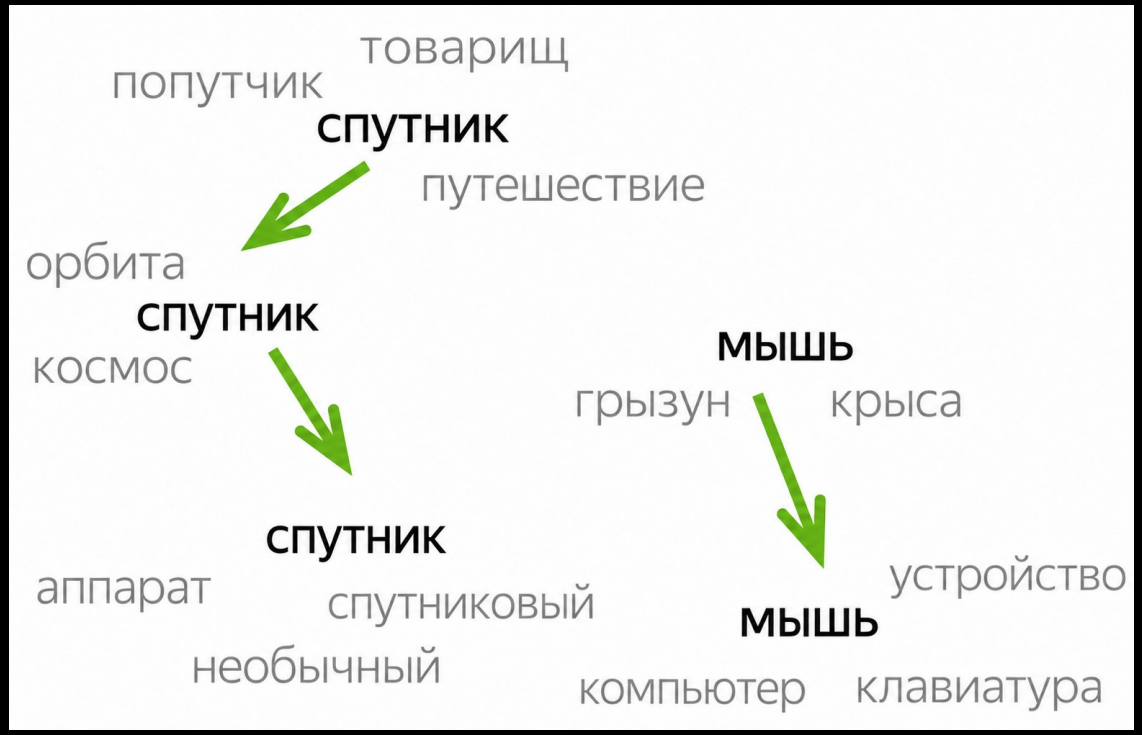



- Представления сравнивают по качеству классификации, поиска или другой целевой задачи.
- Остальные условия эксперимента по возможности сохраняют одинаковыми.
- Важно оценить и качество, и стоимость получения представлений.

# Правила оценки представлений

- Обучающая, проверочная и тестовая части должны оставаться одинаковыми для сравниваемых методов.
- Настройки выбирают без использования итоговой тестовой оценки.
- Проверяют редкие слова, отрицания, длинные тексты и примеры из другой области.
- Одного удачного примера недостаточно для вывода о преимуществе модели.

# Корпус и изменение употребления слов




- Соседство слов отражает тексты, на которых обучали представления.
- Новая предметная область или другое время могут изменить привычные связи.
- Для изменившихся данных качество нужно проверять заново.

# Статические и контекстные представления

- Статическое представление связано со словарной записью.

| Свойство | Статическое | Контекстное |
|---|---|---|
| Что представлено | Слово из словаря | Употребление в последовательности |
| Одна запись в разных фразах | Один вектор слова | Разные скрытые состояния |
| Примеры | Word2Vec, GloVe, fastText | ELMo, BERT |

- Контекстное представление описывает конкретное употребление слова в последовательности.
- Одинаковое слово в разных фразах может получить разные векторы.

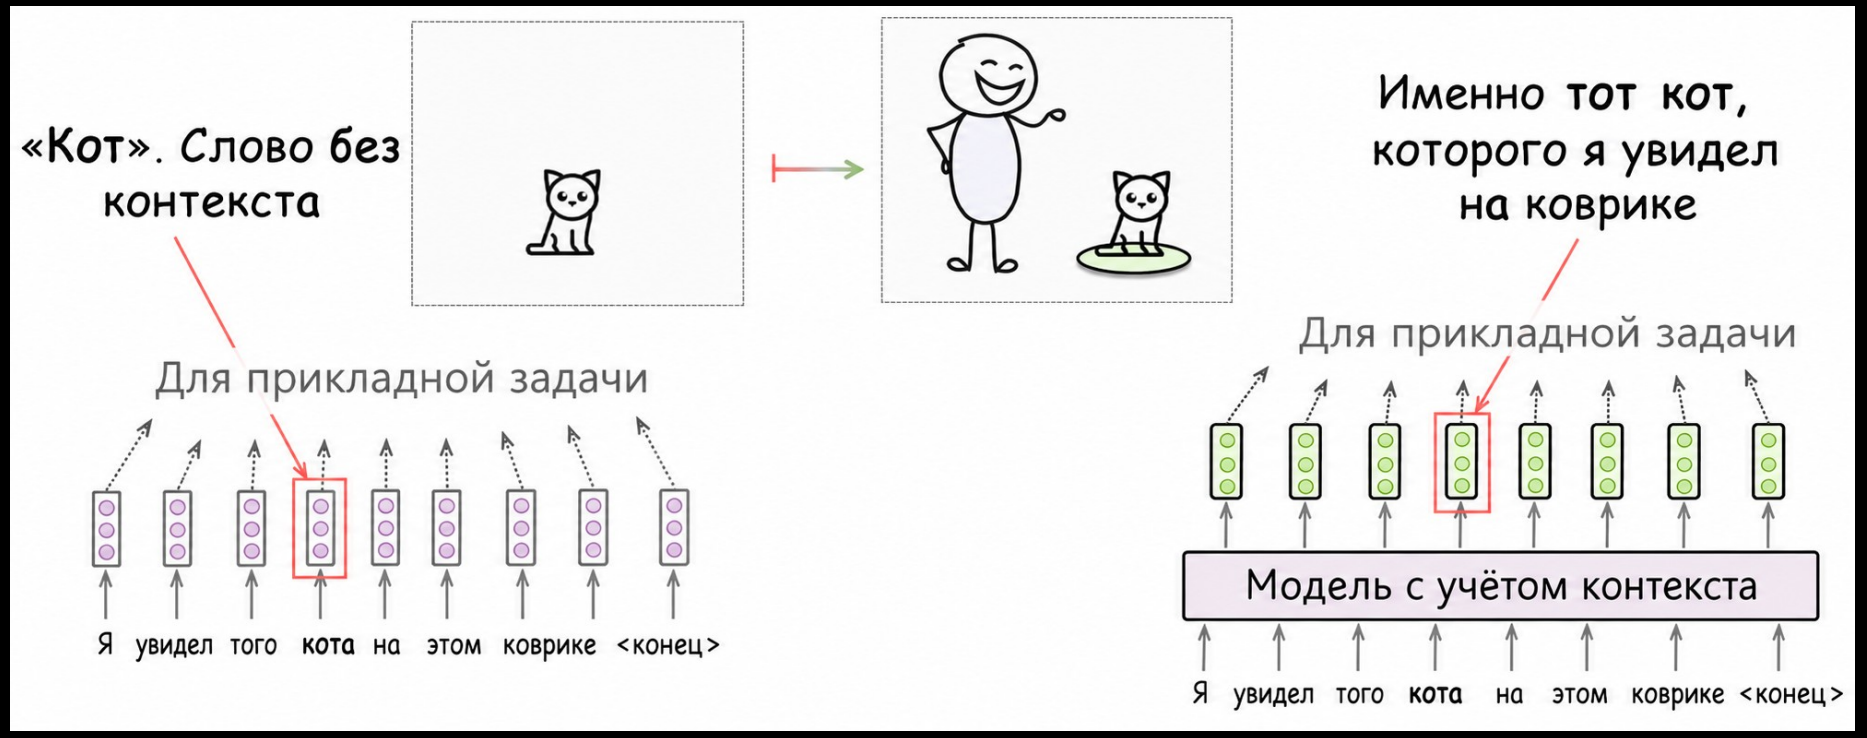
# Многозначность слова «ключ»

- Соседние слова помогают отличить предмет для замка от источника воды.

| Контекст | Значение слова «ключ» | Что нужно учесть |
|---|---|---|
| Ключ не подходил к замку. | Предмет для открывания | Слова «подходил» и «замку» |
| Из-под земли бил холодный ключ. | Источник воды | Слова «из-под земли» и «бил» |

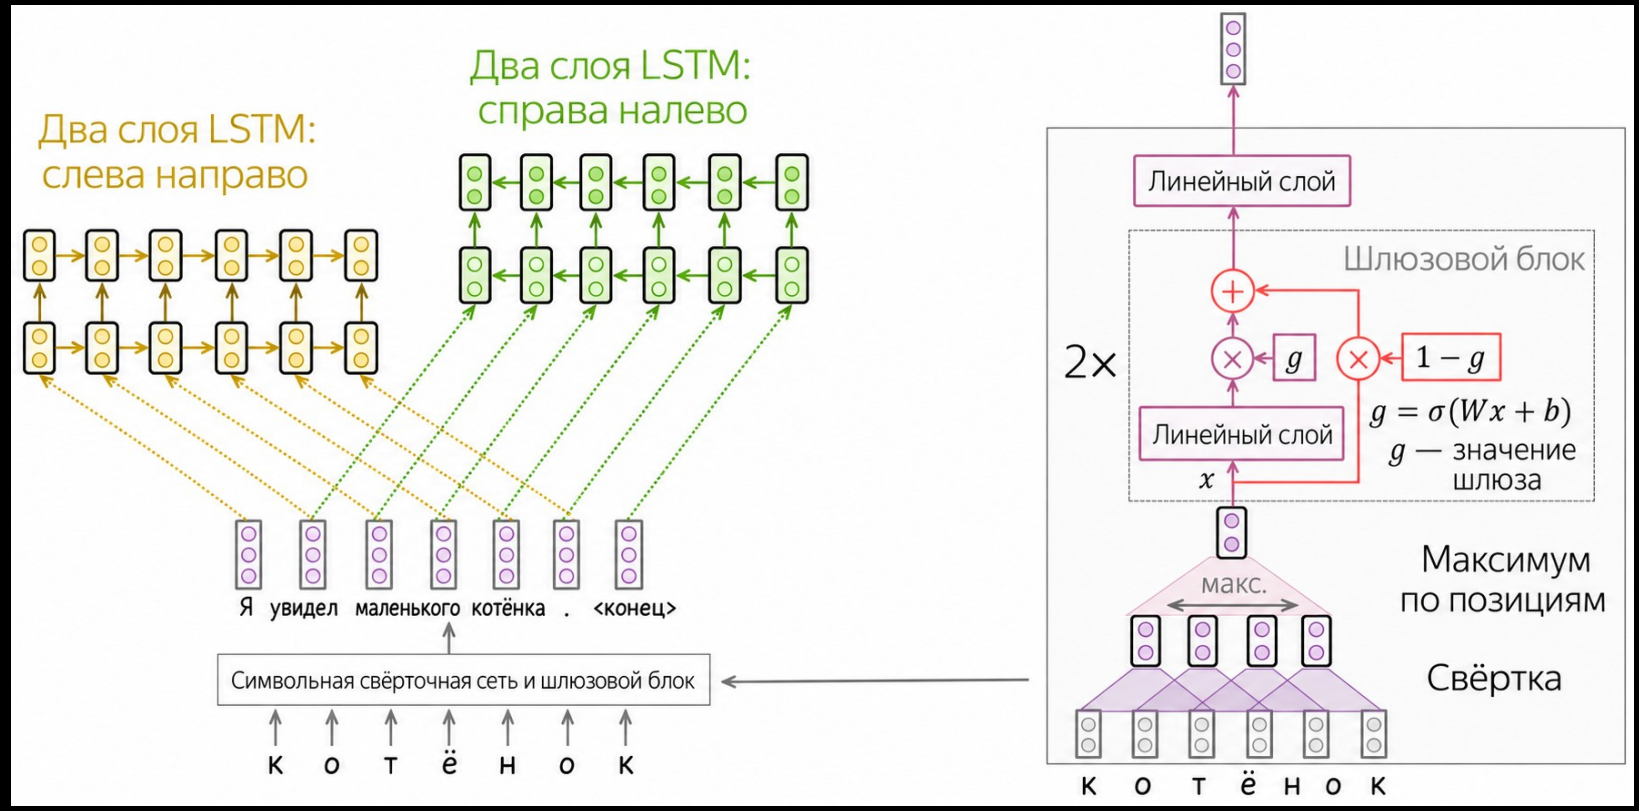
- Модель должна учитывать фразу, а не только выбранную запись.
- Контекстное представление позволяет передать это различие следующему этапу обработки.

# Слово в конкретном контексте



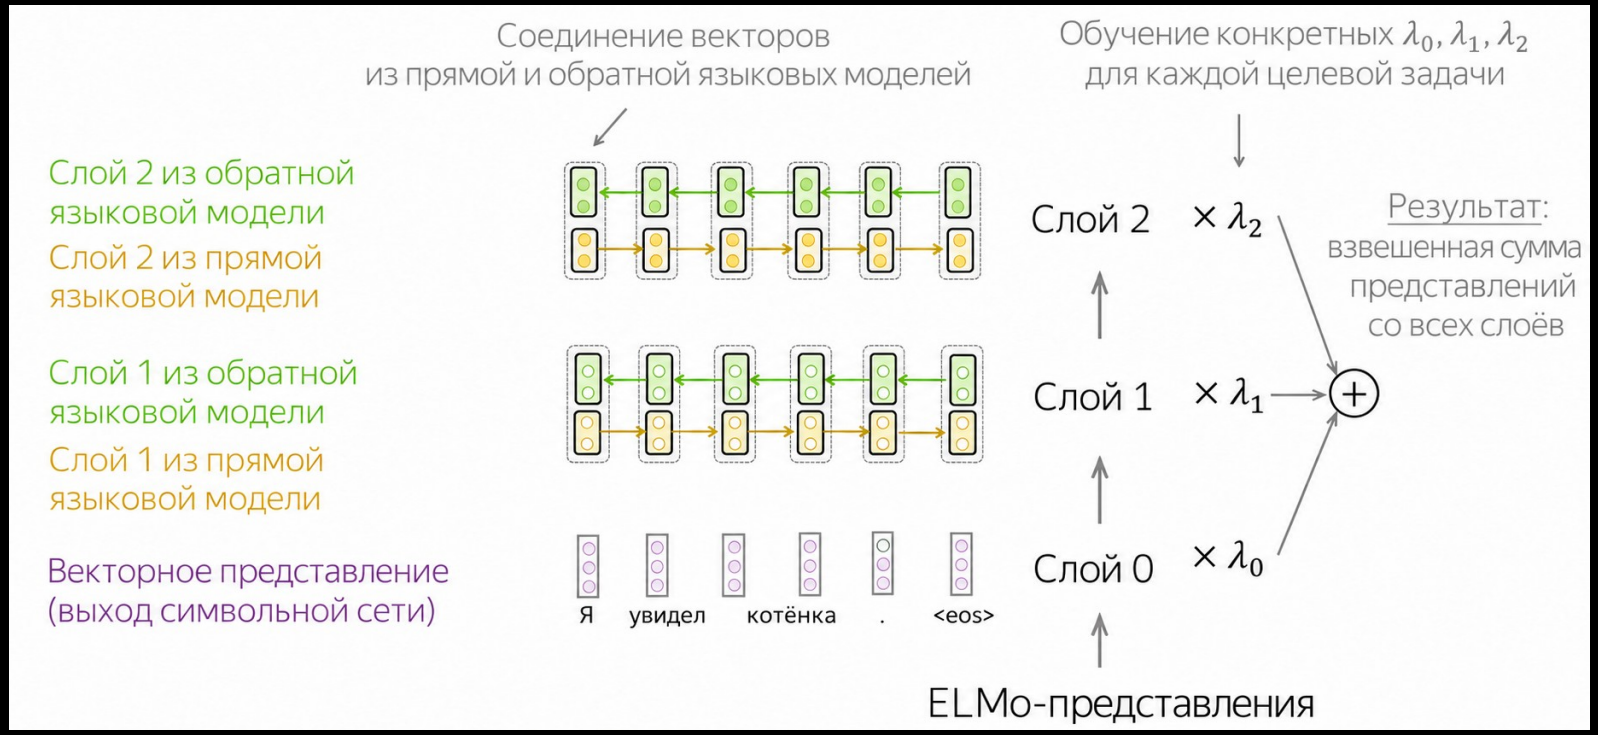

- Статический вектор описывает слово независимо от текущего предложения.
- Контекстная модель учитывает соседей и связи внутри фразы.
- На выходе получается представление данного употребления слова.

# Контекстные представления из языковой модели



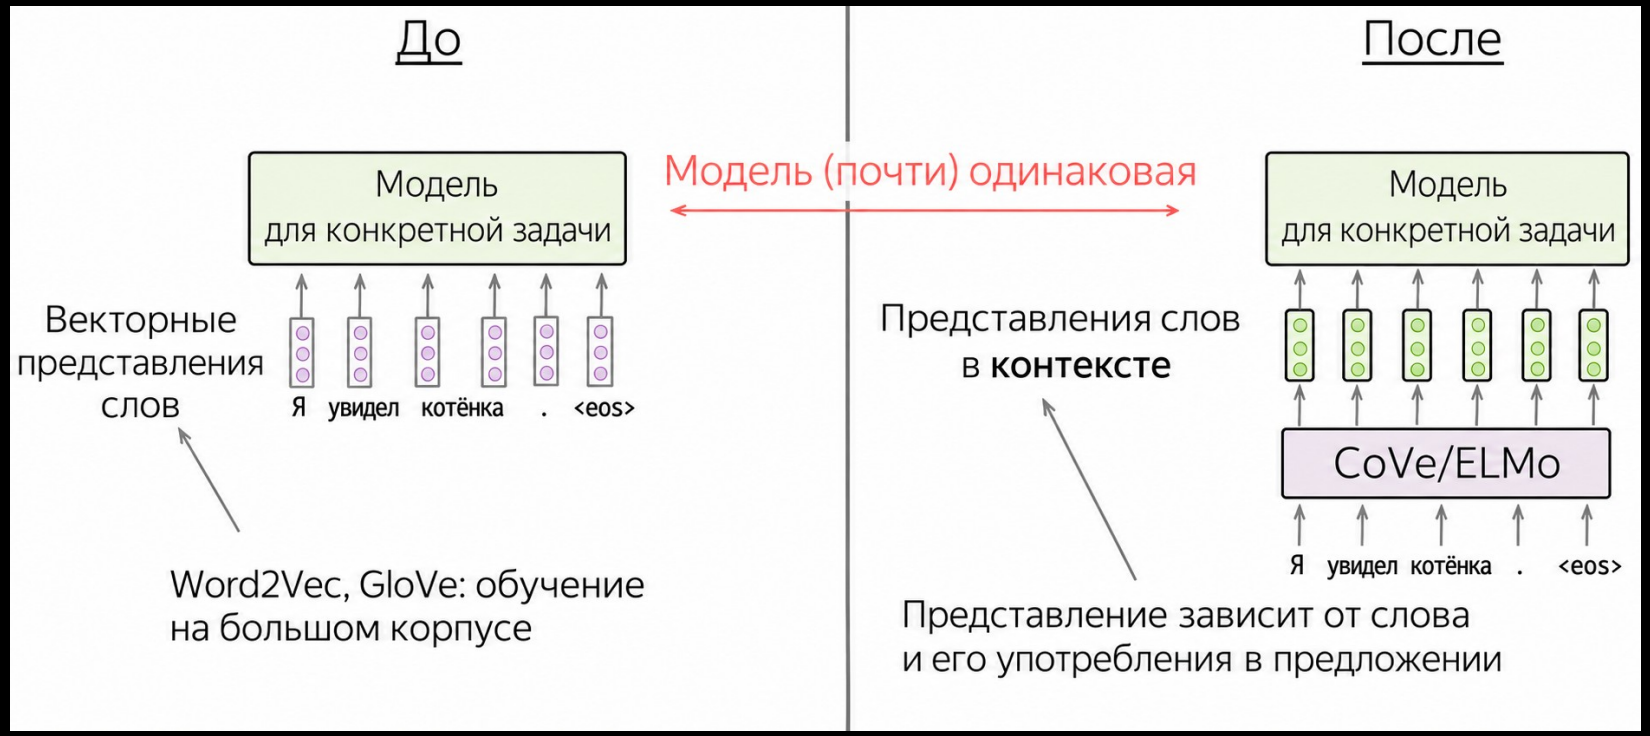

- В ELMo две языковые модели читают текст в противоположных направлениях.
- Представления учитывают левый и правый контекст.
- Входные векторы строятся по символам слова.

# Информация из разных слоёв




- Разные слои могут отражать разные свойства употребления слова.
- ELMo объединяет представления слоёв с обучаемыми весами.
- Веса такого сочетания можно подобрать для конкретной прикладной задачи.

# Передача контекста прикладной модели




- Контекстные представления можно передать классификатору или модели разметки.
- Вместо одной статической таблицы используется способ вычисления векторов по целой фразе.
- Правила ответа задаёт новая задача и её обучающие данные.

# Двунаправленная модель текста




Архитектура модели:

- Кодировщик трансформера

Что в ней особенного:

- Цели обучения
  - MLM: моделирование языка с маскированными токенами
  - NSP: предсказание следующего предложения
- Способ использования
  - Одна основа для разных задач

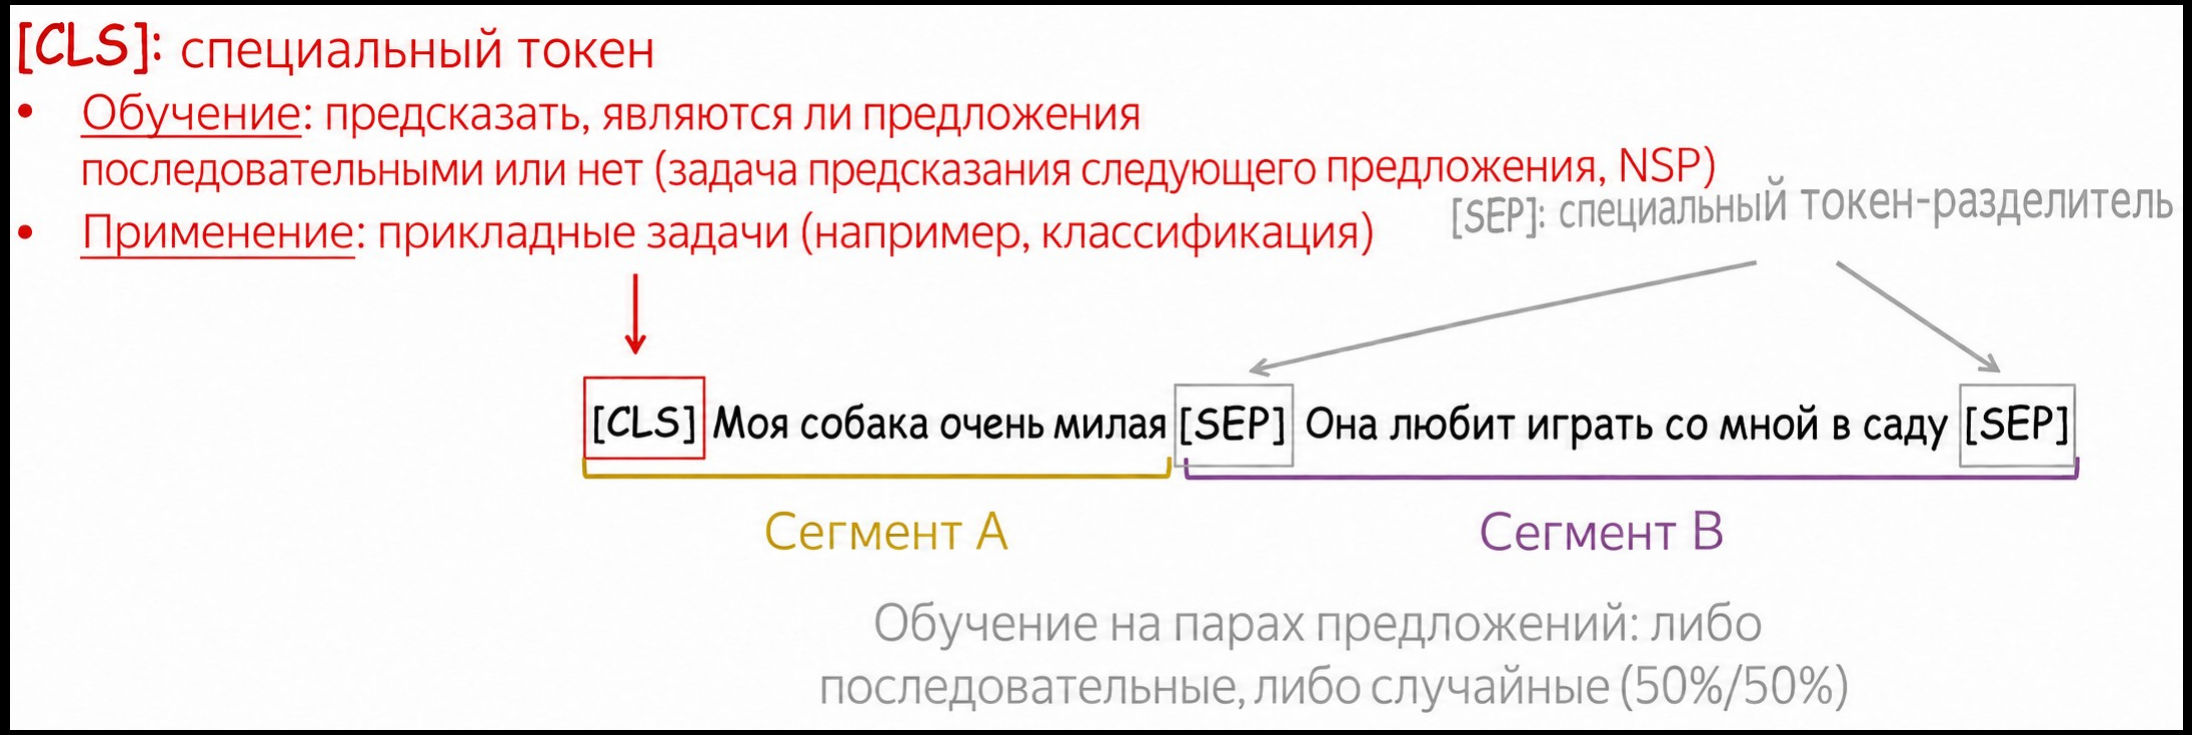
- BERT использует кодировщик трансформера для учёта контекста с обеих сторон.
- Предобученная модель затем применяется или дообучается для прикладной задачи.
- В этом блоке важен принцип переноса представлений, а устройство внимания разбирается далее.

# Восстановление скрытых элементов




- При предобучении BERT выбранные элементы восстанавливают по контексту.
- Модель учится учитывать зависимости между словами в предложении.
- Доля выбранных позиций и способ их замены относятся к процедуре обучения конкретной модели.

# Подготовка входа контекстной модели




- Модель ожидает собственное разбиение текста и служебные элементы.
- Идентификаторы словарных единиц, границы фрагментов и маски должны соответствовать обучению.
- Несовместимый способ подготовки входа может ухудшить результат даже при корректном запуске.

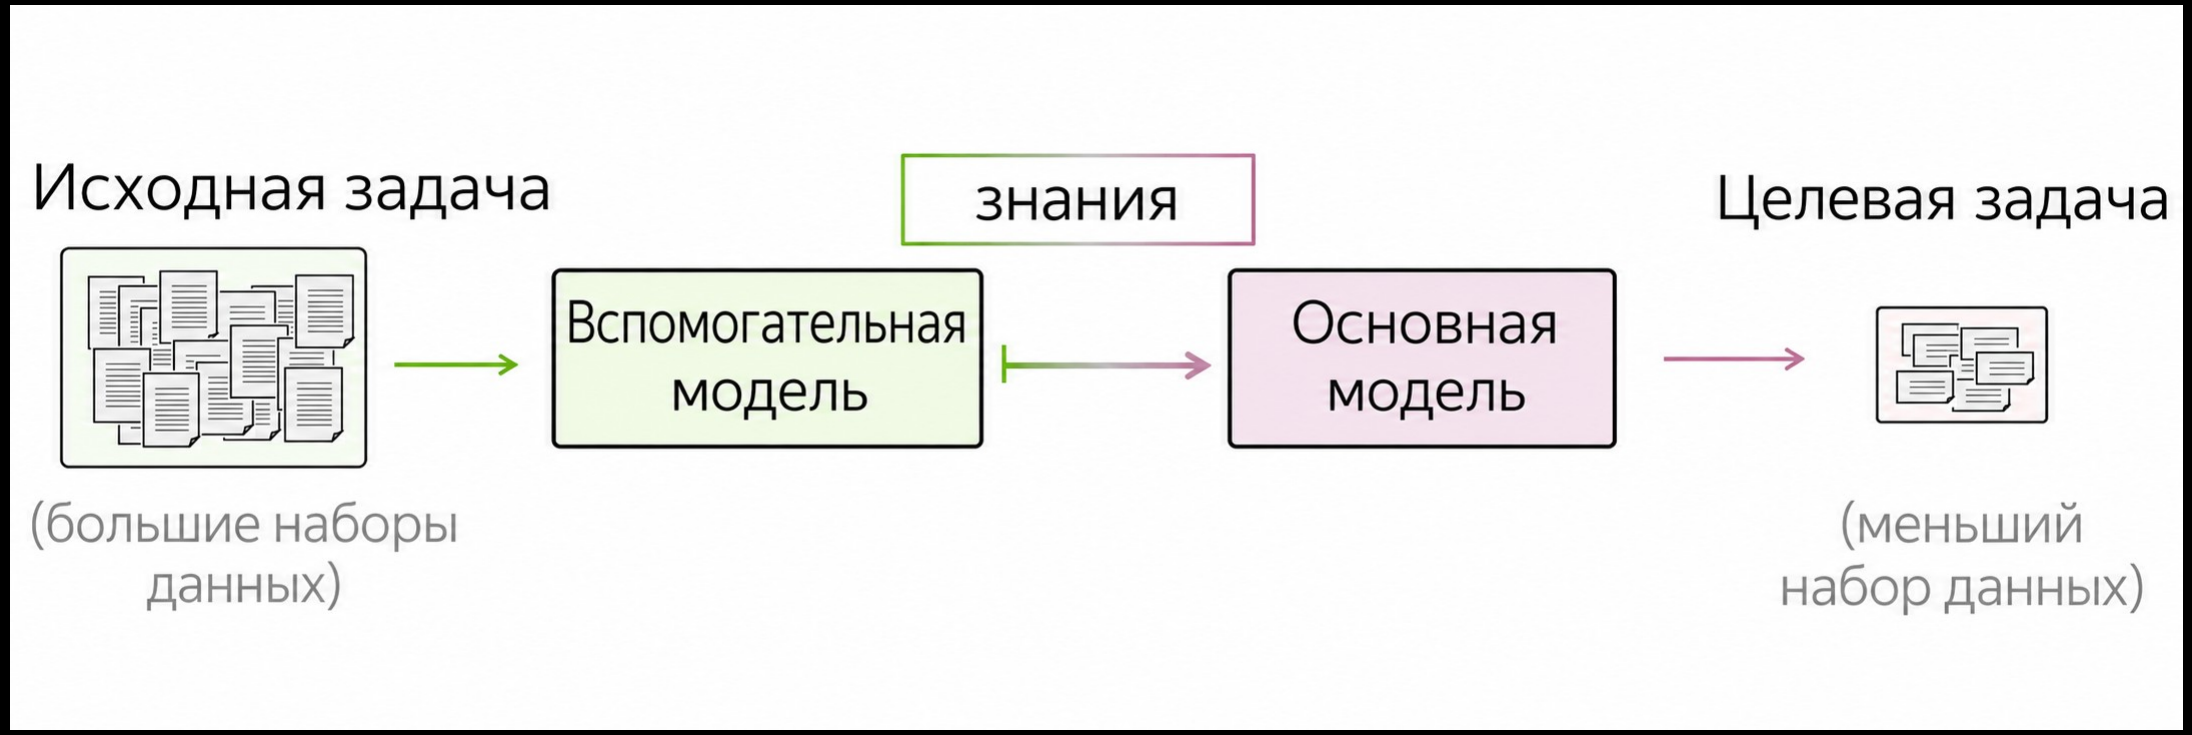
# Скрытые состояния и объединение

- Кодировщик возвращает представления отдельных позиций текста.
- Для одного вектора на документ нужно выбрать способ их объединения.
- Можно использовать среднее по допустимым позициям или специальную позицию, если модель обучена её использовать.
- Пустые позиции для выравнивания длины не должны случайно участвовать в усреднении.

# Вектор предложения из контекстной модели

- Обучение на восстановлении элементов не обязательно делает близость целых предложений удобной для поиска.
- Простое усреднение выходов BERT не гарантирует качественных смысловых расстояний.
- Специальное обучение векторов предложений согласует пространство с нужным видом сходства.
- Качество проверяют на примерах запросов и документов из целевой задачи.

# Предобучение и адаптация

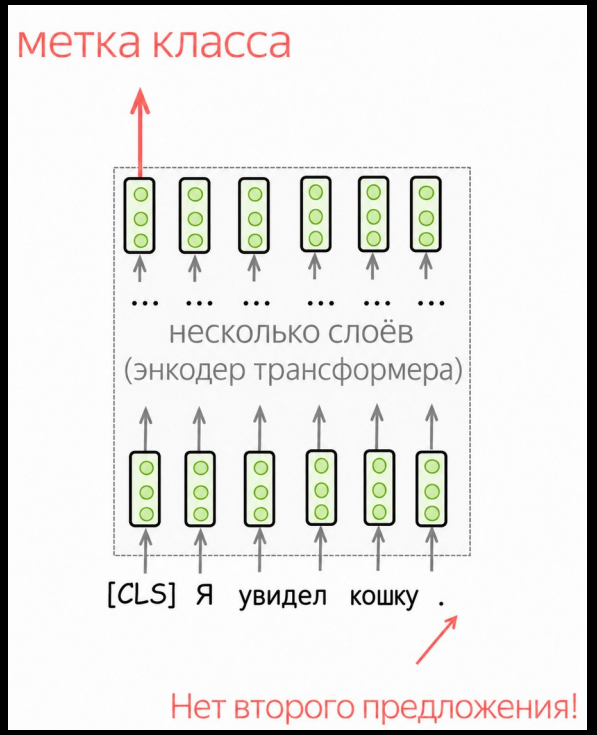



- Предобучение использует большую коллекцию для освоения общих закономерностей языка.
- Затем модель применяют к задаче с собственными данными и целевыми ответами.
- Перенос помогает сократить объём необходимой разметки, но требует проверки качества.

# Готовые признаки или дообучение

- При извлечении готовых признаков параметры кодировщика остаются фиксированными.
- При дообучении часть или все параметры меняются под новую задачу.
- Фиксированный кодировщик проще сравнивать и дешевле обучать вместе с небольшим классификатором.
- Дообучение может улучшить качество, но требует ресурсов и контроля переобучения.

# Основная модель и выходной модуль

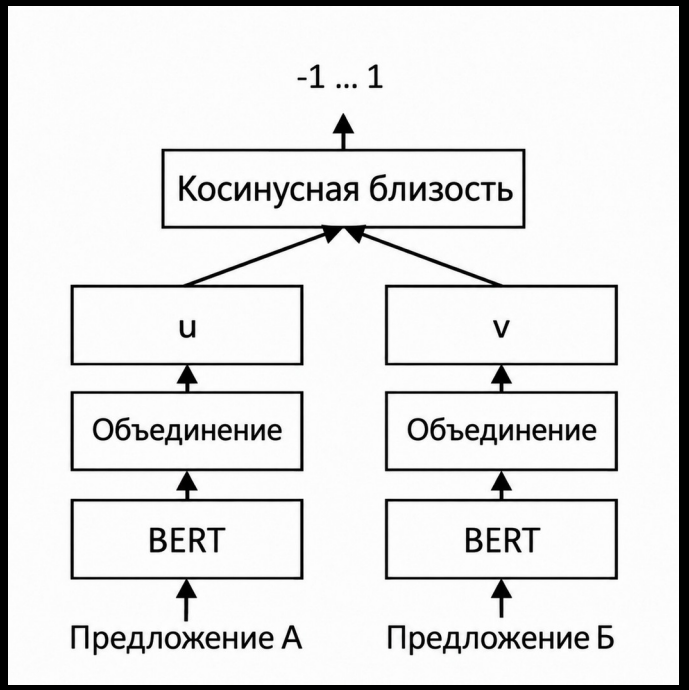



- Кодировщик строит представления входного текста.
- Выходной модуль преобразует их в ответ конкретной задачи.
- Для новой задачи можно изменить выходной модуль и выбрать, какие параметры дообучать.

# Адаптация к предметной области

- Тексты новой области отличаются терминологией, стилем и распределением задач.
- Дополнительное обучение может помочь учесть эти особенности.
- Проверяют не только улучшение на новой области, но и возможную потерю прежних возможностей.
- Данные адаптации и итоговой проверки должны оставаться раздельными.

# Совместимое пространство предложений




- Sentence-BERT обучает представления предложений для сравнения их близости.
- Одинаковый кодировщик обрабатывает тексты в совместимом пространстве.
- После вычисления векторов сравнение можно выполнять без повторного совместного чтения каждой пары.

# Пары текстов для обучения

- Положительная пара связывает тексты, которые должны оказаться близкими.

| Текст / запрос | Связанный текст | Обучающий сигнал |
|---|---|---|
| «Как вернуть заказ?» | «Инструкция по возврату товара» | Положительная пара |
| «Как вернуть заказ?» | «Условия рассрочки» | Отрицательная пара |
| «Отмена подписки» | «Как отключить автопродление» | Положительная пара |

- Отрицательная пара показывает нежелательное совпадение.
- Качество пар и сложность отрицательных примеров определяют полезность обучения.

# Объединение представлений позиций

- Способ объединения должен соответствовать обучению выбранной модели.

| Способ | Принцип | Условие применения |
|---|---|---|
| Усреднение | Усреднение нужных позиций | Пустые позиции исключают по маске |
| Специальная позиция | Использование специальной позиции | Модель обучена использовать её |
| Обучаемое объединение | Обучаемое объединение | Нужны обученные веса |

- При усреднении учитывают маску допустимых позиций.
- Специальная позиция полезна только тогда, когда модель научилась собирать в ней нужную информацию.

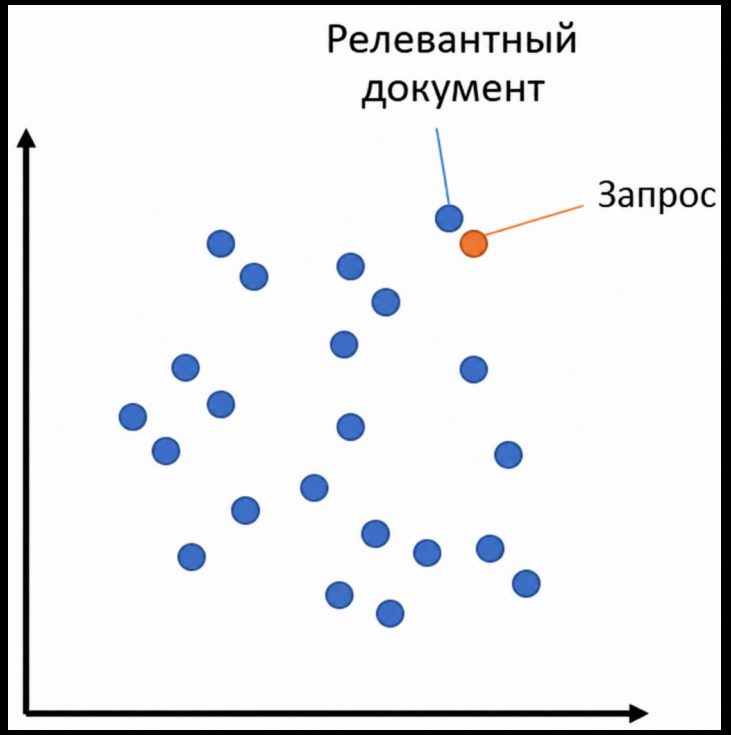
# Получение вектора нового текста

- Используют ту же модель, словарь и правила обработки, что и для остальных объектов.
- Учитывают ограничение длины и допустимый способ обрезки или разбиения текста.
- Вычисляют вектор, выполняя предусмотренное моделью объединение и нормализацию.
- Версии модели и правила обработки сохраняют, чтобы можно было воспроизвести результат.

# Близость и принятие решения

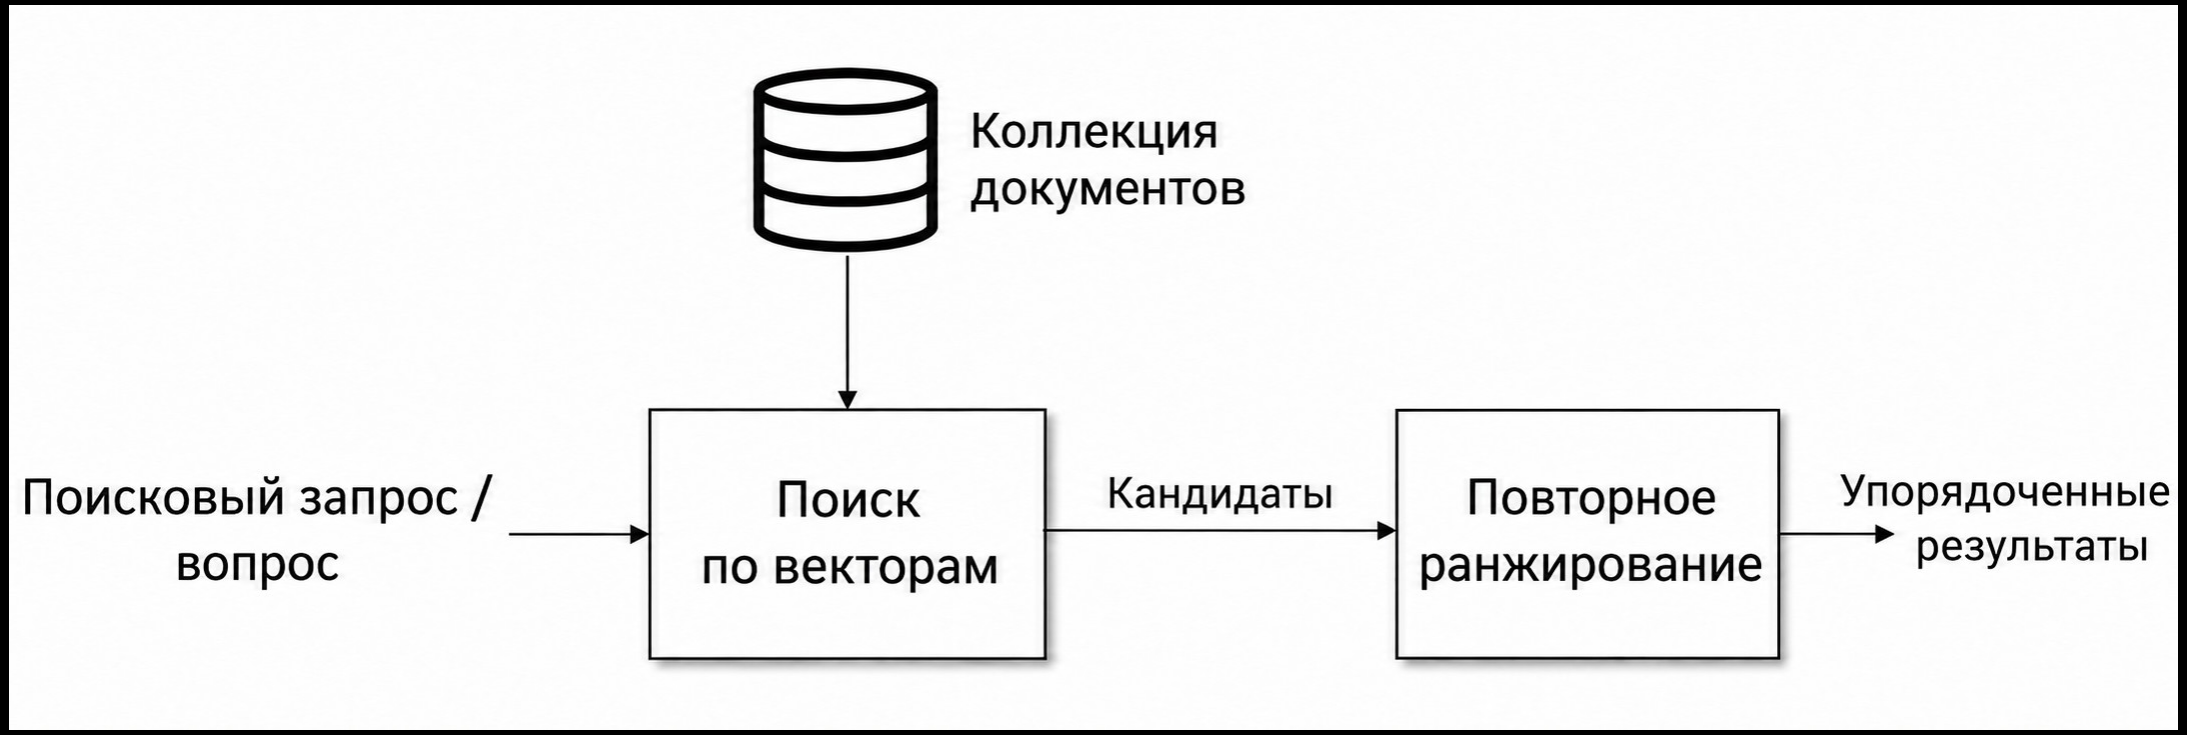
- Численная близость является оценкой модели, а не готовым правилом ответа.
- Порог для объединения, поиска дублей или выбора результата подбирают по размеченным примерам.
- Один порог может плохо переноситься между моделями и предметными областями.
- При настройке учитывают цену пропусков и ложных совпадений.

# Раздельное кодирование запроса и документов




- Документы заранее переводят в векторы и сохраняют в поисковом индексе.
- Для нового запроса вычисляют совместимый вектор.
- По близости выбирают документы-кандидаты для ответа или дальнейшей проверки.

# Последовательность смыслового поиска




- Первый этап быстро извлекает кандидатов из коллекции.
- Второй этап может точнее оценить связь запроса с каждым кандидатом.
- Качество всей системы зависит от обоих этапов и от состава исходных документов.

# Симметричный и асимметричный поиск

- В симметричной задаче сравнивают объекты похожего типа, например два предложения.
- В асимметричной задаче короткий вопрос сопоставляют с длинным документом или ответом.
- Некоторые модели предусматривают разные режимы кодирования запросов и документов.
- Нужно использовать режим, соответствующий обучению модели и реальному сценарию поиска.

# Разбиение документов на фрагменты

- Длинный документ делят на части, которые помещаются во вход модели.
- Фрагмент должен сохранять достаточно контекста для понимания и ответа.
- Размер, перекрытие и границы частей влияют на полноту и точность поиска.
- Для найденного фрагмента сохраняют связь с исходным документом и его расположением.

# Векторный индекс

- Индекс ускоряет поиск близких векторов в большой коллекции.
- Приближённый поиск уменьшает время и расход ресурсов ценой возможных пропусков.
- Настройки выбирают с учётом полноты поиска, задержки и памяти.
- При замене модели векторы коллекции и индекс обычно требуется согласованно пересчитать.

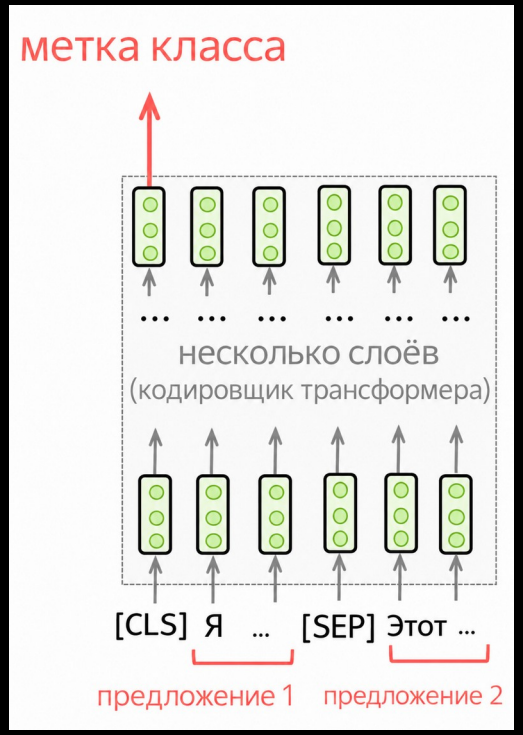
# Словарный, векторный и гибридный поиск

- Словарный поиск хорошо сохраняет точные термины и идентификаторы.

| Подход | Что хорошо сохраняет | Типичный риск |
| --- | --- | --- |
| Словарный | Точные термины и идентификаторы | Нет совпадающих формулировок |
| Векторный | Связи между разными выражениями | Потеря точных деталей |
| Гибридный | Несколько сигналов соответствия | Нужна настройка объединения |

- Векторный поиск помогает находить разные формулировки похожего смысла.
- Гибридный подход объединяет эти сигналы и требует настройки общего порядка результатов.

# Совместная оценка пары текстов




- Совместная модель читает запрос и документ одновременно.
- Такое сравнение обычно дороже, поэтому его применяют к ограниченному набору кандидатов.
- Повторное ранжирование уточняет порядок, но не возвращает документы, потерянные на первом этапе.

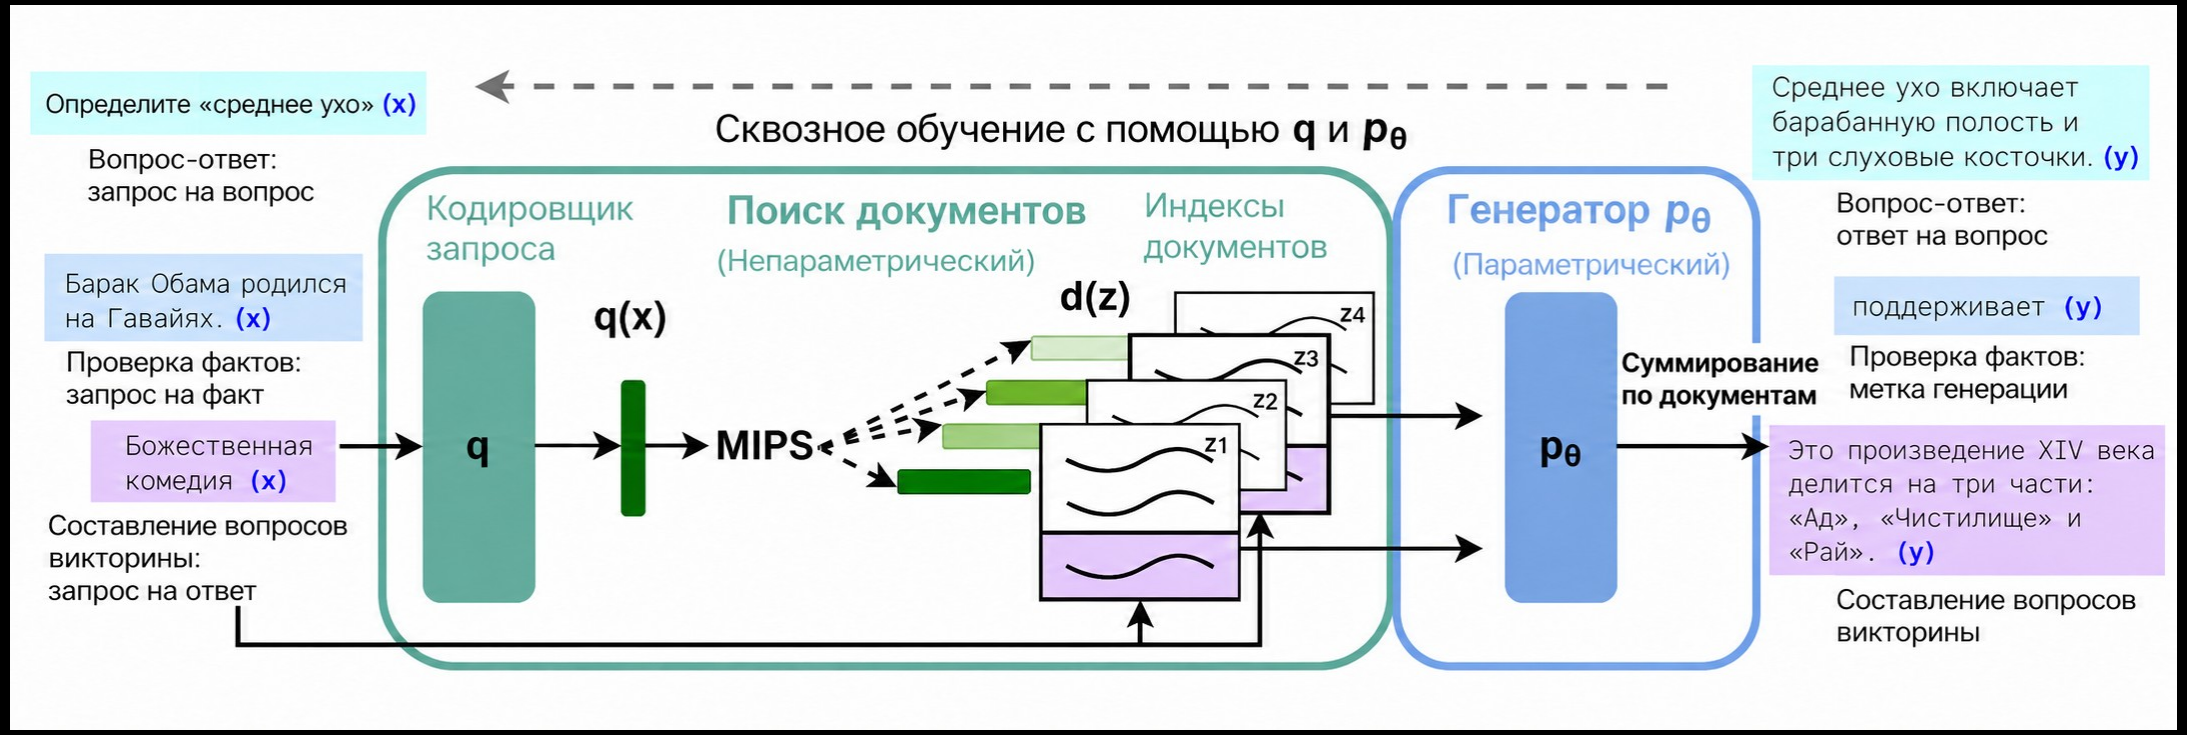
# Оценка качества поиска

- Важны не только найденные документы, но и их позиции в выдаче.

| Позиция | Документ | Соответствие запросу |
|---|---|---|
| 1 | C | Нет |
| 2 | A | Да |
| 3 | D | Нет |

- Полнота среди первых k результатов показывает, какую долю нужных документов удалось извлечь.
- Проверку проводят на наборе запросов с известной оценкой соответствия документов.

# Векторы в ответах по документам




- Поисковая часть выбирает фрагменты, связанные с вопросом пользователя.
- Генератор использует найденные материалы как дополнительный контекст.
- Такой подход называют генерацией с поисковым дополнением, или RAG.

# Поиск и опора ответа на источники

- Наличие поиска не гарантирует достоверности ответа.
- Ошибка может возникнуть при разбиении документов, выборе кандидатов или формировании текста.
- Проверяют, подтверждаются ли утверждения найденными материалами и отвечает ли результат на вопрос.
- При отсутствии подходящих сведений система должна уметь сообщать о недостатке информации.

# Сравнение на семинаре

- Для одной задачи построим исходное решение на TF-IDF и логистической регрессии.
- Затем заменим представление текста на готовые векторы предложений.
- Сохраним сопоставимые данные, метки и правила выбора параметров.
- Сравним качество, скорость вычислений и характер ошибок на конкретных текстах.

# Библиотеки и их назначение

- Инструмент выбирают по нужному этапу обработки, а не только по популярности.

| Инструмент | Назначение |
| --- | --- |
| scikit-learn | Веса слов, классификация, оценка качества |
| Gensim | Векторы слов и документов |
| Hugging Face Transformers | Разбиение текста и готовые кодировщики |
| Sentence Transformers | Векторы текстов и смысловой поиск |

- Модель, словарь и способ объединения представлений должны быть совместимы.
- Версии библиотек и выбранных моделей фиксируют для повторения результата.

# Выбор готовой модели

- Проверяют поддержку русского языка, предметной области и типа поиска.
- Учитывают ограничение длины, размерность, скорость и память.
- Изучают лицензию, описание обучения и ожидаемый формат запросов.
- Окончательное решение принимают по проверке на собственных данных.

# Итоги второй лекции

- Различаем представления слов, предложений и документов.
- Понимаем разницу между статическими векторами и представлениями с учётом контекста.
- Можем объяснить перенос обучения и способы получения вектора нового текста.
- Знаем роль векторов в смысловом поиске и ответах по документам.

# Материалы и источники

Курс ШАД по обработке текста

Векторы слов: Word2Vec, GloVe, fastText

Векторы документов: doc2vec

Контекстные модели: ELMo и BERT

Векторы предложений: Sentence-BERT

Генерация с поиском по документам