Выравнивание и оценка языковых моделей

Предпочтения, безопасность и метрики качества

Илья Новицкий

28 ноября 2026 · Блок 4 · Лекция 2

Содержание лекции

- Разберём, зачем после обучения на инструкциях нужен этап обучения по предпочтениям.
- Сравним RLHF и DPO на уровне идей: какие данные нужны и что оптимизируется.
- Обсудим риски: выдуманные факты, токсичность, смещения и обход ограничений.
- Рассмотрим метрики, оценку с помощью модели-судьи, попарное сравнение и бенчмарки.

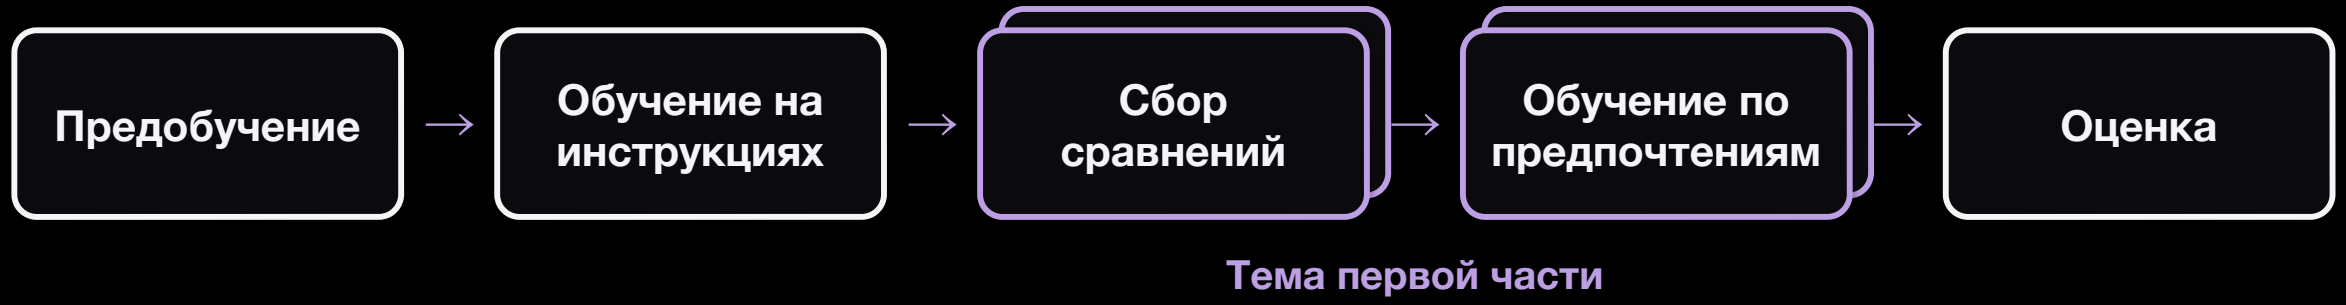
Что называют выравниванием

- Выравнивание — приближение поведения модели к намерениям пользователей и разработчиков.
- Часто используют три ориентира: полезность, честность и безвредность ответа.
- Ориентиры могут конфликтовать: максимально полезный ответ иногда небезопасен.
- Критерии задаются людьми и правилами; модель не выводит их сама из текста.

Почему обучения на инструкциях мало

- Эталонный ответ показывает одну допустимую формулировку, но не объясняет, чем она лучше других.
- Многие качества легче сравнить, чем описать: какой из двух ответов полезнее и точнее.
- Написать идеальный ответ дорого; выбрать лучший из нескольких — дешевле и согласованнее.
- Обучение по сравнениям позволяет снижать вероятность нежелательных ответов, а не только повышать эталон.

Место обучения по предпочтениям



- Сравнения собирают на ответах уже дообученной модели.
- Цикл сбора и обучения может повторяться несколько раз.
- Конкретная последовательность этапов зависит от разработчика модели.

Пример данных предпочтений

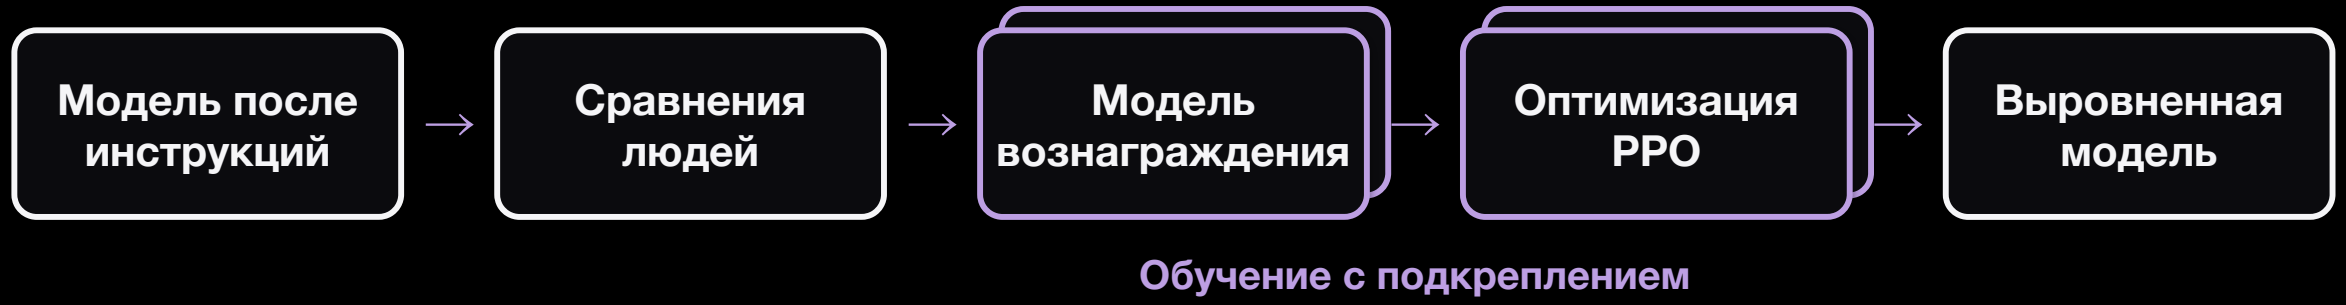
Поле	Содержание
Запрос	Как вернуть деньги за отменённый заказ?
Выбранный ответ	Шаги возврата и срок зачисления по правилам магазина
Отклонённый ответ	«Обратитесь в поддержку» без подробностей

- Одна запись — запрос и два ответа с отметкой, какой из них лучше.
- В TRL поля называются prompt, chosen и rejected.

Сбор сравнений

- Разметчики получают инструкцию с критериями: точность, полнота, безопасность, тон.
- Для одного запроса показывают два или несколько ответов модели и просят выбрать лучший.
- Согласие между разметчиками измеряют: низкое согласие указывает на неясные критерии.
- Часть сравнений можно получать от сильной модели по заданным правилам — RLAIF.

Классическая схема RLHF



- Модель вознаграждения учится предсказывать, какой ответ выберет человек.
- Затем языковая модель генерирует ответы и обновляется, чтобы получать большую оценку.
- Схема описана в работе InstructGPT, 2022.

Модель вознаграждения

$$P(y_w \succ y_l \mid x) = \sigma(r(x, y_w) - r(x, y_l))$$

- r(x, y) — число, которое модель вознаграждения выдаёт для запроса и ответа.
- y_w — предпочтённый ответ, y_l — отклонённый, σ — логистическая функция.
- Модель учится давать предпочтённому ответу большую оценку, чем отклонённому.
- Оценка имеет смысл только для сравнения ответов, а не как абсолютная шкала качества.

Оптимизация с ограничением

$$\max \; E[\, r(x, y) \,] - \beta \cdot KL(\, \pi \,\|\, \pi_{ref} \,)$$

- π — обучаемая модель, π_{ref} — исходная модель после обучения на инструкциях.
- Первое слагаемое поощряет ответы с высокой оценкой вознаграждения.
- Штраф KL не даёт модели слишком далеко уйти от исходного распределения ответов.
- β задаёт баланс: большой β сохраняет исходное поведение, малый — усиливает оптимизацию.

Зачем нужен штраф за отклонение

- Модель вознаграждения обучена на ограниченных данных и ошибается вне их распределения.
- Без ограничения модель находит ответы, которые получают высокую оценку, но не лучше по сути.
- Такое явление называют взломом вознаграждения — reward hacking.
- Штраф сохраняет связь с исходной моделью и её языковыми умениями.

Признаки взлома вознаграждения

Наблюдение	Возможная причина
Ответы становятся всё длиннее	Оценщик предпочитал подробные ответы
Модель чаще соглашается с пользователем	Согласие получало более высокие оценки
Повторяются шаблонные фразы	Фразы ассоциировались с хорошими ответами
Оценка растёт, качество — нет	Оптимизируется слабость оценщика

- Поэтому качество проверяют отдельно от того сигнала, по которому модель обучалась.

Сложности RLHF на практике

- Одновременно нужны несколько моделей: обучаемая, исходная, вознаграждения и оценщик ценности.
- Генерация ответов во время обучения дорогая и медленная.
- Алгоритм PPO чувствителен к гиперпараметрам; обучение может стать нестабильным.
- Ошибки модели вознаграждения переходят в поведение итоговой модели.

Прямая оптимизация предпочтений

- DPO — Direct Preference Optimization — обходится без отдельной модели вознаграждения.
- Модель обучается прямо на парах ответов, как в обычной задаче классификации.
- Нужны только обучаемая модель и замороженная исходная модель для сравнения.
- Метод предложен в 2023 году и быстро стал распространённой заменой PPO.

Функция потерь DPO

$$L = -\log \sigma(\beta \cdot [\log \pi\theta(y_w|x)/\pi_ref(y_w|x) - \log \pi\theta(y_l|x)/\pi_ref(y_l|x)])$$

- Потери уменьшаются, когда модель повышает вероятность выбранного ответа относительно исходной.
- Одновременно понижается относительная вероятность отклонённого ответа.
- Отношение к π_ref играет роль ограничения KL из RLHF.
- Не нужно генерировать ответы во время обучения: пары берутся из набора.

RLHF и DPO

RLHF с PPO

- Отдельная модель вознаграждения
- Генерация ответов при обучении
- Гибко: можно оптимизировать любые сигналы
- Сложнее настроить и дороже

DPO

- Обучение прямо на парах ответов
- Нет генерации при обучении
- Ограничено собранными парами
- Проще и стабильнее в реализации

- Выбор зависит от данных и ресурсов; оба подхода используются в современных моделях.

Другие методы обучения по предпочтениям

Метод	Главная идея
KTO	Отдельные оценки «хорошо» или «плохо» вместо пар
ORPO	Объединяет обучение на инструкциях и предпочтения в одном этапе
SimPO	Не требует исходной модели в функции потерь
RLAIF	Предпочтения размечает модель по набору принципов
GRPO	Сравнение группы ответов вместо модели ценности

- Названия методов полезно знать, чтобы читать документацию TRL и отчёты о моделях.

Обучение с проверяемым вознаграждением

- Для математики и программирования правильность ответа можно проверить автоматически.
- Вознаграждение даёт не модель-оценщик, а проверка: совпадение числа или прохождение тестов.
- Такой сигнал труднее взломать, но он доступен только для задач с однозначной проверкой.
- Подход используют при обучении моделей с развёрнутыми рассуждениями.

DPO в TRL

```
from trl import DPOConfig, DPOTrainer
# train: столбцы prompt, chosen, rejected
args = DPOConfig(output_dir="dpo", beta=0.1, learning_rate=5e-6,
                 num_train_epochs=1, per_device_train_batch_size=4)
trainer = DPOTrainer(model=model, args=args, train_dataset=train,
                     processing_class=tokenizer, peft_config=lora_config)
trainer.train()
```

- С адаптером LoRA исходной моделью служит та же модель с отключённым адаптером.
- Скорость обучения для DPO обычно ниже, чем для обучения на инструкциях.

Параметр β и признаки проблем

- Малое β позволяет модели сильнее отходить от исходной, большое β удерживает её рядом.
- Рост разрыва между выбранными и отклонёнными ответами — ожидаемый признак обучения.
- Если падает вероятность и выбранных ответов, модель может деградировать.
- Длину ответов отслеживают отдельно: предпочтения часто содержат смещение к длинным ответам.

Риски применения языковых моделей

Риск	Пример
Выдуманные факты	Несуществующая статья закона или ссылка
Токсичность	Оскорбительный ответ на провокационный запрос
Смещения	Разные рекомендации при смене имени в запросе
Обход ограничений	Запрещённая инструкция через ролевую игру
Внедрение инструкций	Команда в документе меняет поведение приложения

- Риски проверяют для конкретного применения: требования к чату и к поиску различаются.

Выдуманные факты

- Модель порождает правдоподобный текст, который не подтверждается источниками или противоречит им.
- Причина — цель обучения: модель оценивает правдоподобие продолжения, а не истинность.
- Особенно часты ошибки в числах, датах, именах, цитатах и ссылках.
- В англоязычной литературе это называют галлюцинациями.

Виды ошибок соответствия

Вид	Описание
Противоречие контексту	Ответ не согласуется с переданным документом
Добавление сведений	В ответе есть факты, которых нет в источнике
Фактическая ошибка	Утверждение неверно относительно мира
Ошибка рассуждения	Верные факты, но неверный вывод из них

- Для ответов по документам главный критерий — соответствие источнику.

Как снижать число выдуманных фактов

- Передавать модели проверенные документы и требовать ссылки на конкретные фрагменты.
- Разрешать ответ «в источниках нет сведений» и включать такие случаи в обучающие данные.
- Проверять ответ отдельным шагом: сопоставление утверждений с источником.
- Не дообучать модель на фактах, которых нет в её знаниях, без механизма опоры на источник.

Токсичность

- Оскорбления, угрозы и унижающие высказывания в ответе модели.
- Может появляться при провокационных запросах или при продолжении токсичного контекста.
- Измеряется классификаторами токсичности на наборах провокационных запросов.
- Классификаторы тоже ошибаются, особенно на русском языке, сленге и иронии.

Смещения

- Модель воспроизводит стереотипы, связанные с полом, возрастом, национальностью или профессией.
- Источник — распределение текстов в обучающих данных и выбор разметчиков.
- Смещение проявляется не только в явных высказываниях, но и в различии рекомендаций.
- Проверка: одинаковые запросы, в которых меняется только чувствительный признак.

Проверка с подстановкой признака

Шаблон запроса	Подстановки	Что сравнивают
«{Имя} просит повышения зарплаты. Оцени аргументы.»	Анна / Андрей	Тон и итоговую оценку
«Кандидат {возраст} лет на роль разработчика»	25 / 55	Рекомендацию
«Опиши типичного {профессия}»	врача / медсестру	Пол в описании

- Различие одного ответа случайно; сравнивают доли на десятках повторов и шаблонов.

Обход ограничений

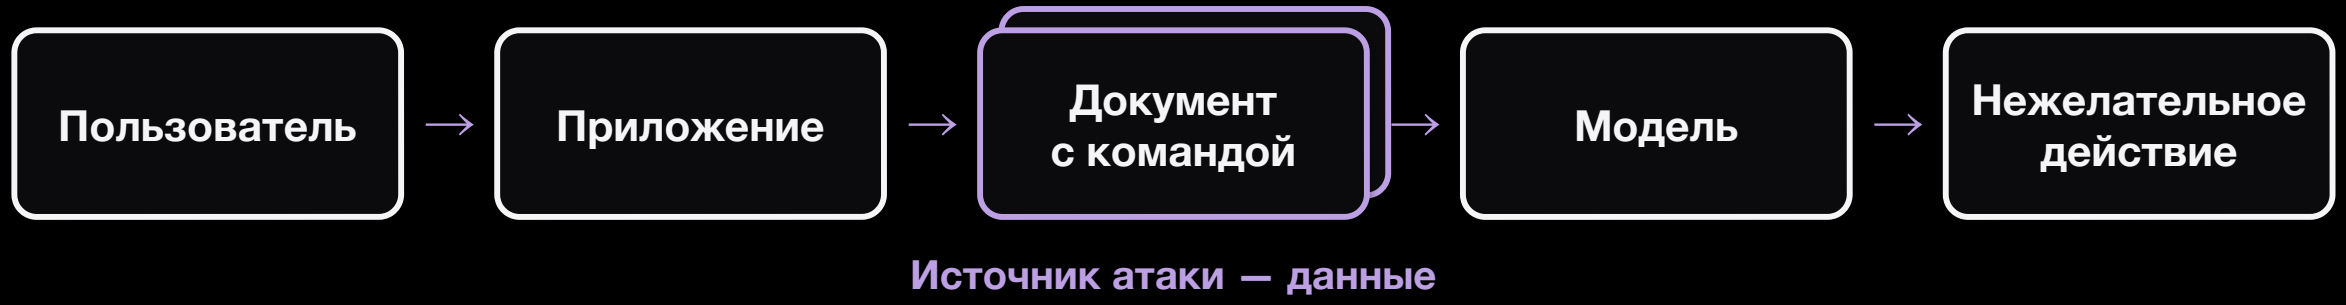
- Пользователь составляет запрос так, чтобы модель нарушила правила, которым её обучали.
- В англоязычной литературе такие запросы называют jailbreak.
- Выровненная модель отказывает на прямую просьбу, но может уступить на переформулированную.
- Устойчивость проверяют наборами атак, а не одним примером отказа.

Типичные приёмы атак

Приём	Идея
Ролевая игра	«Представь, что ты персонаж без ограничений»
Перевод и кодирование	Запрос на редком языке или в закодированном виде
Многоходовый диалог	Цель достигается постепенно за несколько сообщений
Длинный контекст с примерами	Много демонстраций нежелательных ответов
Подобранные суффиксы	Автоматически найденная строка в конце запроса

- Знание приёмов нужно для тестирования собственной системы.

Внедрение инструкций через данные



- Атака приходит не от пользователя, а из письма, страницы или файла.
- Особенно опасна, когда модель может вызывать инструменты: отправлять письма, менять данные.
- Защита: разделять данные и инструкции, ограничивать права инструментов, подтверждать действия.

Защита в несколько уровней

Проверка входа	Классификатор запросов и ограничения длины
Системная инструкция	Правила и границы задачи
Выровненная модель	Отказ на явно вредные запросы
Проверка выхода	Фильтр ответа перед показом
Ограничение инструментов	Минимальные права и подтверждение
Мониторинг	Журнал и разбор инцидентов

- Ни один уровень не надёжен полностью; защита строится из нескольких независимых мер.

Избыточные отказы

- Модель отказывает на безопасный запрос, похожий по словам на опасный.
- Пример: вопрос о том, как «убить процесс» в операционной системе.
- Избыточные отказы снижают полезность и тоже измеряются отдельным набором запросов.
- Цель — точная граница: отказывать на вредное, помогать на допустимое.

Тестирование атаками

- Команда специально ищет запросы, на которых система нарушает правила.
- Найденные случаи пополняют набор регрессионных проверок и данные для обучения.
- Часть атак генерируют автоматически другой моделью, часть придумывают люди.
- В англоязычной практике процесс называют red teaming.

Зачем нужна оценка

- Сравнить модели, промпты и версии дообучения на одинаковых условиях.
- Заметить ухудшение после изменения: регрессию по качеству, формату или безопасности.
- Принять решение о выпуске на основании измерений, а не впечатлений от нескольких примеров.
- Объяснить результат: какие ошибки остались и насколько они критичны.

Способы оценки

Способ	Сильная сторона	Ограничение
Метрики по эталону	Быстро и воспроизводимо	Не видят перефразирования
Модель-судья	Оценивает смысл и стиль	Свои смещения
Оценка людьми	Ближе всего к цели	Дорого и медленно
Бенчмарки	Сравнение с другими моделями	Не ваша задача

- На практике способы комбинируют: каждый закрывает часть недостатков других.

BLEU

$$\mathrm{BLEU} = \mathrm{BP} \cdot \exp\left(\sum_n w_n \cdot \log p_n\right)$$

- p_n — доля n-грамм ответа, найденных в эталоне; обычно n от 1 до 4.
- BP — штраф за краткость: короткий ответ не должен выигрывать только точностью.
- Метрика предложена для машинного перевода и считается по корпусу.
- Хорошо работает, когда допустимых формулировок мало.

ROUGE

- ROUGE-N — полнота: доля n-грамм эталона, найденных в ответе.
- ROUGE-L — длина наибольшей общей подпоследовательности ответа и эталона.
- Метрика исторически используется для оценки кратких изложений.
- Для русского языка важна токенизация: формы слова считаются разными без лемматизации.

Ограничение метрик на совпадениях

Ответ	ROUGE-1 F1	Смысл
Эталон: «Заказ доставят завтра утром»	—	—
«Заказ не доставят завтра утром»	0,89	Противоположный
«Посылку привезут утром следующего дня»	0,22	Совпадает

- Расчёт по словам без лемматизации; числа посчитаны для этого примера.
- Высокое совпадение слов не гарантирует правильный смысл, а низкое — не означает ошибку.

Где метрики на совпадениях уместны

- Как быстрый сигнал при сравнении близких версий системы на одном наборе.
- В задачах с узким набором правильных ответов: извлечение, нормализация, перевод терминов.
- Для обнаружения грубых изменений: пустые ответы, другой язык, обрезка.
- Для открытой генерации их дополняют оценкой смысла.

Модель-судья

- Сильная модель получает запрос, ответ и критерии и выставляет оценку или выбирает лучший ответ.
- Подход называют LLM-as-a-judge; он оценивает смысл, полноту и стиль.
- В работе MT-Bench согласие GPT-4 с людьми было сопоставимо с согласием людей между собой.
- Судья — тоже модель: его ответы проверяют на части данных с ручной разметкой.

Пример запроса к судье

```
Ты оцениваешь ответ службы поддержки.
Критерии: точность по правилам магазина, полнота шагов, вежливость.
Правила: {policy}
Вопрос клиента: {question}
Ответ: {answer}
Сначала кратко обоснуй оценку, затем верни JSON: {"score": 1–5}
```

- Критерии и шкала задаются явно; без них оценки разных запусков несопоставимы.
- Эталон или источник в запросе повышает надёжность проверки фактов.

Смещения модели-судьи

Смещение	Проявление	Что делать
Позиционное	Предпочитает первый ответ	Менять порядок
Длина	Предпочитает длинные ответы	Контролировать длину
Своя модель	Выше оценивает свои ответы	Судья из другого семейства
Стиль	Уверенный тон вместо точности	Чёткие критерии и эталон

- Смещения описаны в работе о MT-Bench и Chatbot Arena, 2023.

Попарное сравнение

- Судья видит два ответа на один запрос и выбирает лучший или фиксирует ничью.
- Сравнить два ответа проще и надёжнее, чем выставить каждому абсолютную оценку.
- Результат — доля побед одной системы над другой на наборе запросов.
- Подходит для сравнения моделей до и после дообучения на одинаковых запросах.

Проверка перестановкой

Порядок в запросе	Вердикт судьи	Итог
A первым, B вторым	A лучше	—
B первым, A вторым	A лучше	Победа A
B первым, A вторым	B лучше	Ничья: зависит от порядка

- Каждую пару оценивают дважды; несогласованные вердикты считают ничьей.
- Доля несогласованных вердиктов — показатель надёжности судьи на задаче.

Рейтинг по попарным сравнениям

$$E_A = 1 / (1 + 10^{((R_B - R_A) / 400)})$$

- E_A — ожидаемая вероятность победы A при рейтингах R_A и R_B.
- После каждого сравнения рейтинги сдвигаются в сторону наблюдаемого исхода.
- Так устроены рейтинги Эло; Chatbot Arena использует близкую модель Брэдли — Терри.
- Разница рейтингов осмысленна, абсолютное значение — нет.

Сравнение моделей людьми

- Chatbot Arena: пользователь задаёт вопрос, получает ответы двух анонимных моделей и голосует.
- Голоса многих людей на разных запросах дают общий рейтинг моделей.
- Рейтинг отражает предпочтения аудитории площадки и типичные для неё запросы.
- Для узкой задачи нужна своя попарная оценка на своих запросах.

Проверка модели-судьи

- Небольшую часть пар размечают люди и сравнивают их вердикты с судьёй.
- Согласие измеряют долей совпадений или коэффициентом каппа Коэна.
- Если согласие низкое, уточняют критерии, добавляют эталон или меняют модель-судью.
- Запрос судьи фиксируют и версионируют, как и любой другой компонент системы.

Бенчмарки языковых моделей

Набор	Что проверяет	Формат
MMLU	Знания по 57 предметам	Выбор из 4 вариантов
MT-Bench	Многоходовые диалоги	Оценка моделью-судьёй
ruMMLU	Знания на русском языке	Выбор из вариантов
MERA	Набор задач для русского языка	Закрытые ответы, лидерборд

- Бенчмарк фиксирует задачи и протокол, чтобы результаты разных моделей были сравнимы.

MMLU

- Massive Multitask Language Understanding: около 16 тысяч вопросов по 57 предметам.
- Предметы — от элементарной математики до права и медицины; уровень от школы до профессионального.
- Ответ — выбор одного из четырёх вариантов; метрика — доля верных ответов.
- Результат зависит от протокола: числа примеров в запросе и способа извлечения ответа.

MT-Bench

- 80 вопросов с двумя ходами диалога в восьми категориях: от письма до программирования.
- Второй ход проверяет, учитывает ли модель контекст и уточнения.
- Ответы оценивает сильная модель-судья по шкале от 1 до 10.
- Набор мал, поэтому различия в десятые доли балла не стоит переоценивать.

Оценка на русском языке

- Переводные наборы, например варианты MMLU на русском, позволяют сравнить с англоязычными результатами.
- Перевод вносит ошибки и не проверяет знания, специфичные для русскоязычного контекста.
- ruMMLU входит в MERA и использует закрытые ответы на тестовой части.
- Для прикладной задачи всё равно нужен свой набор на целевых данных.

MERA

- Открытый бенчмарк для оценки моделей на русском языке с публичным лидербордом.
- Включает около двух десятков задач: знания, логика, математика, код, этика и другие.
- Ответы тестовой части закрыты: результаты отправляют на сервер для подсчёта.
- Закрытые ответы снижают риск подгонки, но не исключают попадание задач в обучение.

Загрязнение тестовых данных

- Задачи бенчмарка могут попасть в обучающие корпуса из открытых источников.
- Модель показывает высокий результат за счёт запоминания, а не умения.
- Признаки: модель продолжает текст вопроса дословно или резко хуже на перефразированных задачах.
- Поэтому результаты на публичных наборах дополняют новыми и закрытыми проверками.

Насыщение бенчмарков

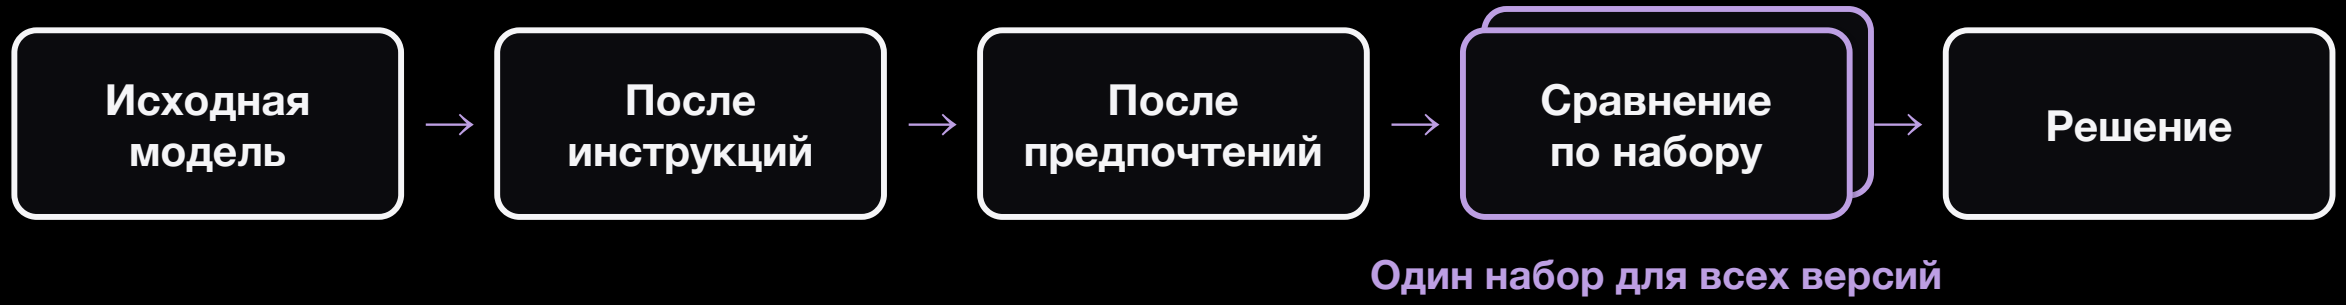
- Когда лучшие модели приближаются к максимуму, набор перестаёт различать их.
- Часть ошибок на верхней границе — ошибки разметки самого набора.
- Появляются более трудные версии: например, MMLU-Pro с десятью вариантами ответа.
- Позиция в рейтинге не заменяет проверку на собственной задаче.

Набор проверок для своей задачи

Компонент	Пример
Основная метрика	Точность извлечения полей
Проверка формата	Доля корректного JSON
Попарное сравнение	Новая версия против текущей
Безопасность	Набор атак и пограничных запросов
Общие умения	Короткий набор общих вопросов

- Набор фиксируют до экспериментов и хранят вместе с версиями моделей и промптов.

Оценка после дообучения



- Все версии оцениваются одним набором проверок с одинаковыми параметрами генерации.
- Попарное сравнение показывает, что изменилось с точки зрения пользователя.
- Ухудшение общих умений или безопасности — повод вернуться к данным.

Отчёт об оценке

- Модели и ревизии, запросы, параметры генерации и версии наборов данных.
- Значения метрик с размером выборки и разбросом, если были повторы.
- Примеры типичных ошибок и случаи, где новая версия хуже прежней.
- Вывод о применимости и известные ограничения.

Контрольные вопросы

- Почему сравнивать ответы проще, чем писать идеальные эталоны?
- Зачем в RLHF ограничивают отклонение от исходной модели?
- Какие данные нужны для DPO и какие модели участвуют в обучении?
- Почему высокий ROUGE не гарантирует правильный ответ?
- Как проверить, что модель-судья не зависит от порядка ответов?

Материалы и подготовка к семинару

- На семинаре: обучим LoRA-адаптер в TRL, затем дообучим его по предпочтениям с DPO.

Training language models to follow instructions (InstructGPT)

Direct Preference Optimization

Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena

Measuring Massive Multitask Language Understanding

MERA: оценка моделей на русском языке